# זיהוי זיופים קוליים באמצעות שילוב ייצוגים ספקטרו-טמפורליים — AASIST

Jung et al. (2022) במאמרם *AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks*, מציגים ארכיטקטורת למידה עמוקה לזיהוי זיופים קוליים, המבוססת על שילוב מידע זמני וספקטרלי באמצעות Graph Attention Networks. המחקר מתמקד באתגר של זיהוי ארטיפקטים המעידים על דיבור מזויף, אשר עשויים להופיע במקטעי זמן ובתחומי תדר שונים בהתאם לשיטת יצירת הזיוף. כחלופה למערכות מורכבות המשלבות מספר מודלים, החוקרים מציעים מערכת End-to-End יחידה המסוגלת ללמוד קשרים בין סוגי המידע השונים.

הארכיטקטורה מקבלת אות אודיו גולמי (Raw Waveform) ומשתמשת ב-Encoder המבוסס על RawNet2 לחילוץ מאפיינים ראשוניים. מאפיינים אלו משמשים לבניית שני ייצוגי גרף, זמני וספקטרלי, אשר משולבים באמצעות Heterogeneous Stacking Graph Attention Layer (HS-GAL). שכבה זו כוללת מנגנון Attention המבחין בין קשרים בתוך כל אחד מהגרפים לבין קשרים בין הגרפים, וכן Stack Node המשמש לצבירת מידע משולב. נוסף על כך, החוקרים מציגים מנגנון Max Graph Operation (MGO), המבוסס על שני ענפים מקבילים ופעולת Maximum בין פלטיהם, במטרה לעודד למידה של מאפיינים משלימים. מנגנון Readout ייעודי משלב את המידע שנצבר בצומתי הגרף וב-Stack Node לצורך הפקת החלטת הסיווג.

השיטה הוערכה על מאגר ASVspoof 2019 במסלול Logical Access, הכולל מתקפות סינתוז דיבור והמרת קול, באמצעות מדדי Equal Error Rate (EER) ו-minimum tandem Detection Cost Function (min t-DCF). בהשוואה למודל RawGAT-ST, מערכת AASIST השיגה EER ממוצע של 1.13% לעומת 1.39%, ו-min t-DCF ממוצע של 0.0347 לעומת 0.0443, שיפור יחסי של כ-22% במדד האחרון. בריצה הטובה ביותר השיגה AASIST תוצאות של EER 0.83% ו-min t-DCF 0.0275. בנוסף, הוצגה גרסה קלת-משקל בשם AASIST-L, הכוללת 85 אלף פרמטרים בלבד ומשיגה EER של 0.99% בריצה המדווחת הטובה ביותר. ניסויי Ablation הראו כי שלושת החידושים הארכיטקטוניים תורמים לביצועי המודל, כאשר להסרת Heterogeneous Attention הייתה ההשפעה השלילית הגדולה ביותר.

למרות התוצאות החזקות, המחקר הוערך על ASVspoof 2019 LA בלבד, ולכן אינו מספק ראיה ישירה ליכולת ההכללה של המודל למאגרים מאוחרים יותר או לזיופים המבוססים על Neural Audio Codecs. כמו כן, אף שמנגנון MGO נועד לעודד למידה של מאפיינים משלימים, לא הוצג ניתוח שמזהה באופן מפורש אילו ארטיפקטים נלמדים בכל אחד מענפי המודל. נוסף על כך, ההבדלים בין ריצות בעלות Random Seeds שונים מדגישים את החשיבות של הערכת יציבות המודל לצד דיווח על תוצאותיו הטובות ביותר.

עבור המחקר הנוכחי, AASIST מהווה מועמד משמעותי לבחינת גישה מבוססת Deep Learning המשלבת קשרים בין מאפיינים זמניים וספקטרליים. בהתאם לכך, ניתן להשוות את AASIST או את גרסתו הקלה AASIST-L למודלים קלאסיים המבוססים על MFCC ו-CQCC, וכן לבחון את יכולת ההכללה שלהם בין מקורות נתונים ושיטות זיוף שונים. הערכה זו תתבסס על פרוטוקול מבוקר, שמירה על הפרדה בין קבוצות הנתונים ושימוש ב-EER כמדד המרכזי, תוך התייחסות ליציבות הביצועים ולדרישות החישוביות.

**מקור ביבליוגרפי**

Jung, J.-w., Heo, H.-S., Tak, H., Shim, H.-j., Chung, J. S., Lee, B.-J., Yu, H.-J., & Evans, N. (2022). AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 6367–6371. https://doi.org/10.1109/ICASSP43922.2022.9747766