Self-Supervised Learning — למידת ייצוגי דיבור באמצעות wav2vec 2.0

Baevski et al. (2020) במאמרם *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*, מציגים מסגרת ללמידה עצמית מונחית (Self-Supervised Learning) של ייצוגי דיבור מתוך אותות אודיו גולמיים, ללא צורך בתמלול בשלב האימון המקדים. המחקר מתמודד עם התלות של מערכות Automatic Speech Recognition (ASR) בכמויות גדולות של נתונים מתויגים, ומציע לנצל מאגרי אודיו לא מתויגים ללמידת ייצוגים הניתנים להתאמה בהמשך למשימות מפוקחות. גישה זו מאפשרת להפריד בין למידת מאפייני הדיבור לבין לימוד משימת היעד, ובכך עשויה לצמצם את כמות הנתונים המתויגים הנדרשת.

הארכיטקטורה משלבת Convolutional Feature Encoder המחלץ ייצוגים לטנטיים רציפים מאות האודיו, ו-Transformer המייצר ייצוגים הקשריים באמצעות למידת קשרים בין מקטעי הדיבור. במהלך ה-Pre-training מוסתרים מקטעים מתוך הייצוגים הלטנטיים, והמודל מאומן באמצעות Contrastive Learning לזהות את ייצוג המטרה הנכון של המקטע המוסתר מתוך קבוצת מועמדים. מטרות האימון מופקות באמצעות Quantization Module המבוסס על Product Quantization ו-Gumbel-Softmax, ונלמדות במשותף עם יתר רכיבי המודל. נוסף על כך, נעשה שימוש ב-Diversity Loss לעידוד שימוש מגוון בקודים הבדידים. לאחר האימון המקדים, החוקרים מבצעים Fine-Tuning על נתוני דיבור מתומללים באמצעות Connectionist Temporal Classification (CTC) Loss לצורך משימות זיהוי דיבור.

המחקר הוערך באמצעות מאגרי LibriSpeech ו-LibriVox, תוך בחינת תצורות מודל BASE ו-LARGE וכמויות משתנות של נתוני אימון מתויגים. בניסוי שבו מודל LARGE עבר Pre-training על כ-53,200 שעות אודיו לא מתויג ולאחר מכן Fine-Tuning באמצעות עשר דקות בלבד של נתונים מתויגים, הושג Word Error Rate (WER) של 4.8% על test-clean ו-8.2% על test-other, תוך שימוש במודל שפה בזמן הפענוח. כאשר נעשה שימוש ב-960 שעות נתונים מתויגים, התקבלו תוצאות של 1.8% ו-3.3%, בהתאמה. בנוסף, השוואה לאימון מאפס הדגימה שיפור בביצועים בעקבות Pre-training גם בתנאים שבהם זמינה כמות גדולה של נתונים מתויגים. ניסויי Ablation הראו כי שימוש בייצוגים רציפים כקלט ל-Transformer ובמטרות Quantized עבור ה-Contrastive Loss השיג את התוצאות הטובות ביותר מבין החלופות שנבדקו, ובכך תמכו בבחירה הארכיטקטונית המרכזית של השיטה.

למרות הישגי המחקר, חשוב להדגיש כי wav2vec 2.0 פותח והוערך במקור עבור Speech Recognition ו-Phoneme Recognition, ולא עבור זיהוי זיופים קוליים. לפיכך, התוצאות אינן מוכיחות שהייצוגים הנלמדים מכילים את כל המאפיינים האקוסטיים הנדרשים לזיהוי דיבור סינתטי או מניפולציות קוליות. יתרה מכך, ייצוגים המותאמים לזיהוי תוכן לשוני עשויים להיות רגישים למאפיינים שונים מאלו המשמשים להבחנה בין דיבור אמיתי למזויף. נוסף על כך, ה-Pre-training המקורי דורש משאבי חישוב נרחבים, וחלק מתוצאות זיהוי הדיבור נשענות גם על מודלי שפה חיצוניים.

עבור המחקר הנוכחי, תרומתו המרכזית של wav2vec 2.0 היא בהצגת תשתית ללמידת ייצוגי דיבור שניתן להתאים למשימות חדשות גם כאשר כמות הנתונים המתויגים מוגבלת. בהינתן מאגר ההקלטות המצומצם יחסית בפרויקט זיהוי הזיופים הקוליים, ניתן לבחון שימוש במודל מאומן מראש כ-Feature Extractor קפוא, ולהשוות אותו לגישת Fine-Tuning שבה חלק ממשקליו מותאמים למשימת הסיווג. בנוסף, ניתן להשוות את ביצועיו למודלים המבוססים על MFCC, CQCC ו-AASIST, תוך שימוש בפרוטוקול הערכה אחיד וב-EER כמדד המרכזי. השוואה זו תאפשר לבחון האם ייצוגי דיבור שנלמדו באמצעות Self-Supervised Learning מספקים מידע שימושי לזיהוי זיופים וליכולת הכללה בין מקורות נתונים ושיטות תקיפה שונות.

מקור ביבליוגרפי:

Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. arXiv:2006.11477. https://arxiv.org/abs/2006.11477