למידת ייצוגי דיבור רב-תכליתיים באמצעות Self-Supervised Learning — WavLM

Chen et al. (2022) במאמרם *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing*, מציגים מסגרת ללמידת ייצוגי דיבור באמצעות Self-Supervised Learning (SSL), המיועדת למגוון רחב של משימות עיבוד דיבור ולא רק לזיהוי תוכן לשוני. בניגוד לגישות קודמות שהתמקדו בעיקר ב-Automatic Speech Recognition (ASR), המחקר מדגיש את הצורך בלמידת ייצוגים המכילים מידע על תוכן הדיבור, זהות הדובר ומאפיינים אקוסטיים ופארה-לשוניים נוספים. החוקרים מצביעים על כך שמשימות שונות דורשות סוגים שונים של מידע, ולעיתים אף מציבות דרישות מנוגדות: זיהוי דיבור מתמקד בתוכן הלשוני, בעוד שאימות דובר מחייב שימור מאפיינים ייחודיים של זהות הדובר.

הארכיטקטורה של WavLM מבוססת על Convolutional Feature Encoder ו-Transformer, ומרחיבה בעיקר את מסגרת ה-Masked Speech Prediction של HuBERT. החידוש המרכזי הוא שילוב של Masked Speech Prediction עם Denoising בשלב ה-Pre-training. במסגרת זו, החוקרים יוצרים הקלטות משובשות באופן מלאכותי באמצעות הוספת רעשי רקע או דיבור חופף של דובר נוסף, ומאמנים את המודל לחזות את ה-Pseudo-labels של הדיבור המקורי במקטעים מוסתרים. מטרת התהליך היא לשפר את יכולת המודל ללמוד ייצוגים שימושיים גם כאשר אות הדיבור מכיל הפרעות או מספר דוברים. בנוסף, החוקרים משלבים מנגנון Gated Relative Position Bias, המאפשר להתאים את השפעת המיקום היחסי במנגנון ה-Self-Attention לתוכן הייצוגים, ומרחיבים את מאגר האימון לכ-94,000 שעות אודיו ממקורות מגוונים, הכוללים Libri-Light, GigaSpeech ו-VoxPopuli.

המודל הוערך באמצעות מסגרת SUPERB, הכוללת 15 משימות המייצגות היבטים שונים של עיבוד דיבור, וכן באמצעות ארבע משימות נוספות שנבדקו על מאגרי הערכה ייעודיים. בניסויי SUPERB, מודל WavLM Base, הכולל כ-94.7 מיליון פרמטרים ואומן על 960 שעות אודיו, השיג תוצאות טובות יותר מ-wav2vec 2.0 Base ומ-HuBERT Base במספר משימות מרכזיות. לדוגמה, במדד Speaker Diarization Error Rate התקבל ערך של 4.55% לעומת 6.08% ו-5.88%, בהתאמה. בניסוי Ablation, הסרת רכיב ה-Denoising הגדילה את שגיאת ה-Diarization ל-6.03%, בעוד שהסרת השינוי הארכיטקטוני הגדילה את ה-WER במשימת ASR מ-6.21% ל-6.80%. תוצאות אלו מצביעות על תרומה שונה של רכיבי המודל למשימות שונות, ולא על שיפור אחיד בכל מדד.

בניסויי ההערכה הנוספים, WavLM Large הציג ביצועים חזקים באימות דובר, בהפרדת דיבור וב-Speaker Diarization. בין היתר, מערכת אימות דובר המבוססת על WavLM Large, לאחר התאמות נוספות של Fine-Tuning וכיול ציונים, השיגה EER של 0.383% בפרוטוקול VoxCeleb1-O. חשוב להדגיש כי תוצאה זו מתייחסת לאימות זהות דובר, ולא לזיהוי זיופים קוליים. בנוסף, החוקרים הראו שבחלק ממשימות הדובר והפרדת הדיבור, שימוש ב-Encoder קפוא הניב ביצועים טובים יותר מעדכון משקליו, ממצא המעיד על כך ש-Fine-Tuning אינו מבטיח שיפור בכל תנאי. ניתוח תרומת שכבות ה-Transformer הראה גם כי משימות שונות מפיקות תועלת משכבות שונות: שכבות מוקדמות ואמצעיות תרמו במידה רבה למידע הקשור לדוברים, בעוד ששכבות גבוהות היו משמעותיות יותר במשימות תוכן וזיהוי דיבור.

למרות הישגיו, המחקר אינו בוחן ישירות Deepfake Detection, ולכן אינו מוכיח ש-WavLM משמר את הארטיפקטים האקוסטיים הנדרשים להבחנה בין דיבור אמיתי למזויף. יתרה מכך, האימון המקדים לעמידות לרעש ולדיבור חופף עשוי לסייע בהכללה לתנאי הקלטה שונים, אך ייתכן גם שיפחית רגישות למאפיינים אקוסטיים עדינים הרלוונטיים לזיהוי זיופים. בנוסף, שיפור הביצועים בעקבות הרחבת נתוני ה-Pre-training אינו מאפשר לבודד לחלוטין את תרומת גיוון מקורות האודיו, מכיוון שגם היקף האימון וגורמים נוספים משתנים.

עבור המחקר הנוכחי, WavLM מציע גישה רלוונטית לבחינת ייצוגי דיבור מאומנים מראש במסגרת משימת זיהוי זיופים קוליים. בהמשך ל-wav2vec 2.0, ניתן להשוות את שני המודלים כ-Frozen Encoders תחת פרוטוקול אחיד, ולבדוק האם ייצוגיו הרב-תכליתיים של WavLM משפרים את ביצועי הסיווג במדד EER. נוסף על כך, ממצאי ניתוח השכבות מצדיקים בחינה של שילוב ייצוגים ממספר שכבות לעומת שימוש בשכבה האחרונה בלבד, וכן השוואה בין Frozen Encoder לבין Fine-Tuning. ניסויים אלו עשויים לסייע בקביעת מידת התאמתם של ייצוגי SSL לזיהוי מתקפות TTS, Voice Conversion וזיופים המבוססים על Neural Audio Codecs, תוך בחינת יכולת ההכללה בין מקורות הנתונים של הפרויקט.

מקור ביבליוגרפי:

Chen, S., Wang, C., Chen, Z., et al. (2022). *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing*. arXiv:2110.13900. https://arxiv.org/abs/2110.13900