זיהוי זיופים קוליים המבוססים על Neural Audio Codecs — CodecFake

במאמרם Wu, Tseng, and Lee (2024), *CodecFake: Enhancing Anti-Spoofing Models Against Deepfake Audios from Codec-Based Speech Synthesis Systems*, חוקרים את יכולתן של מערכות קיימות לזיהוי זיופים קוליים להתמודד עם דיבור שנוצר באמצעות מערכות סינתזת דיבור המבוססות על Neural Audio Codecs. מערכות אלו משתמשות בייצוגים בדידים של אודיו כחלק מתהליך יצירת הדיבור, ומאפשרות הפקת דיבור סינתטי באיכות גבוהה, לרבות חיקוי קול של דוברים שלא נכללו באימון. החוקרים מצביעים על פער בין ההתקדמות במערכות ליצירת דיבור לבין יכולת ההכללה של מודלי Anti-Spoofing שאומנו על מאגרים קיימים, ובפרט ASVspoof 2019.

לצורך בחינת הבעיה, החוקרים הציגו את מאגר CodecFake, שנבנה באמצעות שישה סוגים של Neural Audio Codec Frameworks הכוללים 15 מודלים מאומנים מראש. בניגוד ליצירת דיבור מלאה באמצעות Codec Language Models, תהליך יצירת המאגר מבוסס על Codec Resynthesis: הקלטת דיבור אמיתית מקודדת לרצף קודים בדידים באמצעות Codec Encoder, ולאחר מכן משוחזרת באמצעות Codec Decoder. גישה זו מאפשרת להתמקד במאפיינים האקוסטיים הקשורים לתהליך הקידוד והפענוח, תוך צמצום התלות בהבדלים בין מודלי יצירת הדיבור. המאגר נבנה מתוך VCTK, והחוקרים השתמשו בחלוקה נפרדת לפי דוברים בין קבוצות האימון, האימות והבדיקה, כדי לצמצם את האפשרות שהמודלים ילמדו לזהות דוברים ספציפיים במקום מאפייני זיוף.

לצורך ההערכה, החוקרים השתמשו בארכיטקטורת AASIST-L והשוו בין מודלים שאומנו על ASVspoof 2019 Logical Access לבין מודלים שאומנו על תתי-קבוצות שונות של CodecFake. בניסויי Cross-Testing, כל מודל אומן על דוגמאות משוחזרות באמצעות Codec מסוים ועל הקלטות המקור המתאימות, ולאחר מכן נבחן על דוגמאות שנוצרו באמצעות כל 15 מודלי ה-Codec. התוצאות הראו שמודלים שאומנו על ASVspoof 2019 התקשו לזהות חלק ניכר מהדוגמאות המשוחזרות, ובמרבית תתי-הקבוצות התקבלו שיעורי Equal Error Rate (EER) גבוהים מ-30%. לעומת זאת, אימון על Codec מסוים הניב בדרך כלל תוצאות טובות יותר כאשר הבדיקה בוצעה על אותו Codec או על מודלים מאותה משפחה. עם זאת, בחלק מהמקרים נצפו פערים ניכרים בין ביצועים על מתקפות מוכרות לבין ביצועים על סוגי Codec אחרים, דבר המדגיש את אתגר ההכללה בין מנגנוני יצירת אודיו שונים.

כדי לבחון האם מאגר המבוסס על Resynthesis יכול לסייע גם בזיהוי דיבור שנוצר באמצעות מערכות סינתזה מלאות, החוקרים העריכו את המודלים על דוגמאות מ-VALL-E, מ-VALL-E X ומ-SpeechX. במערכת VALL-E, מודל AASIST-L שאומן על ASVspoof 2019 השיג EER של 13.91%, בעוד שמודל שאומן על CodecFake Subset E, המבוסס על EnCodec, השיג EER של 0.40%. תוצאה זו מדגימה כי נתוני Codec Resynthesis יכולים לסייע באיתור דיבור שנוצר באמצעות מערכת Codec-Based Speech Synthesis מלאה, גם כאשר מודל יצירת הדיבור עצמו אינו חלק מתהליך בניית המאגר. שיפורים נצפו גם על VALL-E X ועל SpeechX, אך החוקרים מציינים שמספר דוגמאות ההערכה שנאספו מדפי ההדגמה קטן, ובפרט לא ניתן היה לאמת את המשמעות הסטטיסטית של השיפור עבור SpeechX. נוסף על כך, הביצועים השתנו במידה רבה בהתאם לתת-קבוצת ה-Codec שנבחרה לאימון, ולכן אין להסיק שכל סוג Codec מספק יכולת הכללה דומה.

מבחינה מחקרית, התרומה המרכזית של CodecFake היא בהדגמת הקושי של מערכות Anti-Spoofing להכליל לטכנולוגיות סינתזה המבוססות על Neural Audio Codecs, ובהצגת שיטה לבניית נתוני אימון המיועדים לצמצם פער זה. עם זאת, המחקר מתמקד בארכיטקטורת זיהוי מרכזית אחת, AASIST-L, ובמספר מוגבל של מערכות סינתזה מלאות. כמו כן, לא נבדקה באופן שיטתי תרומתו של אימון משותף על כל תתי-הקבוצות, ולא הוכחה יכולת הכללה לכל מערכת Codec-Based עתידית. לכן, יש לפרש את התוצאות כראיה לתועלת האפשרית של נתוני Codec Resynthesis, ולא כהוכחה לפתרון אוניברסלי לזיהוי זיופים קוליים.

עבור המחקר הנוכחי, מאמר CodecFake רלוונטי במיוחד משום שחלק ממאגר ההקלטות של הפרויקט מקורו ב-CodecFake, לצד דוגמאות מ-ASVspoof 5 ומ-M-AILABS. המאמר מדגיש את הצורך להעריך מודלים לא רק באמצעות EER כולל, אלא גם תוך בחינת יכולת ההכללה בין מקורות נתונים וסוגי מתקפות. בהתאם לכך, ניתן להשוות בין גישות המבוססות על מאפיינים אקוסטיים קלאסיים, על AASIST ועל ייצוגי דיבור מאומנים מראש כגון wav2vec 2.0 ו-WavLM, תוך שמירה על פרוטוקול הערכה אחיד ומניעת דליפת מידע. בנוסף, יש לבחון האם המודלים לומדים מאפייני זיוף כלליים או מסתמכים על מאפיינים ייחודיים למקור הנתונים. מחקר זה מחזק אפוא את החשיבות של Cross-Dataset Generalization כמרכיב מרכזי בהערכת מערכות לזיהוי זיופים קוליים.

מקור ביבליוגרפי:

Wu, H., Tseng, Y., & Lee, H.-y. (2024). *CodecFake: Enhancing Anti-Spoofing Models Against Deepfake Audios from Codec-Based Speech Synthesis Systems*. arXiv:2406.07237. https://arxiv.org/abs/2406.07237