שיפור עקבות זיוף באמצעות שחזור מאפיינים ספקטרליים מונחה — Enhanced Forensic Trace Generation

Wu et al. (2026), במאמרם *Robust Speech Forgery Detection via Enhanced Forensic Trace Generation*, מציגים מסגרת לשיפור זיהוי זיופים קוליים באמצעות שחזור מאפיינים ספקטרליים והגברת המידע המבחין בין דיבור אמיתי למזויף. המחקר מתמודד עם מגבלותיהן של גישות המבוססות על מאפיינים אקוסטיים מחושבים מראש, כגון LFCC, CQCC ו-Log Power Spectrum (LPS), אשר מציעות יעילות חישובית ויציבות, אך עלולות להתקשות בהכללה לתנאי הקלטה ולמתקפות זיוף שלא נכללו באימון. במקביל, החוקרים מציינים כי מודלים עמוקים עשויים לשפר את יכולת ייצוג המידע, אך לעיתים דורשים משאבי חישוב משמעותיים ומפגינים ירידה בביצועים תחת שינויי התפלגות. לפיכך, המחקר מציע לשפר את איכות המאפיינים המועברים למסווג באמצעות תהליך שחזור ייעודי, במקום להסתמך על המאפיינים המקוריים בלבד.

השיטה המוצעת מבוססת על Vector Quantized Variational Autoencoder (VQ-VAE), המשמש לשחזור מאפיינים ספקטרליים מתוך ייצוג לטנטי בדיד. ההנחה המרכזית היא שתהליך השחזור יכול להבליט אי-התאמות ועקבות אקוסטיות הקשורות לדיבור מסונתז, ובכך להקל על זיהוין באמצעות מסווג. כדי לצמצם את הסיכון לאובדן מידע במהלך השחזור, החוקרים משלבים את המאפיינים המקוריים עם המאפיינים המשוחזרים. בניסויים, השילוב מבוצע במשקל שווה של 0.5 לכל אחד משני מקורות המידע, והייצוג המתקבל מועבר למסווג מבוסס ResNet.

החידוש המתודולוגי המרכזי הוא אסטרטגיית **Knowledge-Driven Generation Optimization**, שבה נעשה שימוש ב-Encoder של מסווג Anti-Spoofing מאומן מראש לצורך הנחיית תהליך האימון של ה-VQ-VAE. משקלי ה-Encoder נשארים קפואים, והייצוגים שהוא מפיק משמשים כאותות פיקוח למודל השחזור. בעוד שה-VQ-VAE משחזר ספקטרוגרמות של דיבור אמיתי, דוגמאות של דיבור מזויף משולבות בתהליך הפיקוח כדי לעודד הפרדה מבחינה במרחב המאפיינים. לשם כך החוקרים מציעים שלושה רכיבי Loss משלימים: **True Speech Consistency Loss**, המעודד דמיון בין ייצוגי הדיבור האמיתי והשחזור שלו; **Triplet Loss**, המעודד הפרדה בין ייצוגי דיבור אמיתי למזויף ביחס לייצוג המשוחזר; ו-**Positive Sample Constraint**, המגביל את המרחק בין ייצוג הדיבור האמיתי לבין ייצוג השחזור שלו.

החוקרים העריכו את השיטה באמצעות אימון על ASVspoof 2019 Logical Access ובדיקה על קבוצות ההערכה של ASVspoof 2019 LA ו-ASVspoof 2021 LA. בניסויים נבחנו שלוש משפחות מאפיינים — LFCC, CQCC ו-LPS — הן בצורתן המקורית והן לאחר שחזור ושילוב באמצעות VQ-VAE. על ASVspoof 2021 LA, שילוב המאפיינים המשוחזרים שיפר את ה-EER בכל שלוש המשפחות: עבור LFCC התקבלה ירידה מ-26.89% ל-20.87%, עבור CQCC מ-23.29% ל-19.33%, ועבור LPS מ-22.64% ל-14.04%. השיפור האחרון, של 8.60 נקודות אחוז, מייצג ירידה יחסית של כ-38% ב-EER בהשוואה ל-ResNet המשתמש במאפייני LPS מקוריים בלבד. בתנאי הערכה אלה, FVQ-LPS השיג גם EER נמוך מזה של מודלי ההשוואה המופיעים במאמר, ובהם AASIST, שהשיג 15.84%.

ניסויי Ablation תמכו בתרומתה של אסטרטגיית האימון המוצעת. הסרת רכיב ה-Triplet Loss הגדילה את ה-EER על ASVspoof 2021 LA מ-14.04% ל-20.92%, בעוד שהסרת True Speech Consistency Loss הגדילה אותו ל-16.00%, והסרת Positive Sample Constraint הגדילה אותו ל-15.30%. תוצאות אלו מצביעות על חשיבותו המיוחדת של רכיב ההפרדה בין המחלקות. בנוסף, השוואת מודלי שחזור מסוג Autoencoder, Variational Autoencoder ו-VQ-VAE הראתה כי VQ-VAE השיג את הביצועים הטובים ביותר בתנאי הניסוי שנבדקו. ניסויי Cross-Feature הראו גם כי שילוב המאפיינים המקוריים והמשוחזרים יכול להיות מועיל יותר משימוש בכל אחד מהם בנפרד.

למרות התוצאות החיוביות, לשיטה מספר מגבלות. ראשית, השיפור בהכללה הודגם במסגרת מעבר מ-ASVspoof 2019 LA ל-ASVspoof 2021 LA, ולא נבחן ישירות על ASVspoof 5 או על מאגרי זיופים המבוססים על Neural Audio Codecs כגון CodecFake. שנית, תהליך השחזור מוסיף מורכבות חישובית: המערכת המוצעת כוללת כ-5.67 מיליון פרמטרים ו-3.12 מיליארד פעולות MAC, לעומת כ-2.34 מיליון פרמטרים ו-1.25 מיליארד פעולות MAC ב-ResNet הבסיסי. לפיכך, השיפור ביכולת הזיהוי כרוך בעלות חישובית נוספת. כמו כן, התוצאות אינן מוכיחות ששחזור באמצעות VQ-VAE יועיל באופן דומה לכל ייצוג אקוסטי, ארכיטקטורת זיהוי או מאגר נתונים.

עבור המחקר הנוכחי, תרומתו המרכזית של המאמר היא בהצגת גישה משלימה לשיפור מאפיינים אקוסטיים קיימים באמצעות שחזור מונחה-משימה. ניתן לבחון האם שילוב מאפיינים מקוריים ומשוחזרים משפר את זיהוי הזיופים ואת יכולת ההכללה בין ASVspoof 5 ל-CodecFake, תוך השוואה לגישות המבוססות על MFCC, CQCC, AASIST ומודלי SSL מאומנים מראש כגון wav2vec 2.0 ו-WavLM. עם זאת, בהתחשב בגודלו המוגבל של מאגר הקורס ובמורכבות האימון של VQ-VAE, השיטה מתאימה בשלב זה לניסוי הרחבה אפשרי לאחר הקמת Baseline יציב והערכת המודלים המאומנים מראש. גישה הדרגתית זו תאפשר לבחון האם השיפור האפשרי ב-EER מצדיק את תוספת המשאבים ומורכבות המימוש.

מקור ביבליוגרפי:

Wu, S., Cheng, Y., Wang, R., & Yan, D. (2026). *Robust Speech Forgery Detection via Enhanced Forensic Trace Generation*. Signal, Image and Video Processing, 20, Article 130. https://doi.org/10.1007/s11760-026-05167-y