זיהוי זיופים קוליים באמצעות שילוב מאפיינים אקוסטיים ומודלים סטטיסטיים ועמוקים — Intelligent Voice Fraud Detection

Izrailov et al. (2026), במאמרם *Intelligent Voice Fraud Detection Methods in Authentication Systems*, מציגים גישה היברידית לזיהוי זיופים קוליים במערכות אימות ביומטרי מבוססות קול. המחקר מתמקד בפגיעותן של מערכות Speaker Verification למתקפות התחזות, שבהן תוקף עשוי להשתמש בהקלטה חוזרת, בדיבור מסונתז או בהמרת קול כדי להתחזות למשתמש מורשה. החוקרים מדגישים כי התאמה בין קול ההקלטה לבין זהותו הנטענת של הדובר אינה מספיקה להבטחת אותנטיות, ולכן נדרש לשלב מנגנוני Anti-Spoofing המסוגלים לזהות מאפיינים המעידים על זיוף. מטרת המחקר היא לשפר את אמינות הזיהוי באמצעות שילוב שיטות קלאסיות לעיבוד אותות דיבור עם מידול סטטיסטי ולמידה עמוקה.

השיטה המוצעת כוללת מספר שלבי עיבוד. תחילה מבוצע Preprocessing של אות הדיבור, הכולל הסרת מקטעי שקט, התאמת עוצמה, המרה לערוץ מונו ושינוי קצב הדגימה לתדר אחיד, כגון 16kHz. לאחר מכן מחולצים מאפיינים אקוסטיים מסוג Mel-Frequency Cepstral Coefficients (MFCC) ו-Perceptual Linear Prediction (PLP). מאפייני MFCC מתארים היבטים של המעטפת הספקטרלית על בסיס סולם Mel, בעוד ש-PLP משלב עקרונות של תפיסה שמיעתית עם Linear Predictive Coding. החוקרים מניחים כי שילוב שני סוגי המאפיינים עשוי לספק מידע משלים על מבנה הדיבור ועל ארטיפקטים הנוצרים בתהליכי סינתזה והמרת קול.

לאחר חילוץ המאפיינים, החוקרים משתמשים במודל Gaussian Mixture Model–Universal Background Model (GMM–UBM) ליצירת ייצוג סטטיסטי של הקלטת הדיבור. מודל הרקע מתאר מאפיינים של דיבור ממספר דוברים, וניתן להתאימו למאפייני הקלטה או דובר באמצעות Maximum a Posteriori Adaptation. בניסויים נבחרו 512 רכיבים גאוסיים, ופרמטרי ההתפלגות משמשים בסיס לייצוג המועבר למסווג. בשלב הסיווג מופעלת רשת Convolutional Neural Network (CNN) קלה יחסית, שמטרתה ללמוד קשרים בין המאפיינים הסטטיסטיים ולזהות סימנים לזיוף. בנוסף מתוארת מסגרת קבלת החלטות הכוללת ארבע קטגוריות: אימות מוצלח, אימות שנכשל, סימנים חזקים לזיוף וסימנים מתונים לזיוף. עם זאת, עיקר ההערכה הכמותית המדווחת עוסק בסיווג דיבור אמיתי לעומת דיבור מזויף, ולא בביצועים נפרדים של ארבע הקטגוריות.

החוקרים העריכו את השיטה על ASVspoof 2019 Logical Access והשוו אותה לשתי גישות קלאסיות, LFCC עם GMM ו-CQCC עם GMM. המערכת המשולבת, MFCC+PLP+GMM+CNN, השיגה Accuracy של 97.8% ו-Equal Error Rate (EER) של 4.79%, לעומת Accuracy של 94.5% ו-EER של 7.44% עבור LFCC+GMM, ו-Accuracy של 95.3% ו-EER של 6.27% עבור CQCC+GMM. בנוסף, דווחו עבור הגישה המוצעת False Acceptance Rate של 4.61%, False Rejection Rate של 4.94% ו-minDCF של 0.623. תוצאות אלה מצביעות על יתרון של המערכת ההיברידית ביחס לשתי שיטות הייחוס שנבדקו, אך אינן מאפשרות לקבוע את תרומתו הנפרדת של כל רכיב במערכת.

במסגרת הערכה נוספת השתמשו החוקרים בנתונים ממאגר TED-LIUM, שכללו 50 דוברים ודוגמאות מזויפות שנוצרו באמצעות WaveNet ו-AutoVC. בניסוי זה דווח על Accuracy של כ-97% ועל EER של כ-5.1%. תוצאות אלו מספקות אינדיקציה מסוימת ליכולת המערכת להתמודד עם מקור הקלטות נוסף, אך ההערכה הוגבלה למספר מצומצם של סוגי זיוף, והמאמר אינו מציג פירוט מספק של הביצועים לפי סוג מתקפה או תנאי הקלטה.

למחקר מספר מגבלות מתודולוגיות. ראשית, לא מוצגים ניסויי Ablation המאפשרים לבודד את התרומה של MFCC, PLP, GMM–UBM וה-CNN, ולכן לא ניתן להסיק האם השיפור נובע משילוב המאפיינים, מהמסווג העמוק או מהשפעתם המשותפת. שנית, פרטי המימוש של הרשת, ממדי הייצוג הסטטיסטי ותהליך החיבור בין הרכיבים אינם מפורטים במידה המאפשרת שחזור מלא. בנוסף, למרות שהחוקרים מציגים את השיטה כמתאימה למערכות ביומטריות מעשיות, לא בוצעה הערכה ישירה ומפורטת של זמן חיזוי, שימוש בזיכרון או עלות חישובית על חומרת יעד. ההערכה התמקדה בעיקר בנתוני דיבור באנגלית, ולא כללה בדיקה שיטתית של מתקפות המבוססות על Neural Audio Codecs או של עמידות בתנאי תקשורת משתנים.

עבור המחקר הנוכחי, תרומתו העיקרית של המאמר היא בהצגת גישת Feature Fusion המשלבת מאפיינים אקוסטיים משלימים עם מידול סטטיסטי ומסווג נלמד. ממצאיו מספקים הצדקה לבחינת Baselines המבוססים על MFCC ו-CQCC, ולהרחבה אפשרית באמצעות PLP או רכיב סטטיסטי נוסף. עם זאת, בהינתן מאגר נתונים מוגבל הכולל הקלטות מ-ASVspoof 5, מ-CodecFake ומ-M-AILABS, יש לבחון האם תוספת המאפיינים משפרת את ה-EER ואת יכולת ההכללה בין מקורות הנתונים, או שמא היא מגדילה את הסיכון להתאמת יתר. לפיכך, מומלץ להתחיל בהשוואה מבוקרת של מאפיינים ומסווגים פשוטים, ורק לאחר מכן לבחון את תרומתה של ארכיטקטורה היברידית מורכבת יותר. תכנון זה יאפשר להעריך לא רק את השיפור בביצועים אלא גם את יציבותו ואת העלות החישובית הכרוכה בו.

מקור ביבליוגרפי:

Izrailov, K. E., Kotenko, I. V., & Chechulin, A. A. (2026). *Intelligent Voice Fraud Detection Methods in Authentication Systems*. Pattern Recognition and Image Analysis, 36(2), 391–399. https://doi.org/10.1134/S1054661826700203