זיהוי זיופים קוליים לא מוכרים באמצעות One-Class Learning ו-wav2vec 2.0

Yin and Lei (2026) במאמרם *A Novel Attack-Resistant Speech Forgery Detection Method Integrating One-Class Learning and Wav2vec2*, מציגים גישה לזיהוי זיופים קוליים המשלבת למידה חד-מחלקתית (One-Class Learning) עם ייצוגי דיבור המופקים ממודל Self-Supervised Learning מאומן מראש. המחקר מתמודד עם מגבלה מרכזית של מערכות Anti-Spoofing מפוקחות: תלות בדוגמאות זיוף מתויגות, שעלולה לפגוע ביכולת ההכללה למתקפות המבוססות על טכנולוגיות סינתזה והמרת קול שלא נכללו באימון. החוקרים מציעים להתמודד עם בעיה זו באמצעות מידול ההתפלגות של דיבור אותנטי וזיהוי הקלטות החורגות ממנה, במקום להסתמך על למידת מאפיינים ייחודיים של מתקפות מוכרות.

השיטה מבוססת על Deep Support Vector Data Description (Deep SVDD), אלגוריתם One-Class הממפה דוגמאות דיבור אמיתיות למרחב מאפיינים נלמד ומגדיר סביבן גבול החלטה בצורת Hypersphere. במהלך האימון המודל שואף ליצור ייצוג קומפקטי של דיבור אמיתי, בעוד שבשלב ההערכה המרחק של הקלטה חדשה ממרכז הכדור משמש לזיהוי חריגות. הקלטות שמיקומן מחוץ לגבול ההחלטה מסווגות כמזויפות. יתרונה העקרוני של גישה זו הוא שהאימון החד-מחלקתי אינו מחייב היכרות מוקדמת עם כל סוגי הזיופים האפשריים, ולכן עשוי להתאים במיוחד לזיהוי מתקפות לא מוכרות.

לצורך חילוץ המאפיינים החוקרים משלבים שני מקורות מידע: מאפיינים אקוסטיים קלאסיים מסוג Linear Frequency Cepstral Coefficients (LFCC), וייצוגי דיבור עמוקים המופקים באמצעות wav2vec 2.0 Base. הייצוגים שמפיק wav2vec 2.0 נלמדו באימון עצמי על נתוני דיבור לא מתויגים, ולכן עשויים לספק תיאור עשיר של מאפיינים ספקטרליים, זמניים והקשריים שאינו תלוי ישירות בדוגמאות זיוף. בתצורה המתוארת, שכבות ה-Transformer של wav2vec 2.0 נשארות קפואות, ומבוצעת התאמה של שכבת פלט. במקביל, מאפייני LFCC כוללים 64 מקדמים בסיסיים לצד נגזרות מסדר ראשון ושני, ובסך הכול ייצוג של 192 רכיבים. רשתות המשנה משתמשות ברכיבי Bi-LSTM וב-LCNN ומפיקות ייצוגים בממד 256 לצורך Deep SVDD.

בנוסף, החוקרים מציעים אסטרטגיית Multi-Model Weighted Fusion המשלבת את ציוני ארבע רשתות המשנה. משקלי השילוב נקבעים באמצעות Optuna, תוך מזעור מדד Equal Error Rate (EER) על קבוצת Validation. השילוב נועד לנצל מאפיינים משלימים ולהפחית את התלות בייצוג יחיד או בארכיטקטורת משנה אחת. עם זאת, השימוש ב-EER לצורך בחירת משקלי השילוב מעלה מגבלה מתודולוגית: אף שאימון Deep SVDD מתואר כמבוסס על דיבור אמיתי בלבד, חישוב EER מחייב קבוצת אימות הכוללת גם דוגמאות מזויפות. לכן הטענה שהמערכת המלאה אינה דורשת דוגמאות זיוף מתויגות אינה מבוססת במלואה על תיאור הפרוטוקול.

החוקרים העריכו את השיטה באמצעות ASVspoof 2019 Logical Access, המוצג כתרחיש של מתקפות מוכרות, ו-ASVspoof 2021 Deepfake, המוצג כתרחיש של מתקפות לא מוכרות. בניסוי הראשון השיטה המוצעת השיגה EER של 2.13%, לעומת 2.35% עבור wav2vec 2.0 עם מסווג בינארי מפוקח, 5.42% עבור Deep SVDD ללא wav2vec 2.0, ו-8.76% עבור LFCC עם One-Class SVM. בניסוי השני, על ASVspoof 2021 DF, השיטה השיגה EER של 6.89%, לעומת 18.45%, 15.67% ו-22.31%, בהתאמה. ממצאים אלה מצביעים על יתרון משמעותי של השיטה המשולבת בהערכת המתקפות הלא מוכרות במסגרת הניסויים המדווחים, במיוחד בהשוואה למסווג הבינארי המבוסס על wav2vec 2.0.

עם זאת, יש לפרש את הממצאים בזהירות. ההשוואה בין ASVspoof 2019 LA לבין ASVspoof 2021 DF כוללת גם שינויים במקור הנתונים, בסוגי ההתקפות ובתנאי ההערכה, ולכן אינה מבודדת באופן מלא את תרומתו של חידוש סוג ההתקפה. בנוסף, השיטה משלבת מספר רכיבים, לרבות wav2vec 2.0, Deep SVDD ו-Weighted Fusion, כך שלא ניתן לייחס את מלוא השיפור ל-One-Class Learning בלבד. ניסויי ה-Ablation מתוארים כמדגימים את תרומת הרכיבים השונים ואת השיפור האפשרי באמצעות Data Augmentation, אך קיימות אי-התאמות בין שמות התצורות וערכי ה-EER בטבלה לבין ההסברים בטקסט. לפיכך, לא ניתן להסתמך על כל הערכים לצורך כימות מדויק של התרומה העצמאית של כל רכיב.

מגבלה נוספת נובעת מעצם אופייה של למידה חד-מחלקתית. דוגמת דיבור אמיתית שהוקלטה בתנאים שונים מאלה שנכללו באימון עשויה להימצא מחוץ לאזור ההתפלגות שנלמד ולסווג בטעות כמזויפת. לכן זיהוי חריגה אינו שקול בהכרח לזיהוי זיוף. בעיה זו משמעותית במיוחד בהערכה בין מקורות נתונים שונים, שבה הבדלי דוברים, שפה, מיקרופון ותנאי הקלטה עלולים להשפיע על מרחקי הייצוגים. נוסף על כך, המאמר אינו מספק תיאור מפורט דיו של כל שלבי יצירת קבוצות האימות והבחירה הסופית של המודל, ואינו מציג הערכה ישירה על ASVspoof 5 או CodecFake.

עבור המחקר הנוכחי, תרומתו המרכזית של המאמר היא בהצגת One-Class Learning כחלופה לסיווג בינארי מבוסס זיופים מתויגים. בהינתן מאגר הקורס הכולל הקלטות אמיתיות ומזויפות מ-ASVspoof 5 ומ-CodecFake, לצד דוגמאות דיבור אמיתיות מ-M-AILABS, ניתן לבחון שימוש בייצוגי wav2vec 2.0 או WavLM מאומנים מראש לצורך מידול דיבור אמיתי. ניסוי מתאים ישווה, תחת פרוטוקול הערכה משותף, בין מסווג בינארי המשתמש בשתי המחלקות לבין גישת One-Class המבוססת על הקלטות אמיתיות בלבד בשלב אימון מסווג החריגות. ההערכה תתבסס על EER ועל ניתוח טעויות לפי מקור נתונים, תוך בחינת הסיכון לדחייה שגויה של דיבור אותנטי המגיע ממקור שלא נכלל באימון. מומלץ להתחיל בגישה פשוטה, כגון One-Class SVM על ייצוגי wav2vec 2.0 קפואים, ורק לאחר מכן לשקול מימוש Deep SVDD ושילוב מספר רשתות משנה, בהתאם לתוצאות ולמשאבים הזמינים.

מקור ביבליוגרפי:

Yin, J., & Lei, S. (2026). *A Novel Attack-Resistant Speech Forgery Detection Method Integrating One-Class Learning and Wav2vec2*. In 2026 International Conference on Communication Networks and Machine Learning (CNML) (pp. 415–419). IEEE. https://doi.org/10.1109/CNML68938.2026.11452384