Academic Summary 10 — AT-ADD

AT-ADD: A Benchmark and Challenge for Robust and All-Type Audio Deepfake Detection

Xie et al., ACM Multimedia 2026 Grand Challenge

המאמר *AT-ADD: A Benchmark and Challenge for Robust and All-Type Audio Deepfake Detection* של Xie ועמיתיו (2026) עוסק במגבלות ההכללה והעמידות של מערכות לזיהוי זיופים קוליים בתנאים מציאותיים. החוקרים מצביעים על כך שמודלים המשיגים ביצועים גבוהים במאגרי הערכה מבוקרים עלולים להתקשות בזיהוי דיבור סינתטי כאשר הם נחשפים למערכות יצירה חדשות, למכשירי הקלטה שונים ולעיבודי אות כגון דחיסה, רעש והקלטה מחדש. לצורך בחינת אתגרים אלה מוצג AT-ADD, Benchmark הכולל שני מסלולים: זיהוי זיופים בדיבור תחת שינויי התפלגות (Track 1), וזיהוי זיופים במגוון סוגי אודיו, לרבות דיבור, צלילי סביבה, שירה ומוזיקה (Track 2). המסלול הראשון רלוונטי במיוחד למחקר הנוכחי, המתמקד בזיהוי דיבור אמיתי לעומת דיבור סינתטי.

מאגר Track 1 כולל 245,655 הקלטות, 11,299 דוברים מזוהים, 96 שפות בסיס ו-47 תנאי יצירת דיבור סינתטי. מבנה ההערכה מבוסס על הפרדה בין 20 מערכות יצירה המופיעות בקבוצות האימון והפיתוח לבין 27 תנאי זיוף המופיעים בקבוצת ההערכה, ובהם גם דיבור סינתטי שעבר Replay. נוסף על כך, נתוני ההערכה כוללים מקורות הקלטה וסביבות אקוסטיות מגוונות, לצד שינויים בעוצמת האות, במהירות ובקצב הדגימה. פרוטוקול זה נועד לבחון יכולת הכללה למערכות סינתזה שלא נראו באימון ועמידות לתנאים שאינם תואמים במלואם את התפלגות נתוני הפיתוח. עם זאת, שילוב מספר גורמי שינוי מקשה על בידוד תרומתו של כל גורם לירידה בביצועים.

החוקרים ערכו את התחרות במסגרת Closed Setting, שבה המשתתפים הורשו להשתמש בנתוני האימון והפיתוח שסיפקו המארגנים, לצד מודלים כלליים מאומנים מראש ואמצעי הרחבת נתונים מותרים. המדד הרשמי של Track 1 הוא Macro-F1, המחושב כממוצע ציוני F1 של המחלקות Real ו-Fake במטרה לתת משקל שווה לשתיהן. במסגרת המחקר הוערכו מודלי Baseline המבוססים על ייצוגים ספקטרליים, AASIST, ייצוגי Self-Supervised Learning ומודלי Audio LLM. מבין ה-Baselines, מערכת FT-XLSR-AASIST השיגה את התוצאה הגבוהה ביותר בקבוצת ההערכה, Macro-F1 76.73%, לעומת 60.39% של AASIST. עם זאת, גם מודל ה-SSL המוביל הציג ירידה משמעותית ביחס לביצועיו בקבוצת הפיתוח, עובדה הממחישה את מגבלות ההכללה בתנאי שינוי התפלגות.

המערכת הזוכה, WaveShield, השיגה Macro-F1 90.71% באמצעות שילוב של ייצוגי W2V-BERT 2.0, רכיבי AASIST ו-Adapters, אסטרטגיות אימון הדרגתיות, Augmentation מגוון ומיזוג ציוני מספר תתי-מערכות. מערכות מובילות נוספות השתמשו בשילובי XLSR, CQCC, התאמות לתנאי ערוץ, ניתוח מקטעי אודיו וכיול ספי החלטה. תוצאות אלה מצביעות על חשיבותה של המערכת הכוללת — לרבות ייצוג האודיו, מדיניות האימון ואסטרטגיית ההסקה — ולא רק על בחירת ארכיטקטורת הבסיס. עם זאת, בהיעדר ניסויי Ablation אחידים, לא ניתן לבודד את תרומתו העצמאית של כל רכיב לפערי הביצועים בין המערכות.

תרומה מרכזית נוספת של המאמר היא ניתוח שגיאות ברמת מערכת היצירה ומקור הדיבור. החוקרים מצאו כי BigVGAN ותנאי Replay היו בין המצבים הקשים ביותר לזיהוי, אף שמרבית המערכות השיגו ביצועים גבוהים על תנאי זיוף אחרים. במקביל, חלק מהמודלים סיווגו בטעות שיעור גבוה של הקלטות אמיתיות ממקורות מסוימים, ובפרט 3D-Speaker. ממצאים אלה מדגישים כי ציון הערכה כולל עלול להסתיר חולשות מהותיות, הן בזיהוי דיבור מזויף והן בשימור זיהוי תקין של דיבור אמיתי. בנוסף, ניתוח החפיפה בין שגיאות המודלים הראה כי דפוסי הכשל שלהם שונים בחלקם, אך שילוב פשוט באמצעות הצבעת רוב לא שיפר את ביצועי המערכת המובילה ב-Track 1. בדיקת Bootstrap הדגימה גם את החשיבות של הערכת אי-ודאות, כאשר פערים קטנים בין מערכות סמוכות בדירוג לא היו יציבים באותה מידה כמו יתרון המערכת הזוכה.

למחקר מספר מגבלות מתודולוגיות. ראשית, שינויים במערכות היצירה, במקורות הדיבור ובתנאי ההקלטה עשויים להתרחש במקביל, ולכן קשה להסיק באופן סיבתי מהו הגורם המרכזי לפגיעה בביצועים. שנית, החוקרים מדווחים על חפיפה של 18 זהויות דוברים מתוך Common Voice בין תתי-הקבוצות שנבחרו, כך שלא ניתן לטעון להפרדה מלאה ברמת הדובר. שלישית, ניתוח המערכות הזוכות מתבסס על החלטות סיווג בינאריות, ולא על ציונים רציפים, ולכן אינו מאפשר חישוב EER או ניתוח ROC מתוך ההגשות. כמו כן, גישה מעשית למאגר Track 1 לא אומתה עבור המחקר הנוכחי, ולכן אין להניח שניתן לשלבו ישירות בתהליכי האימון או ההערכה.

בהקשר לפרויקט הנוכחי, AT-ADD מספק בעיקר מסגרת מתודולוגית לתכנון ולהערכת גלאי זיופים קוליים, ולא מקור נתונים פעיל להרחבת האימון. המאמר מחזק את הצורך בהפרדה מבוקרת בין נתוני אימון, פיתוח והערכה, בבחינת הכללה למערכות סינתזה חדשות ובניתוח ביצועים לפי מקור נתונים וסוג מתקפה. בנוסף, הוא מדגיש את חשיבותם של מדדים משלימים ל-EER, של הערכת אי-ודאות ושל ניסויים מבוקרים לבדיקת תרומתן של שיטות Augmentation ו-Fine-Tuning.

המסקנה המחקרית המרכזית היא שביצועים גבוהים על נתוני פיתוח אינם מעידים בהכרח על הכללה מוצלחת בתנאי עולם אמיתי. הערכה מהימנה של גלאי זיופים קוליים מחייבת בחינה של שינויי התפלגות, ניתוח שגיאות לפי תנאים ומקורות, והפרדה מתודולוגית בין בחירת המודל לבין הערכתו הסופית.

Reference

Xie, Y., et al. (2026). *AT-ADD: A Benchmark and Challenge for Robust and All-Type Audio Deepfake Detection*. arXiv:2608.23437v2. https://arxiv.org/abs/2608.23437