Dataset Academic Summary 01 — MLAAD

MLAAD: The Multi-Language Audio Anti-Spoofing Dataset

Müller et al., IJCNN 2024; arXiv v11, 2026

המאמר *MLAAD: The Multi-Language Audio Anti-Spoofing Dataset* של Müller ועמיתיו מציג מאגר נתונים רב-לשוני של דיבור סינתטי, שנועד לתמוך בפיתוח ובהערכה של מערכות לזיהוי זיופים קוליים. המחקר מתמקד בבעיית ההכללה של גלאי זיופים למקורות נתונים ולמערכות סינתזה שלא נכללו באימון, תוך הדגשת ההטיה הלשונית המאפיינת מאגרי Anti-Spoofing רבים, המתמקדים בעיקר באנגלית ובסינית.

בניגוד למחקרים המציעים ארכיטקטורות זיהוי חדשות, התרומה המרכזית של MLAAD היא בתחום בניית נתוני האימון. החוקרים מבקשים לבחון האם שימוש במאגר המכיל מגוון רחב של שפות ומערכות Text-to-Speech עשוי להוביל ללמידת מאפייני זיוף בעלי יכולת הכללה רחבה יותר.

המאגר מבוסס על M-AILABS Speech Dataset, הכולל הקלטות דיבור אנושי. החוקרים השתמשו בטקסטים של הקלטות המקור, ולעיתים בתרגומם לשפות נוספות, כדי להפיק הקלטות סינתטיות באמצעות מערכות TTS מגוונות. במודלים התומכים בכך נעשה שימוש גם בהקלטות ייחוס קוליות. לצד קובצי האודיו נשמר Metadata המתאר, בין היתר, את שפת ההקלטה, מודל ה-TTS, הארכיטקטורה, הטקסט, הקלטת המקור ולעיתים גם את דובר הייחוס. מידע זה מאפשר לנתח את מקור הדוגמאות ואת הקשרים האפשריים ביניהן.

MLAAD התרחב במספר גרסאות מאז פרסומו המקורי. גרסה 11, המתוארת בגרסת המאמר שנקראה, כוללת 1,153.6 שעות של דיבור סינתטי ב-54 שפות, שהופק באמצעות 205 מודלי TTS המשתייכים ל-127 ארכיטקטורות. עם זאת, חשוב להבחין בין התפתחות המאגר לבין היקף הניסויים המדווחים: הערכת ה-Cross-Dataset המרכזית נערכה באמצעות MLAAD v1 בלבד, הכוללת 63 שעות, 21 מודלי TTS ו-22 שפות. המחברים מציינים שהניסויים לא הורצו מחדש עבור הגרסאות המאוחרות, ולכן אין לראות בהרחבת המאגר הוכחה אמפירית לשיפור נוסף ביכולת ההכללה.

לצורך הערכת MLAAD, החוקרים אימנו שלוש מערכות לזיהוי זיופים קוליים — RawGAT-ST, SSL-W2V2 ו-WhisperDF — על מספר מאגרי אימון שונים, ובהם MLAAD v1, ASVspoof 2019, FakeOrReal ו-InTheWild. בהמשך נבדקו המודלים על מאגרי הערכה נוספים בתנאי Cross-Dataset. האימון כלל איזון מחלקות באמצעות Random Undersampling והרחבת נתונים באמצעות רעש, מוזיקה וקידוד אודיו. המדד ששימש את החוקרים היה Accuracy, בין היתר משום שחלק מקבוצות ההערכה הכילו דוגמאות מזויפות בלבד ולכן לא אפשרו חישוב EER.

התוצאות מדגימות כי בחירת מאגר האימון משפיעה באופן משמעותי על יכולת ההכללה של הגלאים. בפרט, MLAAD ו-ASVspoof 2019 הציגו יתרונות משלימים: כל אחד ממקורות האימון הוביל בחלק אחר מתרחישי ההערכה. לדוגמה, עבור WhisperDF על WaveFake, מודל שאומן על MLAAD v1 השיג Accuracy ממוצע של 97.2% לעומת 2.2% בלבד עבור מודל שאומן על ASVspoof 2019. מנגד, במאגר ASVspoof 2021 DF התקבלה תוצאה טובה יותר עבור SSL-W2V2 שאומן על ASVspoof 2019 מאשר עבור אותו סוג מודל שאומן על MLAAD v1.

ממצאים אלה תומכים במסקנה כי מקורות אימון שונים עשויים להקנות יתרונות שונים בתנאי הערכה משתנים. עם זאת, אין בהם הוכחה שאימון משולב על שני מאגרים יהיה בהכרח עדיף על אימון נפרד, או שמגוון השפות הוא הגורם הישיר לשיפור. מספר השפות, כמות הנתונים, מגוון מערכות ה-TTS ומאפייני ההקלטות המקוריות משתנים יחד, ולכן תרומתם היחסית אינה מבודדת באופן מלא. בנוסף, חלק מהתוצאות מתאפיינות בשונות גבוהה בין הרצות, ומדד Accuracy על מאגר חד-מחלקתי אינו מאפשר להסיק על יכולת ההבחנה הכוללת בין דיבור אמיתי למזויף.

למחקר הנוכחי, העוסק בזיהוי זיופים קוליים ובהכללה למתקפות לא מוכרות, MLAAD רלוונטי במיוחד כמועמד להרחבת נתוני האימון. המאגר עשוי להוסיף מגוון של מערכות סינתזה מעבר למערכות המיוצגות ב-ASVspoof 5 וב-CodecFake. לצד זאת, השימוש בו מחייב בדיקה קפדנית של סיכוני Data Leakage ו-Shortcut Learning, משום ש-MLAAD מבוסס על M-AILABS, שממנו מגיעות גם חלק מההקלטות האמיתיות בנתוני הקורס. חפיפות אפשריות בהקלטות מקור, בדוברים, בטקסטים או במאפייני ההקלטה עלולות להוביל להערכה אופטימית שאינה משקפת יכולת הכללה אמיתית.

בהתאם לכך, מוצע לבחון תחילה תת-קבוצה מבוקרת של MLAAD, תוך בדיקת Metadata, רישוי, קשרי מקור והיתכנות של חלוקות המפרידות דוברים והקלטות קשורות. בהמשך ניתן יהיה להשוות בין מודל שאומן על נתוני הקורס בלבד לבין אותו מודל לאחר הרחבת האימון באמצעות MLAAD, וכן לבחון את תרומתו ביחס ל-PhonemeDF ולשילוב בין שני המאגרים. כדי להבחין בין השפעת כמות הנתונים לבין השפעת מגוון מערכות הזיוף, יידרשו גם ניסויים מבוקרים שבהם תקציב הדוגמאות נשמר דומה.

המסקנה המחקרית המרכזית היא שהרכב נתוני האימון מהווה גורם משמעותי בפוטנציאל ההכללה של מערכות לזיהוי זיופים קוליים, אך השפעתם של מגוון השפות, מערכות היצירה ומקורות ההקלטות מחייבת הערכה מבוקרת ולא ניתן להסיקה מתוך ביצועי סיווג כוללים בלבד.

Reference

Müller, N. M., Kawa, P., Choong, W. H., Casanova, E., Gölge, E., Müller, T., Syga, P., Sperl, P., & Böttinger, K. (2024). *MLAAD: The Multi-Language Audio Anti-Spoofing Dataset*. International Joint Conference on Neural Networks (IJCNN). https://arxiv.org/abs/2401.09512

הערת מקור: הסיכום מתייחס לגרסת arXiv v11 מאוגוסט 2026. תוצאות ההכללה המדווחות מבוססות על MLAAD v1. ההמלצות לשימוש בנתונים חיצוניים במסגרת פרויקט הקורס הן מסקנות תכנוניות שלנו ולא חלק מהניסויים המקוריים.