Dataset Academic Summary 02 — PhonemeDF

PhonemeDF: A Synthetic Speech Dataset for Audio Deepfake Detection and Naturalness Evaluation

Nallaguntla et al., LREC 2026

המאמר *PhonemeDF: A Synthetic Speech Dataset for Audio Deepfake Detection and Naturalness Evaluation* של Nallaguntla ועמיתיו (2026) מציג מאגר נתונים חדש לחקר ההבדלים האקוסטיים בין דיבור אמיתי לדיבור סינתטי ברמת הפונמה. המחקר מתמקד במגבלה של גישות רבות לזיהוי זיופים קוליים, המתבססות על סיווג הקלטות שלמות מבלי לבחון בהכרח באילו יחידות פונטיות מופיעים סימני הזיוף. החוקרים מבקשים לבדוק האם מערכות סינתזה מתקשות בהפקת פונמות מסוימות, והאם ניתן לנצל הבדלים אלה לצורך זיהוי דיבור מזויף.

לשם כך נבנה מאגר PhonemeDF, המבוסס על 28,539 הקלטות אמיתיות מתוך LibriSpeech, לצד 199,773 הקלטות סינתטיות שנוצרו באמצעות ארבע מערכות Text-to-Speech (TTS) ושלוש מערכות Voice Conversion (VC). המאגר כולל כ-730 שעות של דיבור סינתטי וכ-100 שעות של דיבור אמיתי. ייחודו טמון במבנה המקבילי של הנתונים, שבו לכל הקלטת מקור קיימות גרסאות סינתטיות בעלות תוכן לשוני תואם. נוסף על כך, החוקרים השתמשו ב-Montreal Forced Aligner (MFA) להפקת קובצי TextGrid המתעדים את הגבולות הזמניים של הפונמות, ובכך מאפשרים ניתוח אקוסטי ממוקד של יחידות דיבור תואמות.

לצורך ההערכה האמפירית נבחרה תת-קבוצה של 1,000 הקלטות מקור והגרסאות הסינתטיות המתאימות להן. החוקרים חילצו מאפיינים ספקטרליים מסוג LFCC ו-Log-Mel Spectrogram, לצד ייצוגי Self-Supervised Learning המבוססים על wav2vec 2.0 ו-WavLM. באמצעות Kullback–Leibler Divergence (KLD) סימטרי נמדדו ההבדלים בין התפלגויות פונמות אמיתיות וסינתטיות, בעוד שמסווגי Logistic Regression ו-Support Vector Machine שימשו להערכת יכולת ההבחנה ביניהן. נוסף על כך, חושב מתאם Pearson כדי לבחון את הקשר בין גודל ההבדל הסטטיסטי לבין דיוק הסיווג.

תוצאות המחקר מצביעות על שונות משמעותית בין פונמות, מערכות יצירה וסוגי ייצוג. בפרט, דיפתונגים כגון OY ו-EY, עיצורים חוככים כגון SH ו-ZH, ועיצורים סותמים מסוימים הציגו מאפיינים מבחינים בין דיבור אמיתי לסינתטי. בנוסף, נמצאו הבדלים בין מערכות TTS ו-VC, כאשר חלק ממערכות ה-VC הציגו סטיות ספקטרליות גדולות יחסית לדיבור אמיתי. עם זאת, הקשר בין KLD לבין Accuracy לא היה אחיד: בייצוגים ספקטרליים מסורתיים נמצאו מתאמים חיוביים משמעותיים במקרים רבים, בעוד שבייצוגי SSL התקבלו גם מתאמים חלשים ואף שליליים. ממצא זה מדגיש כי הבדל סטטיסטי גדול בין התפלגויות אינו מבטיח בהכרח יכולת סיווג גבוהה, וכי תרומתם של מאפיינים פונטיים תלויה בייצוג ובמסווג שנבחרו.

למחקר מספר מגבלות מרכזיות. המאגר מבוסס על דיבור באנגלית מתוך LibriSpeech ועל שבע מערכות יצירה בלבד, ולכן יכולת ההכללה של הממצאים לשפות, לדוברים ולתנאי הקלטה אחרים אינה מובטחת. נוסף על כך, גבולות הפונמות נקבעו באמצעות Forced Alignment אוטומטי, העלול להכיל שגיאות. ההערכה מתמקדת בעיקר ב-KLD, במתאמים וב-Accuracy ברמת הפונמה, ואינה מספקת הוכחה ישירה לשיפור EER ברמת ההקלטה או ליכולת הכללה למערכות סינתזה שלא נכללו באימון. כמו כן, תיאור הניסויים אינו מאפשר לאמת באופן מלא את ההפרדה בין דוברים והקלטות מקור בכל ניסויי הסיווג.

בהקשר לפרויקט הנוכחי, PhonemeDF מהווה מועמד משמעותי להרחבת נתוני האימון באמצעות דוגמאות ממערכות TTS ו-VC שונות, ובכך מאפשר לבחון את תרומתו של מגוון שיטות היצירה לזיהוי זיופים קוליים. בנוסף, המידע ברמת הפונמה עשוי לשמש בסיס לניתוח שגיאות ולזיהוי מאפיינים אקוסטיים שמודלי הזיהוי מתקשים להתמודד עמם. עם זאת, שימוש במאגר מחייב שמירה על קשרי המקור בין ההקלטות האמיתיות והסינתטיות, בדיקת חפיפות והפרדת דוברים, כדי למנוע דליפת מידע והטיות הנובעות ממקור הנתונים. התאמתו הסופית לאימון מותנית גם באימות תנאי הרישוי וה-Metadata הזמין.

המסקנה המחקרית המרכזית היא שארטיפקטים של דיבור סינתטי אינם מופיעים באופן אחיד לאורך ההקלטה, וניתוח ברמת הפונמה עשוי לספק מידע משלים לגישות זיהוי המבוססות על ייצוגים גלובליים. עם זאת, תרומתם של מאפיינים פונטיים ושל הרחבת נתוני האימון לשיפור ההכללה מחייבת הערכה אמפירית מבוקרת ואינה ניתנת להסקה מתוך KLD או Accuracy ברמת הפונמה בלבד.

Reference

Nallaguntla, V., Fursule, A., Kshirsagar, S., & Avila, A. R. (2026). *PhonemeDF: A Synthetic Speech Dataset for Audio Deepfake Detection and Naturalness Evaluation*. Proceedings of the Fifteenth Language Resources and Evaluation Conference (LREC 2026), 5905–5915.

/https://aclanthology.org/2026.lrec-1.469