סקירת ספרות אינטגרטיבית: זיהוי זיופים קוליים והכללה למתקפות לא מוכרות

פרויקט: Fake or Real: Voice Deepfake Detection
חוקרים: Shlomi Hazan & Mayan Adler
מסגרת: Advanced Topics in Machine Learning, HIT
היקף הסקירה: 12 מאמרים מחקריים שנקראו ונותחו במסגרת הפרויקט, 2017–2026
מעמד המסמך: מהדורה מתוקנת לאחר ביקורת מחקרית — Document A | 7 בנובמבר 2026

תקציר

התפתחותן של טכנולוגיות סינתזת דיבור (Text-to-Speech), המרת קול (Voice Conversion) וקודקים נוירוניים (Neural Audio Codecs) מאפשרת לייצר הקלטות קול סינתטיות באיכות גבוהה, המאתגרות מערכות אימות קולי ומנגנוני זיהוי זיופים. אף שמודלים מתקדמים לזיהוי זיופים קוליים מציגים ביצועים גבוהים על מאגרי הערכה מוכרים, הספרות המחקרית מצביעה על קושי מתמשך בהכללה לשיטות זיוף חדשות, לדוברים שלא נראו באימון ולתנאי הקלטה שונים. קושי זה מעלה שאלה מרכזית: באיזו מידה המודל מזהה סימנים הקשורים ליצירת דיבור סינתטי, ובאיזו מידה ביצועיו תלויים במקור הנתונים ובתנאים שנצפו במהלך האימון? דפוסי שגיאה יכולים להעיד על תלות אפשרית במקור, אך אינם חושפים כשלעצמם את מנגנון ההחלטה של המודל.

סקירה זו מנתחת באופן אינטגרטיבי שנים-עשר מחקרי ליבה העוסקים בזיהוי זיופים קוליים, בייצוג דיבור ובהכללה בין מתקפות ומאגרי נתונים. המחקרים נבחנים לפי חמישה כיוונים מרכזיים: מאפיינים אקוסטיים מחושבים מראש, ארכיטקטורות עמוקות לזיהוי ארטיפקטים, ייצוגי דיבור המבוססים על Self-Supervised Learning, שיפור ייצוגים באמצעות שחזור מונחה ולמידה חד-מחלקתית (One-Class Learning). נוסף על כך נבחנים ASVspoof 5 ו-CodecFake כמסגרות הערכה, MLAAD ו-PhonemeDF כמקורות חיצוניים מועמדים להרחבת נתונים, ו-AT-ADD כמחקר על עמידות והכללה.

מן הספרות עולה כי בחירת הייצוג, ארכיטקטורת הסיווג ופרדיגמת הלמידה משפיעות על ביצועי הזיהוי, אך לא ניתן להניח ששיפור על מאגר מסוים יישמר גם במעבר למקור נתונים או לשיטת זיוף אחרת. במיוחד, שילוב מאפיינים, שימוש במודלים מאומנים מראש ולמידת התפלגות הדיבור האמיתי מציעים כיוונים מבטיחים, אך כל אחד מהם מלווה במגבלות מתודולוגיות ובסיכוני התאמת יתר או למידת קיצורי דרך.

בהתבסס על ממצאים אלו, הסקירה מציעה לבחון את השפעת ייצוג הדיבור, פרדיגמת הלמידה והרכב נתוני האימון על יכולת ההכללה לזיופים שלא נראו באימון, באמצעות השוואה מבוקרת של מודלים קלאסיים, ייצוגי SSL ומסווגים חד-מחלקתיים. נוסף על כך מוצעת מסגרת מחקרית המבחינה בין הגדלת

מספר דוגמאות האימון לבין הרחבת מגוון מערכות הזיוף, ובין ניסויי Leave-One-System-Out לבין Cross-Dataset Evaluation. ההערכה צריכה להבחין בין הכללה למתקפות חדשות לבין רגישות להבדלי מקור, דובר ותנאי הקלטה, תוך שימוש בפרוטוקול חלוקת נתונים עקבי ובמדדי זיהוי מתאימים.

מילות מפתח: Audio Deepfake Detection, Speech Anti-Spoofing, Unseen Attacks, Cross-Dataset Generalization, Speaker Generalization, Channel Robustness, MLAAD, PhonemeDF, AT-ADD, ASVspoof 5, CodecFake, CQCC, AASIST, wav2vec 2.0, WavLM, One-Class Learning, Deep SVDD, EER.

1. מבוא: בעיית זיהוי הזיופים הקוליים

מערכות זיהוי ואימות קול משמשות במגוון יישומים, ובהם אימות זהות מרחוק, מערכות בנקאיות, ממשקי משתמש קוליים ואמצעי אבטחה ביומטריים. במקביל להתקדמותן של מערכות אלו, השתפרה משמעותית יכולתן של טכנולוגיות לייצר דיבור סינתטי הדומה לדיבור אנושי. טכנולוגיות Text-to-Speech (TTS) מאפשרות יצירת דיבור מטקסט, בעוד שטכנולוגיות Voice Conversion (VC) מאפשרות לשנות מאפיינים של קול קיים תוך שימור חלק מתוכנו. התפתחויות נוספות בתחום Neural Audio Codecs מאפשרות לקודד ולשחזר אותות דיבור באמצעות ייצוגים שנלמדו ברשתות נוירונים, ולעיתים גם משמשות רכיב במערכות יצירה סינתטיות. עם זאת, עיבוד של אות באמצעות קודק נוירוני אינו מעיד כשלעצמו שמקור הדיבור סינתטי; תווית האותנטיות תלויה במשימה ובפרוטוקול של המאגר.

יכולות אלה מעוררות אתגר אבטחתי משמעותי: הקלטה סינתטית יכולה לשמר מאפיינים הנתפסים כאותנטיים ואף להידמות לדובר מסוים, מבלי שנוצרה באמצעות דיבור טבעי של אותו אדם. משום כך יש להבחין בין שתי משימות הקשורות זו לזו אך אינן זהות. Speaker Verification בוחנת את ההתאמה בין קול ההקלטה לזהותו הנטענת של הדובר, ואילו Speech Anti-Spoofing בוחנת אם ההקלטה עצמה אותנטית או נוצרה באמצעות מניפולציה. המחקר הנוכחי מתמקד במשימה השנייה: סיווג דיבור ל-Bona Fide ול-Spoof, ללא צורך בהכרעה על זהותו של הדובר.

אחד האתגרים המרכזיים בזיהוי זיופים הוא פער ההכללה בין נתוני האימון לבין נתוני ההערכה. מודל מפוקח עשוי ללמוד דפוסים המאפיינים מתקפות מסוימות ולהשיג שיעורי שגיאה נמוכים כאשר הוא נבדק על נתונים דומים. אולם כאשר משתנה אלגוריתם הסינתזה, הקודק, מאפייני ההקלטה או אוכלוסיית הדוברים, אותם דפוסים עשויים שלא להופיע עוד. כתוצאה מכך, ביצועי המודל עלולים להידרדר גם כאשר המשימה נשארת לכאורה זהה: הבחנה בין דיבור אמיתי למזויף.

בעיה זו נמצאת במרכזם של שני מחקרים העוסקים ישירות במאגרי הערכה ובשיטות זיוף מודרניות: ASVspoof 5 של Wang et al. (2024) [1] ו-CodecFake של Wu et al. (2024) [2]. הראשון מדגיש את השונות בתנאי הדיבור ואת האיום של מתקפות מורכבות, בעוד שהשני ממחיש כיצד מעבר למשפחת טכנולוגיות יצירה שונה עלול לחשוף מגבלות של מערכות זיהוי קיימות.

לפיכך, שאלת המחקר אינה מסתכמת בזיהוי המודל בעל שיעור השגיאה הנמוך ביותר במאגר נתון. יש לבחון גם כיצד משתנים דפוסי השגיאה בין מתקפות ומקורות, ועד כמה הממצאים מתיישבים עם תלות במאפייני מקור או בתנאי עיבוד. ייחוס סיבתי של החלטות המודל למאפיין מסוים מחייב בדיקות בקרה

נוספות, ולא ניתן לגזור אותו ישירות ממדד EER כולל.

2. מאגרי הערכה, שינויי התפלגות והאתגר של מתקפות לא מוכרות

2.1 ASVspoof 5: מעבר לתנאי זיוף והקלטה מורכבים

סדרת אתגרי ASVspoof תרמה להתפתחות תחום זיהוי הזיופים באמצעות יצירת מאגרי נתונים, פרוטוקולי הערכה ומערכות ייחוס משותפות. ASVspoof 5 מהווה התפתחות משמעותית ביחס לגרסאות קודמות, הן מבחינת מקור דוגמאות הדיבור והן מבחינת מאפייני המתקפות הנכללות במאגר (Wang et al., 2024) [1].

המאגר מבוסס על נתוני דיבור שנאספו ממספר רב של דוברים ובתנאים אקוסטיים מגוונים יותר מאלו שאפיינו מאגרים מוקדמים. לצד מתקפות TTS ו-VC, הוא כולל מנגנונים שנועדו לשפר את יכולתן של מתקפות להטעות מערכות אימות וזיהוי זיופים, לרבות שימוש במודלי Surrogate ומתקפות Adversarial. בנוסף, נתוני ההערכה כוללים תנאי דחיסה וקידוד שונים, ובכללם גם קודקים נוירוניים.

המחברים מבחינים בין שני מסלולי הערכה: Track 1 עוסק בזיהוי עצמאי של דיבור אמיתי לעומת מזויף, ו-Track 2 עוסק ב-Spoofing-Robust Automatic Speaker Verification. הבחנה זו חיונית משום ששני המסלולים בוחנים בעיות שונות, ולכן גם המדדים והפרוטוקולים אינם זהים. בפרט, המדד הראשי של Track 1 באתגר הוא minDCF, כאשר EER מדווח כמדד נוסף. במחקר הנוכחי EER נבחר כמדד המרכזי בהתאם לדרישות פרויקט הקורס, אך אין בכך כדי להפוך אותו למדד הראשי של אתגר ASVspoof 5 המקורי.

המאמר מדגיש את חשיבות ההפרדה בין דוברים ובין שיטות תקיפה במסגרת חלוקות האימון וההערכה. בפרוטוקול המקורי, מתקפות A01–A08 משויכות לחלוקת האימון, A09–A16 לחלוקת הפיתוח ו-A17–A32 לחלוקת ההערכה. הבחנה זו רלוונטית גם למחקר הנוכחי, המשתמש בתת-קבוצה של מתקפות A09–A16: עצם השימוש בתת-קבוצה זו אינו מבטיח שמתקפות הבדיקה יהיו לא מוכרות למודל. כדי לבחון הכללה למתקפות שלא נראו באימון, יש ליצור חלוקה ייעודית השומרת מערכות זיוף מסוימות מחוץ לאימון.

התרומה המרכזית של ASVspoof 5 לסקירת הספרות אינה רק הצגת מאגר מתקדם יותר, אלא חידוד הדרישה להערכה המשקפת את המורכבות של העולם האמיתי. הצלחה על דוגמאות בעלות מאפיינים מוכרים אינה מספקת ראיה ליכולת להתמודד עם כל שילוב עתידי של דובר, ערוץ הקלטה, קודק ומערכת סינתזה.

2.2 CodecFake: הכללה למשפחות זיוף חדשות

Wu et al. (2024) [2] בוחנים את יכולתן של מערכות Anti-Spoofing לזהות דיבור שנוצר באמצעות מערכות סינתזה המבוססות על Neural Audio Codecs. החוקרים מצביעים על כך שמערכות זיהוי שאומנו על מאגרי זיוף מסורתיים אינן בהכרח מותאמות לארטיפקטים המאפיינים תהליכי קידוד ושחזור נוירוניים.

לצורך המחקר נבנה מאגר CodecFake, המבוסס על *שש* משפחות של קודקים נוירוניים ובסך הכול 15 מודלים. היבט מתודולוגי משמעותי הוא שדוגמאות הזיוף במאגר נוצרות באמצעות תהליך Codec Resynthesis: קידוד של דיבור קיים לייצוג בדיד ושחזורו באמצעות מפענח הקודק. תהליך זה מאפשר לבחון את ההשפעה של מנגנון הקידוד והשחזור עצמו, מבלי להיות תלויים בכל רכיביה של מערכת TTS מלאה.

החוקרים משתמשים בנתוני VCTK, תוך הפרדה בין דוברים בקבוצות האימון, הפיתוח והבדיקה. בהמשך נבחנים מודלים שאומנו על תת-קבוצות CodecFake שונות, ונבדקת יכולת ההכללה שלהם בין משפחות קודקים וביחס להקלטות שנוצרו באמצעות מערכות סינתזה אחרות. ממצאי המחקר מצביעים על ירידה משמעותית בביצועי מערכות שאומנו על ASVspoof 2019 LA כאשר הן נבחנות על דוגמאות CodecFake. מנגד, אימון באמצעות נתונים הכוללים שחזורי Codec מסוימים משפר את יכולת הזיהוי של חלק ממערכות הסינתזה המבוססות על קודקים.

כך, למשל, החוקרים מדווחים על EER של 0.40% בזיהוי דוגמאות VALL-E עבור מודל שאומן בתנאי CodecFake מסוים. עם זאת, תוצאה זו מתייחסת לתצורה ניסויית מוגדרת ואינה מייצגת את הביצועים של כל מודלי CodecFake או את יכולת ההכללה לכל מתקפה המבוססת על Codec.

יש להבחין בין **Neural Codec כעיבוד או כערוץ העברת אות**, לבין **Codec Resynthesis המוגדר ב-CodecFake כתנאי Spoof**. במסגרת CodecFake הדוגמאות המשוחזרות מסומנות כמזויפות כדי לבחון את יכולת הזיהוי של ארטיפקטים הנובעים מתהליך השחזור [2]; בפרוטוקולים אחרים, כגון תנאי הקידוד ב-ASVspoof 5 [1] ועיבודי האות ב-AT-ADD [12], קידוד יכול לחול גם על Real וגם על Fake בלי לשנות את תווית מקור הדיבור. לכן הצלחה על CodecFake אינה מוכיחה שהמודל מבחין היטב בין דיבור סינתטי לדיבור אנושי לגיטימי שעבר קידוד, ויש לדווח בנפרד על הגדרת התווית בכל Benchmark.

מבחינה מחקרית, CodecFake מדגיש הבדל בין הכללה בתוך משפחת זיופים לבין הכללה בין משפחות זיוף. מודל עשוי לזהות בהצלחה שחזורים שנוצרו באמצעות קודק מוכר, אך להתקשות בזיהוי שחזורים ממערכת בעלת מנגנון קידוד שונה. מכאן נובע שלא מספיק לדווח על EER כולל; יש לבחון כיצד התוצאות משתנות בהתאם לסוג מערכת הזיוף.

2.3 מפת ממדי ההכללה

ארבעת הממדים הרלוונטיים למחקר הם **Unseen Attack Generalization** (מערכות או משפחות יצירה שלא נצפו באימון), **Cross-Dataset Generalization** (מעבר בין מאגרי נתונים), **Speaker Generalization** (זהויות דוברים חדשות), ו-**Acoustic/Channel Robustness** (שינויי עיבוד או תנאי הקלטה שאינם אמורים לשנות אותנטיות). הם אינם שקולים: בפרוטוקול אחד עשוי להשתנות ממד יחיד, ובאחר כמה ממדים יחד. ההגדרות, המגבלות ומטריצת הפרוטוקולים מפורטות בסעיף 2.4.

2.4 Cross-Domain Benchmarking and Evaluation Validity

מסקנת היסוד העולה מ-ASVspoof 5 [1] ומ-CodecFake [2] היא שאין להתייחס למונח *Generalization* כאל תכונה יחידה של מודל. כל פרוטוקול ניסוי קובע איזה גורם נשמר קבוע ואיזה גורם משתנה, ובהתאם לכך אילו מסקנות אפשר לייחס לתוצאות. AT-ADD של Xie ועמיתיו (2026) [12] מעמיק הבחנה זו

באמצעות הערכה של מתקפות שלא נראו באימון לצד תנאי הקלטה, עיבוד ו-Replay משתנים. בשילוב הממצאים של [10] MLAAD על מעברים בין מאגרים, מחקרים אלה ממחישים שפרוטוקולים שונים יכולים לחשוף קשיי הכללה שונים, אך אינם מבודדים בהכרח את סיבת הירידה בביצועים.

2.4.1 Unseen Attack Generalization: הכללה למערכות יצירה חדשות

בניסוי המכוון ל-*Unseen Attack Generalization*, קבוצת ההערכה כוללת מערכות TTS, VC, Vocoder או Codec שלא שימשו באימון. למשל, בתכנון מסוג Leave-One-System-Out (LOSO), מוציאים מערכת יצירה מסוימת מקבוצת האימון ובודקים האם הגלאי מזהה דוגמאות שהופקו באמצעותה. הגדרה מחמירה יותר יכולה להוציא משפחת ארכיטקטורות שלמה, משום ששמות של מערכות שונות אינם מעידים בהכרח על מנגנוני יצירה בלתי תלויים. הניסוי בודק הכללה למערכת או למשפחה שהושארה בחוץ, *בתוך שאר תנאי הפרוטוקול שהוגדרו*. אם אותם דוברים ומקורות מופיעים ב-Train וב-Test, אין לפרש את התוצאה כהוכחה להכללה גם לדוברים או למקורות חדשים.

CodecFake [2] מספק הצדקה אמפירית להפרדה בין משפחות Codec, בעוד ASVspoof 5 [1] מפריד בין מזהי מתקפה לפי חלוקותיו המקוריות. AT-ADD Track 1 [12] מרחיב זאת באמצעות 20 תנאי יצירה ב-Train/Dev לעומת 27 תנאי זיוף ב-Eval, הכוללים גם שני תנאי Replay של דיבור סינתטי. מכאן שלא נכון לתאר את כל 27 התנאים כמערכות סינתזה עצמאיות או להסיק שכל שינוי בביצועים נובע מחדשנות ארכיטקטונית בלבד.

2.4.2 Cross-Dataset Generalization: מעבר בין מקורות נתונים

ב-*Cross-Dataset Generalization* בוחנים מודל שאומן על מקור נתונים אחד מול דוגמאות ממקור אחר, למשל אימון על ASVspoof 5 והערכה על CodecFake. מעבר כזה עשוי לשנות בו-זמנית את מחלקות הזיוף, הדוברים, השפות, מאפייני המיקרופון, משך האודיו ותהליכי העיבוד. לכן EER גבוה יותר במעבר בין מאגרים הוא עדות לקושי ב-*Domain Shift* כולל, אך אינו ראיה בלעדית לכשל בזיהוי מתקפה חדשה. ההבחנה חיונית גם כאשר המאגר החיצוני כולל דוגמאות אמיתיות ומזויפות ממקורות שונים.

MLAAD [10] מדגים שביצועי Cross-Dataset תלויים במאגר האימון ובמאגר ההערכה; אין מאגר אימון אחד ששלט בכל תרחישי ההשוואה שנבדקו. CodecFake [2] מוסיף ראיות לכך שמעבר לדוגמאות שנוצרו בקודקים נוירוניים עשוי לחשוף כשלי העברה ממערכות שאומנו על מאגרי זיופים אחרים. שני הממצאים מחזקים את הצורך לדווח על מקור האימון ועל מקור ההערכה, אך אינם מבודדים בעצמם את השפעת שינוי מערכת היצירה מהשפעת השינויים בדוברים ובתנאי ההקלטה.

2.4.3 Speaker Generalization: הפרדה בין זהויות דוברים

Speaker Generalization בוחנת האם גלאי מזהה אותנטיות אצל דוברים שלא הופיעו באימון. לשם כך יש לזהות את הדובר ולחלק את הנתונים ברמת Speaker ID, ולא רק ברמת קובץ. כאשר קיימות הקלטות מקור וגרסאות סינתטיות הנגזרות מהן, נדרשת גם שמירה על קבוצות מקור כדי למנוע מעבר של תוכן או אות מקור כמעט זהה בין חלוקות. הפרדת דוברים אינה מחליפה הפרדה בין מערכות זיוף, ולהפך.

[12] AT-ADD מדווח על הפרדת דוברים מתוכננת אך מתעד 18 זהויות Common Voice החופפות בין קבוצות שנבחרו. מכאן שהמאגר אינו Speaker-Disjoint לחלוטין. גם ב-[11] PhonemeDF, שבו גרסאות סינתטיות מקבילות נגזרות מאותן הקלטות LibriSpeech, תקפות הערכה מחייבת שמירה על משפחות הקלטות המקור באותה חלוקה. שתי הדוגמאות ממחישות כי אין להסיק מהכותרת *Cross-Domain* או *Unseen Attack* שהובטחה הפרדה מלאה בין דוברים ומקורות; יש לאמת כל תנאי באמצעות מטא-דאטה ופרוטוקול החלוקה.

2.4.4 Acoustic and Channel Robustness: עמידות לשינויי אות וערוץ

Acoustic and Channel Robustness מתייחסת לשימור ביצועים לאחר שינויים שאינם אמורים לשנות את תווית האותנטיות: דחיסה, סינון, Resampling, רעש, הדהוד, שינוי התקן הקלטה או השמעה והקלטה מחדש. הגדרה זו שונה מזיהוי Replay כמתקפה בפני עצמה במשימות ביומטריות מסוימות. ב-AT-ADD Track 1 [12], למשל, דיבור אנושי שהוקלט מחדש נשאר Real ודיבור TTS שהוקלט מחדש נשאר Fake. כך הפרוטוקול מדגיש הבחנה בין מקור הדיבור לבין הערוץ שעבר בו האות.

כדי להעריך עמידות באופן נקי ככל האפשר, רצוי להפעיל את אותו שינוי אות על אותן הקלטות — או על קבוצות מותאמות — בשתי מחלקות האותנטיות. כאשר שינוי מסוים נפוץ יותר במחלקה אחת, המודל עשוי ללמוד קיצור דרך דרך מאפייני העיבוד. AT-ADD מספק ראיות לקשיי BigVGAN ו-Replay וכן לזיהוי שגוי של Real ממקור 3D-Speaker אצל חלק מן המערכות, אך אינו מבודד בניסוי אחיד את השפעת כל תנאי הערוץ.

2.4.5 מטריצת פרוטוקולים: איזה טיעון המחקר מסוגל לתמוך בו?

פרוטוקול	מה מוחזק מחוץ לאימון	מה ניתן לטעון	מה לא ניתן לטעון ללא בדיקה נוספת
Within-Dataset Speaker-Disjoint	דוברים וקבוצות מקור	הכללה לדוברים חדשים בתוך המאגר	הכללה למתקפה או למאגר חדשים
Leave-One-System-Out	מערכת זיוף / משפחת מערכת	הכללה למערכת שהוחרגה	הכללה למקורות ולערוצים חדשים אם הם חופפים
Cross-Dataset Held-Out	מאגר נתונים שלם	יכולת מעבר למקור נתונים אחר	זיהוי הגורם הסיבתי לירידה בביצועים
Controlled Channel Perturbation	תנאי עיבוד מוגדר	עמידות לשינוי האות שנבדק	עמידות לכל צורות Replay או לכל מכשיר
Joint Cross-Domain	דוברים, מערכות ומקורות גם יחד	הכללה תחת שינוי התפלגות משולב	הפרדת התרומה של כל ממד לשגיאה

ההבחנה הזאת מחדדת את הצורך להפריד בין שתי שאלות: *האם המודל נכשל כשהדומיין משתנה?* לעומת *איזה גורם בדומיין החדש אחראי לכשל?* השאלה הראשונה נבחנת באמצעות Benchmark חיצוני; השנייה דורשת בקרות או ניסויי Ablation מתאימים. לפיכך, בפרויקט הנוכחי Leave-One-System-Out ו-

Cross-Dataset אינם תחליפים אלא ניסויים משלימים בעלי גבולות פרשנות שונים.

MLAAD 2.5 ו-PhonemeDF: הרחבת נתונים לעומת הרחבת המגוון

לצד שיפור הארכיטקטורה, מסלול אפשרי אחר להתמודדות עם פערי הכללה הוא שינוי הרכב נתוני האימון. MLAAD [10] ו-PhonemeDF [11] מציעים שני משאבים שונים מבחינת מגוון הדיבור ומגוון מערכות היצירה. בשניהם עצם זמינותם של קובצי סינתזה רבים אינה מוכיחה שהוספתם תשפר את ההכללה; יש להבחין בין כמות הדוגמאות, מספר המערכות, זהות מקורות הדיבור והרכב הדוברים.

MLAAD 2.5.1: מגוון רחב של מערכות TTS ושפות

Müller ועמיתיו [10] מציגים את MLAAD, מאגר דיבור סינתטי רב-לשוני המבוסס על טקסטים והקלטות מקור הקשורים ל-M-AILABS. בגרסת v11 המתוארת במאמר כלולות כ-1,153.6 שעות דיבור סינתטי מ-205 מודלי TTS ב-54 שפות. המאגר כולל מטא-דאטה כגון שפה, ארכיטקטורת המודל, שם מערכת היצירה, תמלול וקישור לקובץ המקור; המידע על דובר הייחוס מתועד החל מגרסאות מאוחרות יותר. היקף זה הופך אותו למועמד להגדלת גיוון הסינתזה, אם כי הוא מפיץ קובצי Fake סינתטיים בלבד, ואת דוגמאות ה-Real יש להתאים ממקור מורשה כגון M-AILABS; הוא מתמקד בעיקר ב-TTS ולא מספק באופן מובנה את אותו כיסוי של VC כמו PhonemeDF.

העבודה פורסמה במקור ב-IJCNN 2024, בעוד שמספרי היקף המאגר של v11 מתייחסים לעדכון arXiv משנת 2026. מגבלה קריטית לפרשנות התוצאות היא שניסויי Cross-Dataset המדווחים במאמר נערכו על **MLAAD v1**, ולא חזרו אוטומטית על כל גרסאות המאגר המאוחרות. המחברים מדווחים ש-MLAAD ו-ASVspoof 2019 משלימים זה את זה, כאשר כל אחד הוביל בארבע מתוך שמונה הגדרות הערכה; אין בכך הוכחה אמפירית שגרסת v11 בהכרח תשיג ביצועים טובים יותר, או שהגדלת הכמות היא לבדה סיבת השיפור. כמו כן, משום שהמאגר נבנה על בסיס M-AILABS — מקור שמופיע כ-Real בלבד גם בנתוני הקורס — קיים צורך מעשי בבדיקת חפיפת קובצי מקור, טקסטים ודוברים לפני שילובו באימון.

PhonemeDF 2.5.2: התאמת מקור וניתוח פונטי

Nallaguntla ועמיתיו [11] מציגים את PhonemeDF, מאגר מקבילי המבוסס על 28,539 הקלטות דיבור אמיתי מ-LibriSpeech ועל 199,773 גרסאות סינתטיות שנוצרו בארבע מערכות TTS ושלוש מערכות VC. הנתונים מלווים בגבולות פונמות שחושבו באמצעות Montreal Forced Aligner ובקובצי TextGrid. תכנון זה מאפשר להשוות מאפיינים אקוסטיים של יחידות פונטיות תואמות ולבחון האם ארטיפקטים מופיעים באופן לא אחיד לאורך הדיבור.

בניתוח על תת-קבוצה של 1,000 הקלטות מקור החוקרים משתמשים ב-LFCC, LogSpec, wav2vec 2.0 ו-WavLM, יחד עם KLD, מסווגי LR/SVM ומתאמי Pearson. הם מוצאים הבדלים ניכרים בין פונמות, מערכות סינתזה וייצוגים. אולם הקשר בין גודל KLD לבין Accuracy אינו עקבי בין Handcrafted Features לייצוגי SSL, ואף עשוי להיות שלילי. לכן המאמר אינו מוכיח ש-KLD גבוה גורר שיפור EER ברמת ההקלטה או ש-PhonemeDF משפר בהכרח הכללה למערכות שלא נראו באימון.

למחקר הנוכחי יש למאגר תפקיד אפשרי כפול: הרחבת אימון באמצעות מערכות TTS ו-VC נוספות, וניתוח שגיאות פונטי כשלב מתקדם. משום שכל הקלטת מקור מולידה גרסאות סינתטיות רבות, יש להחזיק את *כל משפחת ההקלטות הנגזרות מאותו מקור* בתוך אותה חלוקה. אחרת, הסיווג עלול להסתייע בתוכן או באותות מקור שחצו בין Train ל-Test. יש לאמת גם רישוי, Speaker Metadata ומקורות לפני שימוש מעשי.

2.5.3 מדוע "יותר נתונים" ו"יותר מגוון" הן השערות שונות?

תוספת של 10,000 הקלטות סינתטיות מאותה מערכת TTS עשויה להגדיל את מספר דוגמאות האימון בלי להרחיב את כיסוי מנגנוני הזיוף. לעומת זאת, תוספת של 10,000 הקלטות המחולקות בין כמה מערכות TTS ו-VC עשויה להגדיל גם את המגוון. אם משווים את שתי ההתערבויות בלי לשלוט במספר הדוגמאות, אין דרך לדעת אם השיפור נובע מנפח האימון, מגיוון מערכות היצירה, ממקורות הדיבור או משילוב שלהם.

לכן ההמלצה המושגית היא להבחין בין **Size-Controlled Comparison** — שינוי כמות הנתונים תוך שמירה על הרכב דומה — לבין **Diversity-Controlled Comparison** — שמירה על אותה כמות דוגמאות תוך שינוי מספר מערכות היצירה או משפחותיהן. בשני המקרים יש לשמור על חלוקת דוברים ומקורות עקבית, איזון מחלקות, מדיניות עיבוד שווה ותהליך בחירת מודל שאינו משתמש ב-Test. אלה הן *השלכות מחקריות המוצעות על סמך המקורות*, ולא ניסויים שהמאמרים הוכיחו במשותף.

2.6 סינתזה: Benchmark חיצוני אינו תחליף לניסוי סיבתי

מכלול ASVspoof 5 [1], CodecFake [2], MLAAD [10], PhonemeDF [11] ו-AT-ADD [12] תומך בבניית תוכנית מחקר בשני רבדים: (א) **ניסויים מבוקרים**, המבודדים ככל האפשר את תפקידי הייצוג, נפח האימון ומגוון המתקפות; (ב) **ניסויי תוקף חיצוני**, המעריכים כיצד המודל מתפקד תחת שינויים משולבים במקור הנתונים. דיווח נפרד על שני סוגי ניסויים מונע את הטעות שלפיה תוצאה טובה במבחן חיצוני מגלה בעצמה איזה רכיב גרם לשיפור, או שתוצאה טובה בניסוי LOSO מוכיחה עמידות כללית לכל שינוי ערוץ ומאגר.

3. מאפיינים אקוסטיים קלאסיים: בין יעילות חישובית לרגישות למתקפות

3.1 ייצוג אקוסטי כאמצעי לזיהוי ארטיפקטים

גישות מוקדמות לזיהוי זיופים קוליים הסתמכו במידה רבה על חילוץ מאפיינים אקוסטיים מחושבים מראש (Handcrafted Features), כגון MFCC, LFCC ו-CQCC, ולאחר מכן על שימוש במסווגים סטטיסטיים כדוגמת Gaussian Mixture Models.

הנחת היסוד של גישות אלו היא שתהליכי סינתזה והמרת קול עלולים להשאיר באות הדיבור סימנים ספקטרליים או זמניים המבדילים אותו מדיבור טבעי. בחירה מתאימה של ייצוג אקוסטי עשויה להבליט סימנים אלה גם כאשר הם אינם ניכרים בהאזנה רגילה.

יתרונם של מאפיינים קלאסיים הוא היותם מוגדרים באמצעות תהליך חישובי ידוע, הניתן לשחזור ולניתוח. הם יכולים לשמש בסיס למודלים פשוטים יחסית, ולפיכך הם מתאימים במיוחד לניסויי Baseline שמטרתם לבחון באופן מבוקר את התרומה של שלבי חילוץ המאפיינים ושל המסווגים.

עם זאת, מאפיינים המוגדרים באמצעות נוסחה קבועה מגבילים את סוגי המידע הנשמרים בייצוג. במצב שבו מנגנון זיוף מצליח לחקות היטב מאפיינים מסוימים של דיבור אמיתי, מסווג המבוסס על אותם מאפיינים עלול שלא להבחין במניפולציה.

CQCC 3.2 וחשיבות הרזולוציה הספקטרלית

Todisco, Delgado and Evans (2017) [3] מציעים שימוש ב-Constant Q Cepstral Coefficients (CQCC) לזיהוי מתקפות נגד מערכות אימות דובר. השיטה משלבת Constant-Q Transform עם עיבוד Cepstral, במטרה לשמר מידע ספקטרלי המתאים לזיהוי ארטיפקטים הנוצרים במתקפות זיוף.

בניגוד לניתוח המבוסס על חלוקת תדרים ליניארית, Constant-Q Transform משתמש בחלוקה לוגריתמית של תחום התדרים, המאפשרת רזולוציית תדר גבוהה יותר בתדרים נמוכים ורזולוציה זמנית גבוהה יותר בתדרים גבוהים. מאפיינים אלה עשויים לספק רגישות לתבניות שלא נשמרות באותו אופן בייצוגים אקוסטיים אחרים.

המחברים בוחנים את CQCC בשלושה מאגרים הכוללים תרחישי זיוף שונים: ASVspoof 2015, AVspoof ו-RedDots Replayed. מעבר להדגמת יעילותו של הייצוג, המחקר מציג תובנה חשובה לגבי הכללה: תצורות CQCC המתאימות למאגר או לסוג מתקפה מסוים אינן בהכרח התצורות המתאימות ביותר למאגר אחר.

לכן תרומתו של CQCC למחקר הנוכחי אינה רק בהצעת מאפיין אקוסטי נוסף, אלא בהמחשת החשיבות של בחירת ייצוג בהתאם לאופי המתקפות ולתנאי ההערכה. העובדה שמאפיין מסוים משיג ביצועים טובים בתרחיש מוגדר אינה מבטיחה שהוא יהיה עמיד בפני שינוי התפלגות.

Feature Fusion 3.3 ושילוב מודלים סטטיסטיים ונוירוניים

כיוון נוסף מוצג על ידי Izrailov, Kotenko and Chechulin (2026) [8], המציעים מערכת לזיהוי זיופים קוליים בסביבת אימות ביומטרי באמצעות שילוב MFCC, Perceptual Linear Prediction (PLP), GMM–UBM ורשת CNN.

ההיגיון בשיטה הוא שמאפיינים אקוסטיים שונים עשויים לתאר היבטים משלימים של אות הדיבור. בעוד ש-MFCC מבוסס על ניתוח המעטפת הספקטרלית בסולם Mel, PLP משלב הנחות הקשורות לתפיסה שמיעתית ול-Linear Predictive Coding. השילוב נועד לאפשר זיהוי של תבניות שלא בהכרח מיוצגות היטב באמצעות סוג מאפיינים יחיד.

GMM–UBM משמש למידול סטטיסטי של התפלגות המאפיינים, ואילו ה-CNN מיועד ללמוד קשרים בתוך הייצוג המשולב. על ASVspoof 2019 LA החוקרים מדווחים על EER של 4.79% עבור הגישה ההיברידית, לעומת 6.27% עבור CQCC+GMM ו-7.44% עבור LFCC+GMM. בניסוי נוסף על נתוני TED-LIUM דווח על EER של כ-5.1%, בתנאי הערכה מוגבלים יותר.

תוצאות אלו מצביעות על פוטנציאל לשיפור באמצעות שילוב מאפיינים וגישות סיווג. עם זאת, המאמר אינו כולל ניסויי Ablation המבודדים באופן מלא את תרומת MFCC, PLP, GMM–UBM וה-CNN. מכאן שאין להסיק כי הוספת PLP לבדה היא הגורם לשיפור או ש-CNN מורכב בהכרח עדיף על מסווג פשוט באותו מרחב מאפיינים.

נוסף על כך, המאמר מציע מסגרת קבלת החלטות בעלת ארבע קטגוריות, המשלבת בין אימות דובר לבין רמות שונות של חשד לזיוף, בעוד שטבלת התוצאות המרכזית אינה מציגה הערכה נפרדת של כל ארבע הקטגוריות. לכן יש להבחין בין תיאור המערכת המוצעת לבין היקף הראיות הניסויות התומכות בה.

3.4 מסקנה אינטגרטיבית: בחירת ייצוג לפני הגדלת מורכבות

ממצאי CQCC והגישה ההיברידית מציעים שני כיוונים משלימים. הראשון מדגיש את חשיבותם של מאפיינים אקוסטיים בעלי תכונות שונות, והשני מציע לשלב מאפיינים ומודלים כדי לנצל מידע משלים.

עם זאת, שני הכיוונים אינם מוכיחים שהגדלת מספר המאפיינים או מורכבות המערכת מובילה בהכרח לשיפור. שילוב מאפיינים עשוי גם להגדיל את ממד הנתונים, להוסיף מידע כפול או להגביר רגישות למאפיינים לא רלוונטיים.

בהקשר של מאגר אימון מוגבל, יש הצדקה מחקרית להתחיל במודלים פשוטים עם מספר מצומצם של מאפיינים, ולבחון באופן מבוקר האם תוספת מידע באמת משפרת את הביצועים ואת ההכללה.

4. למידה עמוקה מקצה לקצה: זיהוי קשרים ספקטרליים וזמניים

מעבר לגישות המבוססות על מאפיינים מחושבים מראש, מחקרים רבים מציעים רשתות עמוקות הלומדות בעצמן ייצוגים רלוונטיים לזיהוי זיופים מתוך אות הדיבור.

אחת הגישות המרכזיות בכיוון זה היא AASIST — Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks, שהוצגה על ידי Jung et al. (2022) [4].

4.1 ארכיטקטורת AASIST

AASIST משתמשת ב-Encoder המבוסס על RawNet2 לצורך חילוץ ייצוגים מאותו דיבור, ולאחר מכן במנגנונים גרפיים המתארים קשרים בתחום הזמן ובתחום התדר.

החידוש המרכזי של המודל הוא שימוש ב-Heterogeneous Stacking Graph Attention Layer (HS-GAL), המאפשרת ללמוד קשרים בין ייצוגים זמניים וספקטרליים שונים. בכך המודל אינו מוגבל לבחינת כל תחום בנפרד, אלא יכול ללמוד קשרים בין ארטיפקטים המופיעים במיקומים שונים לאורך ההקלטה ובתחומי תדר שונים.

בנוסף, המודל כולל Max Graph Operation (MGO), המשלב שתי זרועות עיבוד באמצעות פעולת Maximum, ומנגנון Readout המשתמש בין היתר ב-Stack Node לצורך איגום מידע רלוונטי לסיווג.

ההנחה המחקרית היא שזיופים שונים עשויים להשאיר סימנים באזורים שונים של האות, ולכן מנגנון Attention המסוגל להתמקד בקשרים מגוונים עשוי להיות יעיל יותר מייצוג גלובלי פשוט.

4.2 תוצאות ותרומת הרכיבים

על ASVspoof 2019 LA, המחברים מדווחים על EER של 0.83% ועל min t-DCF של 0.0275 עבור התוצאה הטובה ביותר של AASIST. חשוב לציין שהתוצאות הללו הן של הריצה הטובה ביותר, בעוד שהממוצעים שדווחו על פני שלושה Seeds הם EER של 1.13% ו-min t-DCF של 0.0347.

החוקרים מציגים גם גרסה קלת משקל, AASIST-L, הכוללת כ-85 אלף פרמטרים ומשיגה EER של 0.99% בריצה הטובה ביותר. ממצא זה מדגים כי ניתן להשיג ביצועים תחרותיים באמצעות ארכיטקטורה קומפקטית יחסית, אם כי מספר פרמטרים קטן אינו שקול בהכרח לעלות חישובית נמוכה בכל סביבת חומרה.

בניסויי Ablation נמצא כי להסרת רכיבי HS-GAL, MGO או מנגנון ה-Readout קיימת השפעה שלילית על הביצועים, כאשר מנגנון ה-Heterogeneous Attention הציג את התרומה המשמעותית ביותר מבין הרכיבים שנבחנו.

4.3 מגבלות ההכללה של ארכיטקטורה ייעודית

למרות הישגיה, ההערכה המרכזית במאמר AASIST מתבצעת על ASVspoof 2019 LA. תוצאות אלו אינן מעידות לבדן על יכולת לזהות מתקפות עדכניות יותר, ובפרט זיופים המבוססים על Neural Audio Codecs.

בהקשר זה, ממצאי CodecFake [2] משמעותיים במיוחד: הם מצביעים על כך שמודלים בעלי ביצועים חזקים על מאגר ASVspoof 2019 LA עלולים להציג ירידה ניכרת כאשר הם נבחנים על זיופים ממשפחת Codec שונה.

שילוב שני המחקרים מלמד כי ארכיטקטורה המסוגלת ללמוד קשרים ספקטרליים וזמניים מורכבים אינה חסינה בהכרח מפני שינוי בהתפלגות המתקפות. איכות ייצוג הארטיפקטים היא גורם חשוב, אך גם המגוון והמאפיינים של נתוני האימון עשויים לקבוע אילו ארטיפקטים המודל לומד לזהות.

לפיכך, AASIST משמשת בסקירה זו כדוגמה לארכיטקטורה עמוקה ייעודית בעלת יכולות הבחנה גבוהות, אך לא כהוכחה ליכולת הכללה בלתי מוגבלת.

5. Self-Supervised Learning: ייצוגי דיבור מאומנים מראש כחלופה לאימון מאפס

גישה נוספת להתמודדות עם מגבלות נתונים היא שימוש במודלי דיבור שעברו Pre-training על כמויות גדולות של אודיו לא מתויג.

בניגוד למודלים המאמנים את כל רכיבי הייצוג ישירות על מאגר הזיופים, Self-Supervised Learning (SSL) מאפשר ללמוד מאפייני דיבור כלליים, ולאחר מכן להשתמש בייצוגים שנלמדו לצורך משימות נוספות.

5.1 wav2vec 2.0: למידת ייצוגים באמצעות משימה ניגודית

Baevski et al. (2020) [5] מציגים את wav2vec 2.0, ארכיטקטורה ללמידת ייצוגי דיבור מתוך Raw Waveform.

המודל משלב Convolutional Feature Encoder, Transformer Context Network ומנגנון Quantization המשמש בשלב האימון העצמי. במהלך Pre-training מוסתרים מקטעים מתוך הייצוג הרציף, והמודל נדרש לזהות את הייצוג הבדיד המתאים באמצעות Contrastive Learning, תוך הבחנה בין הייצוג הנכון לבין דוגמאות שליליות.

אופן אימון זה מאפשר למודל ללמוד ייצוגים המתארים קשרים זמניים והקשריים בדיבור, בלי להזדקק לתמלול עבור כל הקלטה במהלך ה-Pre-training.

המחברים מדגימים את יעילות השיטה בעיקר במשימות Automatic Speech Recognition (ASR), לרבות מצבים שבהם קיימת כמות מוגבלת של נתונים מתויגים. עם זאת, המדדים המרכזיים במאמר, כגון Word Error Rate (WER), אינם מדדים לזיהוי זיופים קוליים.

לכן תרומתו של wav2vec 2.0 למחקר הנוכחי היא בהצגת מנגנון יעיל ללמידת ייצוגי דיבור מאומנים מראש, ולא בהוכחה ישירה לכך שייצוגים אלה מזהים זיופים טוב יותר ממאפיינים אקוסטיים אחרים.

5.2 WavLM: הרחבת ייצוגי הדיבור למשימות מגוונות

Chen et al. (2022) [6] מציגים את WavLM, מודל SSL שנועד להפיק ייצוגים המתאימים למגוון רחב של משימות עיבוד דיבור, ולא רק לזיהוי התוכן המילולי.

המודל משלב Masked Speech Prediction עם Denoising במהלך ה-Pre-training, ומשתמש ב-Gated Relative Position Bias לצורך מידול קשרים זמניים. גרסת WavLM Large אומנה על כ-94 אלף שעות של אודיו ממקורות שונים.

אחד ההיבטים המרכזיים במחקר הוא ההבחנה בין סוגי המידע הקיימים בייצוגי דיבור. בעוד שמשימות ASR מתמקדות בעיקר בתוכן הנאמר, משימות אחרות דורשות מידע על זהות הדובר, אינטונציה, סביבה אקוסטית או קשרים בין דוברים.

המחברים מדגימים את יעילות המודל במגוון משימות במסגרת SUPERB ובמאגרי הערכה נוספים, לרבות Speaker Verification, Speaker Diarization ו-Speech Separation.

עם זאת, תוצאות EER המופיעות במאמר עבור Speaker Verification מתייחסות לאימות זהות הדובר, ולא לסיווג דיבור אמיתי מול דיבור מזויף. אין לפרש אותן כמדדי Deepfake Detection.

5.3 הרלוונטיות של ייצוגי SSL לזיהוי זיופים

שני המחקרים מציעים אפשרות להשתמש בידע שנלמד מנתוני דיבור נרחבים לצורך משימה בעלת מאגר מתויג קטן יחסית.

מבחינה יישומית, ניתן להשתמש ב-wav2vec 2.0 וב-WavLM כ-Encoders קפואים, לחלץ מהם Embeddings ולהעביר את הייצוגים למסווג פשוט. גישה זו מאפשרת לבחון את איכות הייצוג בלי לאמן מחדש את מיליוני הפרמטרים של המודל המקורי.

עם זאת, קיים מתח בין למידת ייצוגים כלליים לבין שימור הסימנים העדינים הדרושים לזיהוי זיופים. ייצוג המתאים היטב לזיהוי תוכן דיבור או לזהות דובר אינו בהכרח משמר את אותם ארטיפקטים ספקטרליים שמעידים על סינתזה מלאכותית.

כמו כן, שכבות שונות של מודל SSL עשויות לשמר סוגי מידע שונים. לפיכך בחירת ה-Layer, שיטת ה-Pooling ואופן התאמת המסווג עשויים להשפיע על ביצועי הזיהוי.

מכאן שהשימוש ב-Pre-trained Encoder הוא השערה מחקרית סבירה, אך לא פתרון מובטח לבעיית ההכללה. תרומתו צריכה להיבחן באופן אמפירי, תחת פרוטוקול זהה לזה של שיטות ההשוואה.

נוסף על כך, **מקור נתוני ה-Pre-training הוא חלק מפרוטוקול התוקף**. מאחר שמודלי SSL עשויים להיות מאומנים על קורפוסים רחבים, יש לתעד את הגרסה המדויקת של ה-Checkpoint ואת המקורות הידועים של האימון המקדים, ולבדוק חפיפות אפשריות עם הקלטות ההערכה וקובצי המקור שלהן. חשיפה מוקדמת לאודיו לא מתויג אינה שקולה בהכרח לדליפת תוויות Test בעת אימון מפוקח, אך היא עשויה לצמצם את מידת העצמאות של ההערכה; בהיעדר מידע מספיק יש לדווח על אי-הוודאות, ולא לטעון להיעדר מוחלט של חפיפה.

6. שיפור ייצוגים באמצעות שחזור מונחה והדגשת עקבות פורנזיות

המחקרים שנסקרו עד כה מתמקדים בעיקר בבחירת ייצוג הדיבור או בארכיטקטורת הסיווג. לעומתם, Wu et al. (2026) [7] במאמר *Robust Speech Forgery Detection via Enhanced Forensic Trace Generation*, מציעים לשפר את המידע המועבר למסווג באמצעות תהליך שחזור מונחה.

6.1 הרעיון המרכזי: שחזור כדרך להדגשת מידע מבחין

החוקרים משתמשים ב-Vector-Quantized Variational Autoencoder (VQ-VAE) לצורך שחזור מאפיינים ספקטרליים, ולאחר מכן משלבים את הייצוג המשוחזר עם הייצוג המקורי.

מטרת התהליך אינה רק לשחזר נאמנה את אות הדיבור, אלא לשפר את יכולת המסווג להבחין בין דיבור אמיתי למזויף. בהתאם לכך, המודל הגנרטיבי מאומן באמצעות אותות פיקוח המגיעים מ-Encoder של מסווג זיופים שאומן מראש ופרמטריו נשארים קפואים בשלב הנחיית השחזור.

החוקרים מציעים מספר רכיבי Loss המכוונים את תהליך השחזור. True Speech Consistency Loss נועד לשמר את הקרבה בין ייצוגים של דיבור אמיתי לבין שחזוריהם, ואילו Dual-Margin Triplet Loss משתמש גם בדוגמאות מזויפות כדי להגביר את ההבחנה בין דיבור אמיתי למזויף במרחב המאפיינים.

נקודה חשובה היא שהגישה אינה One-Class Learning במובנה המלא. אף שהשחזור מכוון לדיבור אמיתי, דוגמאות זיוף משמשות כאות פיקוח במהלך האימון, ולכן השיטה מסתמכת גם על מידע מפורש לגבי המחלקה המזויפת.

6.2 תוצאות ויכולת הכללה

המחקר נבחן על ASVspoof 2019 LA ועל ASVspoof 2021 LA, באמצעות מאפיינים אקוסטיים שונים ומסווג המבוסס על ResNet.

עבור Log-Power Spectrum (LPS), המערכת המבוססת על המאפיינים המקוריים השיגה EER של 1.22% על ASVspoof 2019 LA ו-22.64% על ASVspoof 2021 LA. לאחר שילוב המאפיינים המקוריים עם השחזור המונחה, התקבלו EER של 1.02% ושל 14.04%, בהתאמה.

כלומר, השיפור על ASVspoof 2021 LA היה משמעותי יותר מהשיפור על מאגר 2019, והדגים פוטנציאל לשיפור ביצועים תחת שינוי בתנאי ההערכה.

עם זאת, השיפור לא היה אחיד בכל הייצוגים. לדוגמה, עבור CQCC התקבלה הרעה מסוימת ב-EER על ASVspoof 2019 LA לאחר הוספת תהליך השחזור, לצד שיפור על ASVspoof 2021 LA. ממצא זה מחזק את הצורך להעריך את תהליך השיפור בהתאם לייצוג ולמאגר, ולא להניח ש-Feature Reconstruction מועיל בכל מצב.

בנוסף, השיטה מוסיפה עלות חישובית ביחס למסווג המקורי. החוקרים מדווחים על עלייה ממערכת הכוללת כ-2.34 מיליון פרמטרים וכ-1.25 מיליארד MACs למערכת הכוללת כ-5.67 מיליון פרמטרים וכ-3.12 מיליארד MACs. לפיכך, שיפור ה-EER מלווה בהגדלת מורכבות המערכת.

6.3 המשמעות המחקרית

המחקר מדגים כי שיפור ביכולת הזיהוי אינו חייב לנבוע מהחלפת המסווג כולו. ניתן גם לשנות את הייצוג המועבר למסווג, במטרה להדגיש מידע הקשור לזיוף.

עם זאת, אין להסיק שהתהליך יפעל באותה מידה על מאגרי CodecFake או ASVspoof 5, שלא נבחנו ישירות במאמר. בנוסף, מכיוון שהשיטה מסתמכת על רכיבים גנרטיביים ועל פונקציות אובדן נוספות, יש לבחון את היחס בין תרומתה לביצועים לבין העלות והמורכבות שהיא מוסיפה.

בהקשר של המחקר הנוכחי, שיטה זו מספקת כיוון אפשרי להרחבה עתידית, אך אינה מחייבת מימוש בשלב הראשוני של המחקר.

7. One-Class Learning: מידול הדיבור האמיתי במקום למידת מתקפות מוכרות

הגישות שנידונו עד כה משתמשות בעיקר בלמידה מפוקחת של ההבדל בין דיבור אמיתי למזויף, או בהדגשת מאפיינים באמצעות דוגמאות משתי המחלקות. גישה שונה מוצעת על ידי Yin and Lei (2026) [9], במאמר *A Novel Attack-Resistant Speech Forgery Detection Method Integrating One-Class Learning and Wav2vec2*.

7.1 שינוי פרדיגמת הלמידה

המחברים טוענים כי אחד הגורמים לפגיעה בהכללה הוא תלות בדוגמאות זיוף מתויגות, המייצגות רק חלק מהטכנולוגיות האפשריות. כדי להתמודד עם מגבלה זו, הם מציעים ללמוד את ההתפלגות של דיבור אותנטי בלבד, ולהגדיר דוגמאות החורגות ממנה כחשודות.

השיטה מבוססת על Deep Support Vector Data Description (Deep SVDD), שבמסגרתו רשת נוירונים ממפה דוגמאות אמיתיות למרחב ייצוגים ולומדת אזור קומפקטי סביבן. האזור מיוצג באמצעות Hypersphere, והמרחק ממרכזו משמש בסיס לציון החריגה של הקלטה חדשה.

יתרונה האפשרי של גישה זו הוא שהמודל אינו נדרש ללמוד את המאפיינים הייחודיים של כל טכנולוגיית זיוף. במקום זאת, הוא בוחן אם ההקלטה תואמת את התפלגות הדיבור האמיתי שנלמדה באימון.

7.2 שילוב Deep SVDD עם wav2vec 2.0

המערכת המוצעת משתמשת בייצוגי wav2vec 2.0 Base ובמאפייני LFCC. רשתות משנה הכוללות רכיבי Bi-LSTM ו-LCNN מפיקות ייצוגים המשמשים ללמידת גבולות Deep SVDD.

בנוסף, החוקרים מציעים מנגנון Weighted Fusion המשלב ציונים של ארבע רשתות משנה. משקלי השילוב נבחרים באמצעות Optuna, במטרה להפחית EER על קבוצת Validation.

באופן זה המחקר משלב שני רעיונות שונים: שימוש בייצוגי דיבור מאומנים מראש, ושינוי של פרדיגמת הסיווג מלמידה בינארית ללמידת חריגות.

7.3 תוצאות על מתקפות מוכרות ולא מוכרות

המחברים מדווחים על EER של 2.13% על ASVspoof 2019 LA ושל 6.89% על ASVspoof 2021 DF.

לשם השוואה, מודל wav2vec 2.0 עם מסווג בינארי מפוקח השיג EER של 2.35% על ASVspoof 2019 LA ושל 18.45% על ASVspoof 2021 DF.

התוצאות מצביעות על יתרון בולט של המערכת המשולבת על קבוצת ההערכה של ASVspoof 2021 DF, בהתאם לפרוטוקול המדווח.

עם זאת, יש להבחין בין תוצאה זו לבין הוכחה כללית לעדיפות של One-Class Learning. השיטה המוצעת אינה שונה מהמסווג הבינארי רק בפרדיגמת הלמידה; היא כוללת גם מספר רשתות משנה, שילוב ציונים ואופן ייצוג שונה. לכן אי אפשר לייחס את כל השיפור ל-Deep SVDD בלבד.

נוסף על כך, המעבר בין ASVspoof 2019 LA ל-ASVspoof 2021 DF כולל שינוי במאגר ובתנאי ההערכה, ולא רק החלפה של סוג המתקפה. לפיכך, הממצא מהווה ראיה מסוימת ליכולת להתמודד עם נתוני הערכה שונים, אך אינו מבודד באופן מלא הכללה למתקפות חדשות.

7.4 מגבלות מתודולוגיות של השיטה

המאמר מציג את השיטה ככזו שאינה דורשת דוגמאות זיוף מתויגות. אולם לצד אימון Deep SVDD על דיבור אמיתי, המחברים מתארים שימוש ב-EER לצורך Early Stopping ולבחירת משקלי ה-Fusion באמצעות Optuna.

מאחר שחישוב EER במשימת זיהוי זיופים דורש דוגמאות מתויגות משתי המחלקות, התיאור אינו מבסס במלואו את הטענה שהמערכת השלמה אינה תלויה כלל בדוגמאות זיוף. יש להבחין בין אימון מסווג החריגות עצמו לבין תהליך בחירת המודל וההיפר-פרמטרים.

כמו כן, בטבלת ה-Ablation של המאמר קיימות אי-התאמות בין שמות התצורות לבין הערכים וההסברים המילוליים. אי-התאמות אלה מגבילות את האפשרות לייחס בצורה מדויקת את השיפור לכל רכיב.

7.5 חריגה מההתפלגות אינה בהכרח זיוף

המגבלה העקרונית החשובה ביותר של One-Class Learning נובעת מן ההבחנה בין זיהוי חריגה לבין זיהוי זיוף.

הקלטה אמיתית עשויה להיות חריגה מהנתונים שעליהם אומן המודל בשל הבדלי דובר, שפה, מיקרופון, רעש רקע או מקור הנתונים. במקרה כזה המודל עלול לזהות דיבור אותנטי כזיוף.

מנגד, זיוף איכותי במיוחד עשוי להפיק ייצוג דומה מספיק להתפלגות הדיבור האמיתי, ולכן לא להתגלות כחריגה.

מכאן שהצלחת One-Class Learning תלויה לא רק באיכות גבול ההחלטה, אלא גם במידת הייצוגיות של דוגמאות הדיבור האמיתי ובאופן שבו מרחב המאפיינים מבדיל בין שינויים טבעיים לבין ארטיפקטים של זיוף.

לכן שיטה זו מחייבת הערכה ייעודית של שיעור הדחייה השגויה של דיבור אמיתי, במיוחד כאשר ההקלטות מגיעות ממקורות שונים.

8. סינתזה השוואתית של כיווני המחקר

המחקרים שנסקרו מייצגים גישות שונות לזיהוי זיופים ולהתמודדות עם בעיית ההכללה. ההבדלים ביניהם אינם מסתכמים בארכיטקטורה או במספר הפרמטרים, אלא נוגעים לשאלה איזה מידע נחשב רלוונטי לזיוף וכיצד המודל לומד להשתמש בו.

8.1 מפת המחקרים

מחקר	תרומה מרכזית	ראיות להכללה	מגבלה משמעותית
ASVspoof 5 [1]	מאגר ופרוטוקול הכוללים מתקפות ותנאים מגוונים	חלוקות מתקפה, דובר וערוץ	אינו מוכיח הכללה של מודל מסוים
CodecFake [2]	מאגר זיופים מבוססי Neural Codecs	Cross-Codec ו--Cross Dataset	הביצועים תלויים במשפחת ה-Codec ובתצורת האימון
CQCC [3]	ייצוג ספקטרלי בעל רזולוציה משתנה	הערכה במספר מאגרים	רגישות הייצוג לסוג המתקפה ולתנאי ההערכה
AASIST [4]	למידה עמוקה של קשרים ספקטרליים וזמניים	ביצועים חזקים על ASVspoof 2019 LA	הכללה למתקפות Codec חדשות אינה מובטחת
wav2vec 2.0 [5]	ייצוגי דיבור באמצעות SSL	הכללה למשימות ASR עם מעט תוויות	אין הוכחה ישירה לזיהוי זיופים במאמר המקורי
WavLM [6]	SSL למגוון משימות דיבור	ביצועים במשימות דיבור שונות	מדדי Speaker Verification אינם Spoof EER
Enhanced Forensic Trace [7]	שחזור ספקטרלי מונחה לצורך הדגשת ארטיפקטים	שיפור על ASVspoof 2021 LA	מורכבות נוספת ושיפור שאינו אחיד בין מאפיינים
Intelligent Voice Fraud [8]	שילוב MFCC, PLP, GMM–UBM ו-CNN	הערכה נוספת על TED-LIUM	היעדר Ablation ופירוט מימוש מלא
One-Class + wav2vec 2.0 [9]	מידול דיבור אמיתי באמצעות Deep SVDD	ביצועים משופרים על ASVspoof 2021 DF	רגישות ל-Domain Shift ואי-בהירות בפרוטוקול הכוונון
MLAAD [10]	הרחבת מערכות TTS ושפות באימון	ניסויי Cross-Dataset על v1	אין להסיק ביצועי v11 מהערכות v1; חפיפות עם M-AILABS מחייבות בדיקה
PhonemeDF [11]	מאגר TTS/VC מקבילי עם תיוג פונמות	ניתוח הפרדה פונטית בין Real ל-Fake	אין ראיה ישירה לשיפור EER או הכללה ל-Unseen Generators
AT-ADD [12]	פרוטוקול עמידות והכללה בתנאי הקלטה משתנים	Generator Shift, Replay, ערוץ וניתוח שגיאות	שינויי דומיין משולבים; גישה לנתוני Track 1 לא אומתה

הטבלה משמשת להשוואה מושגית ומתודולוגית בין המחקרים. היא אינה מהווה דירוג ביצועים מספרי, מכיוון שהמאמרים נבדקו על מאגרים, משימות ופרוטוקולים שונים.

8.2 עוגני ראיות אמפיריות וגבולות פרשנות

הטבלה הבאה מציגה **השוואות פנימיות בלבד**: המספרים נועדו לעגן טענות מסוימות במחקרים המקוריים, לא לדרג את כלל המודלים על פני מאגרים ומדדים שונים.

מחקר	השוואה אמפירית מדווחת	מה ניתן להסיק — ומה לא
CodecFake [2]	בדוגמת VALL-E מדווח EER של 0.40% בתנאי אימון על תת-קבוצת CodecFake מסוימת; אימון על מאגר מסורתי פוגע בביצועים בתרחישים שנבדקו	הרכב דוגמאות האימון רלוונטי להעברה בין משפחות Codec; אין להכליל את הערך לכל השיטות
AASIST [4]	EER ממוצע 1.13% על פני שלוש ריצות על ASVspoof 2019 LA; ריצה מיטבית 0.83%	ביצוע חזק במאגר מוגדר; אין הוכחה אוטומטית להכללה בין מאגרים
Enhanced Forensic Trace [7]	בייצוג LPS, מעבר מ-22.64% ל-14.04% EER ב-ASVspoof 2021 LA	שחזור מונחה עשוי לסייע בתנאים שנבדקו; אין שיפור אחיד בכל הייצוגים
One-Class + wav2vec 2.0 [9]	EER 18.45% למערכת השוואה בינארית ב-ASVspoof 2021 DF לעומת 6.89%	למערכת המשולבת יתרון בניסוי המדווח; לא ניתן לייחסו ל-Deep SVDD לבדו
MLAAD [10]	במבחני Cross-Dataset על MLAAD v1, ו-ASVspoof 2019 מובילים כל אחד בארבע מתוך שמונה תצורות הערכה	מאגרי אימון משלימים; לא בוצעה הוכחת שיפור מבוקרת עקב המעבר ל-v11
PhonemeDF [11]	הבדלים ב-KLD וב-Accuracy בין פונמות וייצוגים, כולל מתאמים שליליים בחלק מייצוגי SSL	קיימת שונות פונטית באותות ההבחנה; אין ראיה ישירה לשיפור EER ברמת הקלטה
AT-ADD Track 1 [12]	Macro-F1 76.73% ל-Baseline הרשמי המוביל לעומת 90.71% למערכת הזוכה; BigVGAN ו-Replay קשים יחסית	למערכת השלמה של הזוכים ביצועים עדיפים בפרוטוקול זה; אין בידוד סיבתי של כל רכיב או יכולת להשוות מספרית ל-EER

ממצאים אלה מחזקים את המסקנה שהצלחת מערכת תלויה בהרכב הנתונים, בייצוג, בתהליך האימון ובאופן ההערכה. עם זאת, **שום שורה אינה ניסוי משותף לכל שנים-עשר המחקרים**; גבולות ההסקה של כל מקור נשמרים בנפרד.

8.3 שש תובנות אינטגרטיביות

ראשית, בחירת הייצוג משפיעה על יכולת זיהוי הזיופים. CQCC מדגים את חשיבות המבנה הספקטרלי, AASIST לומד קשרים זמניים וספקטרליים ו-SSL מספק ייצוגי דיבור מאומנים מראש. אולם אף אחד מהייצוגים אינו מבטיח לבדו עמידות לכל סוגי המתקפות.

שנית, שיפור ביכולת ההבחנה אינו שקול בהכרח לשיפור בהכללה. מודל עשוי להשיג EER נמוך על מאגר מוכר, אך להציג ירידה משמעותית כאשר משתנה מנגנון יצירת הזיוף. ממצאי CodecFake מדגימים בעיה זו באופן ישיר.

שלישית, קיימות דרכים שונות לצמצום התלות בדוגמאות זיוף מוכרות. שימוש בייצוגי SSL מבקש לנצל ידע שנלמד מדיבור בהיקף רחב, שחזור מונחה מבקש להדגיש מידע מבחין, ו-One-Class Learning מבקש להגדיר את תחום הדיבור האמיתי במקום ללמוד את כל צורות הזיוף.

רביעית, התועלת של מורכבות נוספת אינה מובטחת. Feature Fusion, VQ-VAE ו-Multi-Model Fusion עשויים לשפר ביצועים, אך גם להגדיל עלות חישובית, רגישות לכוונון והסיכון להתאמת יתר. כדי לקבוע את ערכם יש לבחון את תרומתם באמצעות ניסויים מבוקרים, ולא להסתמך רק על הביצועים הכוללים של מערכת מורכבת.

חמישית, מגוון האימון הוא משתנה ניסויי נפרד מנפח האימון. MLAAD [10] ו-PhonemeDF [11] מציעים הזדמנות להרחבת מקורות הזיוף, אך אינם מוכיחים שהגדלת כמות הקבצים כשלעצמה מסבירה שיפור בהכללה. יש לבחון בנפרד תוספת כמות ותוספת משפחות TTS/VC, תוך שליטה במקור ובמספר דוגמאות.

שישית, תוקף ההערכה תלוי בהגדרה המדויקת של השינוי. AT-ADD [12] ו-CodecFake [2] מציעים פרוטוקולים מחמירים המביאים בחשבון שינויי Generator, Speaker, Dataset ו-Channel. עם זאת, ביצועים בתנאי Shift משולב אינם מזהים את מקור הכשל ללא ניסוי מבוקר נוסף.

8.4 המתח בין ייצוג עשיר לבין ייצוג עמיד

אחת התובנות העולות מן הסינתזה היא שקיים מתח אפשרי בין העשרת ייצוג הדיבור לבין הפחתת רגישותו לשונות שאינה קשורה לזיוף.

ייצוג עשיר עשוי לשמר יותר פרטים, ובהם ארטיפקטים עדינים הנוצרים בתהליכי סינתזה. אולם הוא עשוי לשמר גם מידע על דובר, שפה, ערוץ הקלטה או מקור המאגר. אם המודל נשען על מידע זה, שיפור הביצועים על נתוני האימון אינו מבטיח יכולת הכללה.

מצד שני, ייצוג שמטרתו ללמוד תכונות כלליות ועמידות לשינויי סביבה עשוי לדכא חלק מהפרטים האקוסטיים הדרושים להבחנה בין דיבור טבעי למזויף.

ממצא נוסף מ-PhonemeDF [11] הוא שיכולת ההבחנה משתנה בין פונמות: סימני זיוף אינם חייבים להתפלג באופן אחיד בזמן. מכאן עולה **השערת מחקר נוספת אך לא מחייבת**: Temporal Mean Pooling של Embeddings ברמת הקלטה עשוי לדלל ארטיפקטים מקומיים, בעוד ש-Aggregation המשמר מידע של מקטעים מסוימים עשוי לשמרם. המאמר אינו מוכיח יתרון של שיטת Pooling אחרת עבור נתוני הקורס, ולכן זוהי אפשרות לניתוח או Ablation עתידי, ולא מסקנה מוכחת.

האיזון בין שני הכיוונים אינו נפתר באופן חד-משמעי בספרות שנסקרה. הוא מצריך הערכה אמפירית הבוחנת לא רק את איכות הסיווג אלא גם את סוג המידע שעליו מתבססות החלטות המודל.

9. מדדי הערכה ותקפות המתודולוגיה

Equal Error Rate 9.1

EER הוא מדד מרכזי במחקרי Speech Anti-Spoofing. הוא מתקבל בנקודת סף שבה שיעור הדוגמאות המזויפות המתקבלות בטעות ושיעור הדוגמאות האמיתיות הנדחות בטעות משתווים.

ערך EER נמוך יותר מצביע על יכולת הבחנה טובה יותר בין המחלקות במסגרת קבוצת ההערכה הנתונה.

יתרונו של המדד בכך שהוא מבוסס על ציוני המודל ועל בחינת ספים שונים, ולא על Accuracy בסף החלטה יחיד. עם זאת, EER אינו מספק לבדו מידע מלא על עלויות השגיאות ביישום מסוים או על איכות כיול הציונים.

לצורך המחקר הנוכחי, נדרשת מוסכמת ציונים אחידה: ערך Score גבוה יותר צריך להעיד על סבירות גבוהה יותר לזיוף. במודלים שבהם ציון גבוה יותר מייצג דיבור אמיתי, יש להפוך את כיוון הציון לפני חישוב EER.

9.2 מדדי עלות והבדלים בין פרוטוקולים

לצד EER, הספרות עושה שימוש במדדים כגון minDCF, actDCF ו-min t-DCF. מדדים אלה נועדו להביא בחשבון עלויות החלטה, הנחות על שכיחות המחלקות או את האינטראקציה בין מנגנון Anti-Spoofing למערכת Speaker Verification.

חשוב להדגיש כי ערכי minDCF ו-min t-DCF אינם בהכרח בני-השוואה בין מחקרים המשתמשים בהגדרות שונות של פונקציית העלות ובפרוטוקולי הערכה שונים.

באופן דומה, מספרי EER שדווחו עבור ASVspoof 2019 LA, ASVspoof 2021 LA, ASVspoof 2021 DF או מאגרי CodecFake אינם מאפשרים דירוג ישיר בין המודלים כל עוד הם לא נבחנו על אותם נתונים ובאותו פרוטוקול.

9.3 הערכה לפי סוג מתקפה ומקור נתונים

EER כולל עשוי להסתיר הבדלים משמעותיים בין מתקפות. מודל מסוים עשוי לזהות היטב סוג אחד של זיופים ולהתקשות מאוד בסוג אחר, כאשר הממוצע הכולל מסתיר את הפער.

לפיכך נדרש, ככל שהנתונים מאפשרים, ניתוח נוסף לפי סוג מערכת הזיוף ולפי מקור הנתונים.

חישוב EER עבור מערכת זיוף מסוימת מחייב לכלול לצידה קבוצת דוגמאות אמיתיות מתאימה. לא ניתן לחשב EER מקבוצה המכילה רק דוגמאות מזויפות או רק דוגמאות אמיתיות.

במיוחד, **M-AILABS בתת-המאגר של הקורס מכיל Real בלבד**, ולכן לא ניתן לחשב עבורו EER עצמאי. אפשר למדוד Real Recall, שיעור דחייה שגויה בסף שנבחר מראש על Validation והתפלגות ציוני האותנטיות, בתוספת מספר הקלטות. באופן דומה, אם בודקים Generator שמופיעות בו רק דוגמאות Fake, יש לחשב Fake Recall או להגדיר במפורש קבוצת Real מתאימה כדי לחשב EER.

כאשר מספר הדוגמאות קטן, גם EER מחושב עשוי להיות רגיש למספר קטן של החלטות שגויות. לכן יש לדווח על גודל קבוצות ההערכה ולהיזהר מהסקת מסקנות חזקות מתוך תוצאות המבוססות על מעט הקלטות.

9.4 Data Leakage, Protocol Mismatch וחפיפות אימון מוקדם

יש להבחין בין שני כשלים שונים. **Data Leakage** מתרחש כאשר מידע אסור עובר מתהליכי ההערכה לאימון או לכוונון: אותה הקלטת מקור וגרסה נגזרת שלה מופיעות בחלוקות שונות; חלונות מאותו קובץ מתפזרים בין Train ל-Test; התאמת Threshold או בחירת Checkpoint נעשית על סמך Test; או שמידע

מתוויות ההערכה מגיע למודל בדרך אחרת. כאשר מקור אחד מייצר גרסאות סינתטיות רבות (כמו ב-PhonemeDF), יחידת החלוקה חייבת להתחשב במשפחת המקור.

לעומת זאת, **Protocol Mismatch** מתרחש כאשר החלוקה עצמה תקינה אך התוצאה מוצגת כראיה לטענה שלא נבחנה. לדוגמה, שימוש באותה מערכת TTS באימון ובבדיקה עשוי להיות תקף לחלוטין לניסוי *Known-Generator / Within-Distribution* אם הקבצים עצמאיים ואין חפיפות אסורות. הוא אינו מוכיח הכללה למערכת TTS שלא נראתה. באופן דומה, Speaker-Disjoint אינו מבטיח Generator-Disjoint. לכן יש להגדיר מראש לכל ניסוי את ממד ה-Shift שהוא בוחן.

סוג נוסף של אי-תלות חלקית עשוי להתקיים בין נתוני **Pre-training של Encoder מאומן מראש** לבין הקלטות ההערכה. יש לתעד את Checkpoint, מקורות Pre-training הידועים ואת ה-Provenance של הקלטות ה-Test, ככל שניתן. חשיפה לאודיו לא מתויג באימון קודם אינה בהכרח דליפת תוויות מבחן, אך היא מגבילה טענות חזקות על נתונים שלא נראו אי-פעם למערכת. היעדר אפשרות לאמת חפיפה יצוין כמגבלת מחקר.

9.5 היתכנות ותוקף פרוטוקולי ההכללה

ההבחנה העיונית בין **Leave-One-System-Out**, **Speaker-Disjoint** ו-**Cross-Dataset** מפורטת בסעיף 2.4. בפועל, תוקפו של כל ניסוי תלוי בזמינות מזהי מערכת, דובר וקובץ מקור, במספר הדוגמאות בכל תת-קבוצה, בייצוג שתי המחלקות ובהיעדר נגזרות שחוצות חלוקות. המונח המלא *Leave-One-System-Out* עדיף כאן על ראשי התיבות LOSO, העלולים להתפרש גם כ-Leave-One-Speaker-Out.

אין להניח מראש שנתוני הקורס מאפשרים בדיקה מחמירה של כל סוגי ההכללה. בדיקת EDA ו-Metadata היא תנאי מוקדם לאישור ההיתכנות; כשאין די דוגמאות או מזהי מקור תקפים, יש להקטין את היקף הטענה ולא להציג את הפרוטוקול כאילו יושם במלואו.

9.6 מדדים, ספים וניתוח שגיאות ברמות שונות

AT-ADD Track 1 [12] משתמש ב-Macro-F1, ואילו שאלת המחקר בפרויקט הקורס ממוקדת ב-EER. המדדים משלימים אך אינם שקולים: EER מחושב מסריקת ספים על ציונים רציפים, בעוד Macro-F1 משקף החלטות בסף מסוים ותלוי גם בהרכב המחלקות. לכן יש לשמור את ציוני המודל, לבחור Threshold רק על Validation ולדווח על Real/Fake Recall בנפרד. במקרה של מערכת זיוף יחידה ללא Real תואם אפשר לחשב Fake Recall, אך לא EER תקף לאותה תת-קבוצה מבלי להגדיר קבוצת Real להשוואה.

ניתוח השגיאות של AT-ADD מצא תנאים קשים כמו BigVGAN ו-Replay, ושיעורי דחייה שגויה גבוהים של דיבור Real ממקורות מסוימים. הוא גם הראה שדפוסי שגיאות משלימים אינם מבטיחים ש-Majority Voting ישפר את המודל הטוב ביותר. לפיכך השוואה מחקרית תקפה צריכה לשלב EER כולל עם דיווח לפי מאגר ומערכת זיוף, בדיקה של שגיאות Real/Fake, ומדדי אי-ודאות או רווחי סמך כאשר מספר דוגמאות ההערכה מאפשר זאת. עבור קליפים בעלי דובר או מקור משותף, רצוי לשקול Bootstrap לפי קבוצות ולא להניח אי-תלות מלאה בין כל הקבצים.

9.7 תקפות תוצאות בניסויי הרחבת נתונים

יש לשאול האם השיפור הנצפה משקף **יותר דוגמאות**, **יותר מערכות זיוף**, **יותר דוברים**, **יותר שפות**, או **שינוי של מקור/איכות ההקלטות**. משום כך, אין להשוות באופן נאיבי אימון על מאגר בסיס קטן לאימון על מאגר חיצוני גדול ולייחס את ההבדל דווקא לגיוון ה-Generator. הניסוי הנכון להפרדת ההסברים כולל, ככל האפשר, תנאי אימון מותאמים בגודל, איזון המחלקות, דוברים/מקורות שאינם דולפים, Augmentation עקבי ומספר ריצות חוזרות. התכנון המפורט יופיע במסמך B; כאן מודגש ההיגיון המחקרי והעיקרון של בידוד משתנים.

10. הקשר למחקר הנוכחי: מאגר הנתונים והאתגרים הייחודיים

10.1 הרכב נתוני הפרויקט

המחקר הנוכחי מתבסס על מאגר הכולל 1,520 הקלטות קול באורך ארבע שניות, בקצב דגימה של 16kHz ובערוץ מונו, בהתאם למפרט הקורס.

הנתונים מגיעים משלושה מקורות:

מקור	דיבור אמיתי	דיבור מזויף	סך הכול
ASVspoof 5	300	300	600
CodecFake	300	300	600
M-AILABS	320	0	320
סה"כ	**920**	**600**	**1,520**

ASVspoof 5 כולל בתת-הקבוצה שנבחרה דוגמאות TTS ו-VC ממערכות A09–A16. CodecFake כולל דיבור שעבר תהליכי קידוד ושחזור באמצעות קודקים נוירוניים, ואילו M-AILABS מכיל דיבור אמיתי בלבד, שמקורו בהקלטות ספרי שמע.

מכאן שמאגר הפרויקט אינו כולל רק שתי מחלקות, אלא גם הבדלים מהותיים בין מקורות הנתונים.

10.2 הסיכון ללמידת קיצורי דרך

היבט מתודולוגי מרכזי נובע מכך שמקור M-AILABS מיוצג באמצעות דוגמאות אמיתיות בלבד.

כתוצאה מכך, המודל עשוי ללמוד שמאפיינים המזוהים עם M-AILABS מעידים על דיבור אמיתי, במקום ללמוד מאפיינים כלליים של אותנטיות. באופן דומה, הוא עשוי ללמוד לזהות תבניות הקשורות למקור ASVspoof 5 או CodecFake ולא למנגנון הזיוף עצמו.

בעיה זו מכונה לעיתים Shortcut Learning: המודל משיג התאמה טובה לנתונים באמצעות קשרים סטטיסטיים זמינים, אך קשרים אלה אינם בהכרח משקפים את המנגנון שאותו מבקשים לזהות.

דוגמה נוספת היא שימוש במאפייני הקלטה, כגון רמת עוצמה, רעש רקע, משך שקט, רוחב פס או ארטיפקטים הקשורים לקידוד. חלק ממאפיינים אלה עשויים להיות קשורים למקור ההקלטה ולא לעצם היותה מזויפת.

לכן הצלחה על חלוקה מסוימת של נתוני הקורס לא תספיק כשלעצמה כדי להוכיח שהמודל למד מאפייני זיוף בעלי יכולת הכללה. ניתוח עקרוני מתאים יבחן את התפלגות הציונים להקלטות Real לפי מקור, Fake Recall לפי מערכת זיוף, ואת רגישות התחזיות לשקט, לעוצמה ולרוחב פס כאשר אפשר לבצע בקרות מותאמות. בדיקות כאלה יכולות לחשוף תלות בעייתית, אך אינן מוכיחות לבדן איזה מאפיין פנימי משמש את המודל להכרעה.

10.3 האתגר של One-Class Learning בנתונים אלה

מבנה המאגר יוצר הזדמנות לבחון את רעיון הלמידה החד-מחלקתית שהוצג על ידי Yin and Lei (2026) [9], אך גם ממחיש את מגבלתו.

אפשר עקרונית לאמן מסווג חריגות על דוגמאות דיבור אמיתי בלבד. אולם אם דוגמאות האימון אינן מייצגות היטב את מגוון המקורות, המודל עלול לדחות דיבור אמיתי ממקור חדש.

לדוגמה, מודל שאומן על הקלטות אמיתיות מ-ASVspoof 5 עשוי להתקשות לקבל דיבור אמיתי מ-M-AILABS, לא בשל זיוף אלא בשל הבדלי דוברים, סגנון דיבור ותנאי הקלטה.

לכן תוצאה חיובית של One-Class Learning תצטרך להתפרש לצד ניתוח ייעודי של דוגמאות הדיבור האמיתי, ולא רק על פי ה-EER הכולל.

10.4 משמעות המגבלה בגודל המאגר

מאגר בן 1,520 הקלטות קטן יחסית לכמויות הנתונים שעליהן אומנו מודלי SSL גדולים. עובדה זו אינה שוללת שימוש בלמידה עמוקה, אך היא מחזקת את החשיבות של בחירת אסטרטגיית האימון.

אימון מודל גדול מאפס עלול להיות רגיש להתאמת יתר ולשונות בין חלוקות הנתונים. לעומת זאת, שימוש ב-Encoder מאומן מראש ומסווג פשוט מאפשר לנצל ייצוגים שנלמדו מנתוני דיבור רבים, בלי להידרש לאימון מחדש של כל רכיבי המודל.

עם זאת, גם ייצוגים קפואים יכולים לשמר מידע הקשור למקור הנתונים, ולכן אינם פותרים באופן אוטומטי את בעיית ה-Shortcut Learning.

ההחלטה על מורכבות המודל צריכה, לפיכך, להיות מבוססת על השוואה אמפירית ועל בחינת יציבות הביצועים, ולא רק על מספר הפרמטרים או על הצלחת הארכיטקטורה במחקר אחר.

10.5 מבחן התחרות לעומת ניסויי הכללה

לפי מסמך דרישות הקורס, קבוצת התחרות הסופית תידגם מאותם שלושה מאגרי נתונים. אולם אין בכך הבטחה שכל סוגי המתקפות בקבוצת המבחן יהיו חדשים ביחס לאימון.

משום כך יש להבחין בין שתי מטרות הערכה:

ביצועי תחרות: יכולת סיווג הקלטות שלא שימשו לאימון, מתוך מקורות הנתונים שהוגדרו בקורס.

יכולת הכללה מחקרית: יכולת לזהות מתקפות, מערכות או תנאים שלא נכללו באימון באופן מבוקר.

שתי המטרות חשובות, אך אינן חופפות לחלוטין. מודל יכול להגיע לתוצאה טובה בתחרות ועדיין להתקשות במתקפה חדשה, ולהפך.

מכאן נובע הצורך לבחון את שאלת ההכללה בניסוי ייעודי, גם כאשר הערכת התחרות אינה מבודדת את המשתנה הזה.

10.6 מאגרים חיצוניים כמועמדי אימון: החלטות והסתייגויות

הסקירה החדשה מוסיפה שני מאגרי אימון מועמדים, אך אינה הופכת את היקפם המלא למתווה שימוש מחייב. **MLAAD [10]** עשוי להרחיב את מספר מערכות TTS ואת מגוון השפות. דף ההפצה הציבורי מציין רישיון **CC BY-NC 4.0** לשימוש אקדמי לא מסחרי; לפני שילוב מעשי נדרש לבדוק גם את תנאי השימוש בנתוני המקור, את גרסת המאגר, את קובצי המקור ואת החפיפה האפשרית עם M-AILABS המשמש את הקורס. **PhonemeDF [11]** עשוי להוסיף דוגמאות TTS ו-VC ממערך מקבילי; נדרש אימות שהשימוש בקובצי האודיו הסינתטי מותר, ושההפרדה בין חלוקות נשמרת ברמת מקור ודובר ולא רק ברמת קובץ.

AT-ADD [12] מסווג כאן כ-*Research Paper 10*, ולא כמקור אימון חיצוני ישים: פרוטוקול ההערכה שלו חשוב, אך לא קיימת עבורנו גישה מאומתת למאגר Track 1 ותנאי השימוש בו אינם מאומתים לצורכי הפרויקט. החלטת הסיווג הזאת משמרת את ההבחנה בין מאגר שאנחנו שוקלים לשלב בפועל לבין מאמר המשמש לבניית פרוטוקול הערכה תקף.

10.7 גבולות היתכנות ותוצרי הקורס

מסמך ההנחיות דורש Baseline עם EER, השוואה של גישות נוספות, ניתוח לפי מערכת זיוף ודיון בהכללה בין מאגרים; קבוצת התחרות הסופית צפויה להידגם מאותם שלושה מקורות ולעבור עיבוד דומה. לפיכך ההערכה הרשמית בוחנת ביצועים על דוגמאות חדשות מתוך מקורות מוגדרים, בעוד ניסויי Shift מחמירים מצריכים חלוקות ייעודיות שיאושרו רק לאחר EDA של דוברים, מערכות ומקורות. אי אפשר להניח מראש היתכנות של Leave-One-System-Out, Speaker-Disjoint ו-Cross-Dataset מלאים על תת-המאגר המצומצם. מסמך A מספק הצדקה מדעית, ומסמך B יפרט את תוכנית הניסויים הישימה בהתאם לממצאי הביקורת על הנתונים.

11. הפער המחקרי העולה מן הספרות

למרות ההתקדמות במאפיינים אקוסטיים, בארכיטקטורות ייעודיות ובייצוגי SSL, קשה לעיתים להפריד בין השפעת **ייצוג הדיבור**, **פרדיגמת הלמידה** ו**הרכב נתוני האימון** על יכולת ההכללה. מחקרים מדווחים על שיפורים בתצורות מלאות שנבדקו על מאגרים שונים, אך הבדלים בנתונים, במסווג, בכוונון ובתנאי הערכה מגבילים ייחוס של שיפור לרכיב יחיד [2], [4], [7], [9], [12].

במקביל, מעבר בין מאגרים עשוי לשנות יחד את שיטת היצירה, דוברי המקור, השפה ותנאי ההקלטה. לכן מדד ביצועים חיצוני מאפשר לזהות **שקיימת בעיית הכללה**, אך אינו מראה לבדו **מדוע היא מתרחשת**. ניתוח שגיאות לפי מקור או Generator מספק אותות לאבחון, ואילו הסבר סיבתי דורש בקרות מתאימות. הקושי בולט במיוחד בנתוני הקורס, שבהם M-AILABS מספק דוגמאות Real בלבד, והפרדת המערכות והדוברים בתת-המאגר טעונה בדיקת Metadata.

הרחבת נתונים באמצעות MLAAD [10] ו-PhonemeDF [11] מעוררת שאלה משלימה: האם שיפור אפשרי נובע מעוד דוגמאות, ממגוון מערכות יצירה או משינוי במקור הדיבור? הספרות שנבחרה מצדיקה את הבדיקה, אך אינה פותרת את ההבחנה הזאת בתנאי הפרויקט שלנו. יתרה מכך, חלק מתוצאות ההכללה ב-MLAAD מתייחסות לגרסה מוקדמת ולא להיקף v11, ו-PhonemeDF מנתח בעיקר רמת פונמה ולא מוכיח שיפור EER ברמת ההקלטה.

הפער המחקרי הספציפי שלנו הוא אפוא הצורך בהשוואה מבוקרת ובהערכה מתועדת של ייצוגי דיבור ושיטות למידה תחת שינויי התפלגות שניתן להגדיר ולאמת במאגר קורס מוגבל, ובבדיקת תרומת מגוון נתוני האימון כאשר הנתונים מאפשרים בקרה מתאימה. אין כאן טענה שהשוואות כאלה לא בוצעו מעולם; זו הצדקה למחקר אמפירי ממוקד על המשימה, המגבלות והחלוקות של הפרויקט הנוכחי.

12. גזירת שאלת המחקר ותעדוף

מן הסינתזה נגזרת שאלת מחקר מרכזית:

כיצד בחירת ייצוג הדיבור, פרדיגמת הלמידה והרכב נתוני האימון משפיעים על יכולת ההכללה של גלאי זיופים קוליים למערכות ולתנאים שלא נראו באימון, במסגרת פרוטוקולי הערכה שניתן לאמת?

לצורך מיקוד, המחקר מאורגן בשלושה צירים בעלי סדר עדיפות ברור, ולא בשש משימות עצמאיות שחייבות כולן להתבצע במלואן:

RQ1 — Representation (ציר ליבה): כיצד משתנים ביצועי הזיהוי וההכללה בין מאפיינים קלאסיים (למשל MFCC/CQCC) לבין ייצוגי SSL (wav2vec 2.0/WavLM), כאשר המסווג, חלוקת הנתונים ותנאי ההשוואה נשלטים ככל שניתן?

RQ2 — Learning Paradigm (ציר ליבה): כיצד משתווה סיווג בינארי מפוקח ל-One-Class Learning על דיבור Real, כאשר נעשה שימוש בייצוג ובפרוטוקול הערכה מקבילים? ההשוואה תדווח במפורש אם הופעלו תוויות Fake לצורך Validation, Early Stopping או כיול, כדי לא להציג מערכת מכוילת באמצעות Fake כבלתי תלויה לחלוטין במחלקה זו.

RQ3 — Training Data Diversity (ציר מותנה בהיתכנות): בהינתן מספר הקלטות אימון דומה, האם חשיפה למספר גדול יותר של מערכות או משפחות TTS/VC משפרת הכללה למערכות שלא נראו באימון, מעבר להשפעת כמות הדוגמאות? בדיקת שאלה זו תלויה בגישה ורישוי, באימות מקור ההקלטות וביכולת ליצור חלוקות מספקות ללא חפיפות.

שכבת הערכה רוחבית — אינה שאלת מחקר עצמאית: לכל ציר יוגדרו מראש קבוצות הערכה ושיטות דיווח לפי הניתן לביצוע: EER כולל, מדדי Real/Fake בסף שנבחר על Validation, ניתוח לפי Dataset ו-Generator, וכן Speaker-Disjoint, Leave-One-System-Out או Cross-Dataset כאשר המזהים וכמות הדוגמאות מאפשרים זאת. עבור M-AILABS (Real בלבד) נבחן שיעורי קבלה/דחייה שגויה ולא EER עצמאי. פערי ביצועים בין דומיינים לא יפורשו כהוכחה למקור הסיבתי לכשל.

הרחבות אפשריות, לא התחייבות ליבת המחקר: Feature Fusion, שיטות Pooling הממוקדות בארטיפקטים מקומיים, Score Consistency, Fine-Tuning רחב יותר, Ensemble ומדידת עלות חישובית. הן יישקלו לפי משאבים, ממצאי EDA ותרומתן לשאלות הליבה.

המסגרת הזאת שומרת על כל הרעיונות שעלו מן המאמרים, אך מבחינה בין השערות שיש לתכנן עבורן ניסויים מחייבים לבין כיוונים אפשריים שאינם תנאי להשלמת הפרויקט.

13. מסקנות סקירת הספרות

שנים-עשר המחקרים שנסקרו מדגימים כי זיהוי זיופים קוליים נשען על שילוב של ייצוג האודיו, שיטת הלמידה, הרכב נתוני האימון ופרוטוקול ההערכה. CQCC, AASIST וייצוגי SSL מדגישים רמות שונות של מידע אקוסטי, אך אף אחת מהגישות אינה מבטיחה הכללה לכל מערכת יצירה או תנאי הקלטה. שחזור מונחה, שילוב מאפיינים ולמידה חד-מחלקתית מציעים חלופות, אך יתרונן תלוי בתנאי הניסוי ובליווי בקרות מתאימות.

ASVspoof 5, CodecFake ו-AT-ADD מציבים את תקפות ההערכה במרכז: הצלחה על מערכות מוכרות, על Generator שלא נכלל באימון, במעבר בין מאגרים או אחרי שינוי ערוץ הן טענות שונות. הבדלים בין דומיינים עשויים לחשוף חולשה, אך אינם מבודדים בהכרח את הסיבה לה. ניתוח Real/Fake בנפרד, שמירת ציונים רציפים, ספים שנבחרים רק על Validation ודיווח על מגבלות החלוקות הם תנאים לפרשנות זהירה של הממצאים.

MLAAD ו-PhonemeDF מוסיפים אפשרות להרחיב את מגוון האימון, אך מחייבים בקרה על גודל המאגר, קשרי המקור, דוברים, רישוי וחפיפות. PhonemeDF אף מעלה אפשרות שמידע פונטי מקומי נבלע באיגום גלובלי, אולם זו השערת המשך ולא תוצאה מוכחת במודל הקלטות של הפרויקט. עבור נתוני הקורס, שבהם M-AILABS מיוצג ב-Real בלבד, נדרשת התייחסות מפורשת ל-Shortcut Learning ולמגבלות המדדים שניתן לחשב לפי מקור.

לפיכך מוצעת השוואה מבוקרת בין ייצוגים אקוסטיים לייצוגי SSL ובין סיווג בינארי ללמידה חד-מחלקתית, עם בדיקה מותנית בהיתכנות של כמות נתוני אימון לעומת מגוון מתקפות. **מטרת המחקר אינה רק לצמצם EER, אלא לקבוע באילו תנאים השיפור נשמר, מה ניתן להסיק ממנו, ומה נותר לא ודאי.** מסמך B יתאר את תכנון הניסויים והבקרות שיישמו את ההיגיון המחקרי הזה.

מקורות ביבליוגרפיים

Wang, X., Delgado, H., Tak, H., Jung, J., Shim, H., Todisco, M., et al. (2024). *ASVspoof 5:* **[1]** *Crowdsourced Speech Data, Deepfakes, and Adversarial Attacks at Scale*. arXiv:2408.08739. https://arxiv.org/abs/2408.08739

Wu, H., Tseng, Y., & Lee, H.-y. (2024). *CodecFake: Enhancing Anti-Spoofing Models* **[2]** *Against Deepfake Audios from Codec-Based Speech Synthesis Systems*. Interspeech 2024. https://arxiv.org/abs/2406.07237

Todisco, M., Delgado, H., & Evans, N. (2017). *Constant Q cepstral coefficients: A spoofing* **[3]** *countermeasure for automatic speaker verification*. Computer Speech & Language, 45, 516–535. https://doi.org/10.1016/j.csl.2017.01.001

Jung, J.-w., Heo, H.-S., Tak, H., Shim, H.-j., Chung, J. S., Lee, B.-J., Yu, H.-J., & Evans, N. **[4]** (2022). *AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks*. ICASSP 2022. https://doi.org/10.1109/ICASSP43922.2022.9747766

Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for* **[5]** *Self-Supervised Learning of Speech Representations*. Advances in Neural Information Processing Systems. https://arxiv.org/abs/2006.11477

Chen, S., Wang, C., Chen, Z., Wu, Y., Liu, S., et al. (2022). *WavLM: Large-Scale Self-* **[6]** *Supervised Pre-Training for Full Stack Speech Processing*. IEEE Journal of Selected Topics in Signal Processing, 16(6), 1505–1518. https://doi.org/10.1109/JSTSP.2022.3188113

Wu, S., Cheng, Y., Wang, R., & Yan, D. (2026). *Robust Speech Forgery Detection via* **[7]** *Enhanced Forensic Trace Generation*. Signal, Image and Video Processing, 20, Article 130. https://doi.org/10.1007/s11760-026-05167-y

Izrailov, K. E., Kotenko, I. V., & Chechulin, A. A. (2026). *Intelligent Voice Fraud Detection* **[8]** *Methods in Authentication Systems*. Pattern Recognition and Image Analysis, 36(2), 391–399. https://doi.org/10.1134/S1054661826700203

Yin, J., & Lei, S. (2026). *A Novel Attack-Resistant Speech Forgery Detection Method* **[9]** *Integrating One-Class Learning and Wav2vec2*. 2026 International Conference on Communication Networks and Machine Learning (CNML), 415–419. IEEE. https://doi.org/10.1109/CNML68938.2026.11452384

Müller, N. M., Kawa, P., Choong, W. H., Casanova, E., Gölge, E., Müller, T., Syga, P., **[10]** Sperl, P., & Böttinger, K. (2024). *MLAAD: The Multi-Language Audio Anti-Spoofing Dataset*. 2024 International Joint Conference on Neural Networks (IJCNN), 1–7. היקף המאגר המעודכן בסקירה נלקח מגרסת .https://doi.org/10.1109/IJCNN60899.2024.10650962 **arXiv v11 (2026)**: https://arxiv.org/abs/2401.09512

Nallaguntla, V., Fursule, A., Kshirsagar, S., & Avila, A. R. (2026). *PhonemeDF: A Synthetic* **[11]** *Speech Dataset for Audio Deepfake Detection and Naturalness Evaluation*. Proceedings of /LREC 2026, 5905–5915. https://aclanthology.org/2026.lrec-1.469

Xie, Y., Cheng, H., Zhou, J., et al. (2026). *AT-ADD: A Benchmark and Challenge for* **[12]** *Robust and All-Type Audio Deepfake Detection*. arXiv:2608.23437v2 (15 October 2026). המאמר מתאר את ACM Multimedia 2026 Grand Challenge; אין בכך קביעה שאומת פרסום המאמר עצמו בהליכי הכנס. https://arxiv.org/abs/2608.23437

מקור להגדרת המשימה ונתוני המחקר

מסמך הנחיות הקורס, *זיהוי זיופים קוליים: אמיתי או מזויף?*, נושאים מתקדמים בלמידת מכונה, HIT, אוקטובר 2026. מקור זה משמש לתיאור מאגר הנתונים, דרישות הפרויקט ופרוטוקול ההערכה הנדרש; הוא אינו נספר כמאמר מחקרי בסקירת הספרות.

הערה על היקף הסקירה: זהו מסמך סקירה אינטגרטיבית המבוסס על שנים-עשר המאמרים שקראנו וניתחנו, שנבחרו בשל רלוונטיותם לשאלת המחקר. אין מדובר בסקירה שיטתית ממצה של כלל הפרסומים בתחום. תוצאות מספריות המובאות במסמך הן תוצאות שדווחו במחקרים המקוריים, ולא תוצאות של ניסוי שבוצע במסגרת פרויקט הקורס. שאלות המחקר והשלכותיהן על המאגר הנוכחי הן סינתזה ופרשנות מחקרית שלנו, ולא מסקנות שאומתו במשותף על ידי מחברי המאמרים.