סקירת ספרות אינטגרטיבית: זיהוי זיופים קוליים והכללה למתקפות לא מוכרות

פרויקט: Fake or Real: Voice Deepfake Detection **חוקרים:** Shlomi Hazan & Mayan Adler **מסגרת:** Advanced Topics in Machine Learning, HIT 2017–2026 **היקף הסקירה:** תשעה מאמרים מחקריים **מעמד המסמך:** מסמך יסוד מחקרי לסקירת הספרות ולגיבוש שאלת המחקר

תקציר

התפתחותן של טכנולוגיות סינתזת דיבור (Text-to-Speech), המרת קול (Voice Conversion) וקודקים נוירוניים (Neural Audio Codecs) מאפשרת לייצר הקלטות קול סינתטיות באיכות גבוהה, המאתגרות מערכות אימות קולי ומנגנוני זיהוי זיופים. אף שמודלים מתקדמים לזיהוי זיופים קוליים מציגים ביצועים גבוהים על מאגרי הערכה מוכרים, הספרות המחקרית מצביעה על קושי מתמשך בהכללה לשיטות זיוף חדשות, לדוברים שלא נראו באימון ולתנאי הקלטה שונים. קושי זה מעלה שאלה מרכזית: האם מודל לומד מאפיינים מהותיים של זיוף, או שמא הוא מסתמך על דפוסים התלויים בטכנולוגיית היצירה ובמקור הנתונים שעליהם אומן?

סקירה זו מנתחת באופן אינטגרטיבי תשעה מחקרים העוסקים בזיהוי זיופים קוליים, בייצוג דיבור ובהכללה בין מתקפות ומאגרי נתונים. המחקרים נבחנים לפי חמישה כיוונים מרכזיים: מאפיינים אקוסטיים מחושבים מראש, ארכיטקטורות עמוקות לזיהוי ארטיפקטים, ייצוגי דיבור המבוססים על Self-Supervised Learning, שיפור ייצוגים באמצעות שחזור מונחה ולמידה חד-מחלקתית (One-Class Learning). נוסף על כך נבחנים מאגרי ASVspoof 5 ו-CodecFake כמסגרות הערכה המדגישות את השונות בין מתקפות ואת מגבלות ההכללה.

מן הספרות עולה כי בחירת הייצוג, ארכיטקטורת הסיווג ופרדיגמת הלמידה משפיעות על ביצועי הזיהוי, אך לא ניתן להניח ששיפור על מאגר מסוים יישמר גם במעבר למקור נתונים או לשיטת זיוף אחרת. במיוחד, שילוב מאפיינים, שימוש במודלים מאומנים מראש ולמידת התפלגות הדיבור האמיתי מציעים כיוונים מבטיחים, אך כל אחד מהם מלווה במגבלות מתודולוגיות ובסיכוני התאמת יתר או למידת קיצורי דרך.

בהתבסס על ממצאים אלו, הסקירה מציעה לבחון את השפעת ייצוג הדיבור ופרדיגמת הלמידה על יכולת ההכללה לזיופים שלא נראו באימון, באמצעות השוואה מבוקרת של מודלים קלאסיים, ייצוגי SSL ומסווגים חד-מחלקתיים. ההערכה צריכה להבחין בין הכללה למתקפות חדשות לבין רגישות להבדלי מקור, דובר ותנאי הקלטה, תוך שימוש בפרוטוקול חלוקת נתונים עקבי ובמדדי זיהוי מתאימים.

מילות מפתח: Audio Deepfake Detection, Speech Anti-Spoofing, Generalization, Unseen Attacks, ASVspoof 5, CodecFake, CQCC, AASIST, wav2vec 2.0, WavLM, One-Class Learning, Deep SVDD, EER.

1. מבוא: בעיית זיהוי הזיופים הקוליים

מערכות זיהוי ואימות קול משמשות במגוון יישומים, ובהם אימות זהות מרחוק, מערכות בנקאיות, ממשקי משתמש קוליים ואמצעי אבטחה ביומטריים. במקביל להתקדמותן של מערכות אלו, השתפרה משמעותית יכולתן של טכנולוגיות לייצר דיבור סינתטי הדומה לדיבור אנושי. טכנולוגיות Text-to-Speech (TTS) מאפשרות יצירת דיבור מטקסט, בעוד שטכנולוגיות Voice Conversion (VC) מאפשרות לשנות מאפיינים של קול קיים תוך שימור חלק מתוכנו. התפתחויות נוספות בתחום Neural Audio Codecs מאפשרות לקודד, לשחזר ולייצר אותות דיבור באמצעות ייצוגים בדידים שנלמדו ברשתות נוירונים.

יכולות אלה מעוררות אתגר אבטחתי משמעותי: הקלטה סינתטית יכולה לשמר מאפיינים הנתפסים כאותנטיים ואף להידמות לדובר מסוים, מבלי שנוצרה באמצעות דיבור טבעי של אותו אדם. משום כך יש להבחין בין שתי משימות הקשורות זו לזו אך אינן זהות. Speaker Verification בוחנת את ההתאמה בין קול ההקלטה לזהותו הנטענת של הדובר, ואילו Speech Anti-Spoofing בוחנת אם ההקלטה עצמה אותנטית או נוצרה באמצעות מניפולציה. המחקר הנוכחי מתמקד במשימה השנייה: סיווג דיבור ל-Bona Fide ול-Spoof, ללא צורך בהכרעה על זהותו של הדובר.

אחד האתגרים המרכזיים בזיהוי זיופים הוא פער ההכללה בין נתוני האימון לבין נתוני ההערכה. מודל מפוקח עשוי ללמוד דפוסים המאפיינים מתקפות מסוימות ולהשיג שיעורי שגיאה נמוכים כאשר הוא נבדק על נתונים דומים. אולם כאשר משתנה אלגוריתם הסינתזה, הקודק, מאפייני ההקלטה או אוכלוסיית הדוברים, אותם דפוסים עשויים שלא להופיע עוד. כתוצאה מכך, ביצועי המודל עלולים להידרדר גם כאשר המשימה נשארת לכאורה זהה: הבחנה בין דיבור אמיתי למזויף.

בעיה זו נמצאת במרכזם של שני מחקרים העוסקים ישירות במאגרי הערכה ובשיטות זיוף מודרניות: ASVspoof 5 של Wang et al. (2024) [1] ו-CodecFake של Wu et al. (2024) [2]. הראשון מדגיש את השונות בתנאי הדיבור ואת האיום של מתקפות מורכבות, בעוד שהשני ממחיש כיצד מעבר למשפחת טכנולוגיות יצירה שונה עלול לחשוף מגבלות של מערכות זיהוי קיימות.

לפיכך, שאלת המחקר אינה מסתכמת בזיהוי המודל בעל שיעור השגיאה הנמוך ביותר במאגר נתון. יש לבחון גם את אופי המידע שהמודל מנצל, את מידת תלותו בדוגמאות זיוף מוכרות ואת יכולתו להבחין בין סימנים מהותיים לזיוף לבין הבדלים שאינם קשורים לאותנטיות ההקלטה.

2. מאגרי הערכה, שינויי התפלגות והאתגר של מתקפות לא מוכרות

2.1 ASVspoof 5: מעבר לתנאי זיוף והקלטה מורכבים

סדרת אתגרי ASVspoof תרמה להתפתחות תחום זיהוי הזיופים באמצעות יצירת מאגרי נתונים, פרוטוקולי הערכה ומערכות ייחוס משותפות. ASVspoof 5 מהווה התפתחות משמעותית ביחס לגרסאות קודמות, הן מבחינת מקור דוגמאות הדיבור והן מבחינת מאפייני המתקפות הנכללות במאגר (Wang et al., 2024) [1].

המאגר מבוסס על נתוני דיבור שנאספו ממספר רב של דוברים ובתנאים אקוסטיים מגוונים יותר מאלו שאפיינו מאגרים מוקדמים. לצד מתקפות TTS ו-VC, הוא כולל מנגנונים שנועדו לשפר את יכולתן של מתקפות להטעות מערכות אימות וזיהוי זיופים, לרבות שימוש במודלי Surrogate ומתקפות Adversarial. בנוסף, נתוני ההערכה כוללים תנאי דחיסה וקידוד שונים, ובכללם גם קודקים נוירוניים.

המחברים מבחינים בין שני מסלולי הערכה: Track 1 עוסק בזיהוי עצמאי של דיבור אמיתי לעומת מזויף, ו-Track 2 עוסק ב-Spoofing-Robust Automatic Speaker Verification. הבחנה זו חיונית משום ששני המסלולים בוחנים בעיות שונות, ולכן גם המדדים והפרוטוקולים אינם זהים. בפרט, המדד הראשי של Track 1 באתגר הוא minDCF, כאשר EER מדווח כמדד נוסף. במחקר הנוכחי EER נבחר כמדד המרכזי בהתאם לדרישות פרויקט הקורס, אך אין בכך כדי להפוך אותו למדד הראשי של אתגר ASVspoof 5 המקורי.

המאמר מדגיש את חשיבות ההפרדה בין דוברים ובין שיטות תקיפה במסגרת חלוקות האימון וההערכה. בפרוטוקול המקורי, מתקפות A01–A08 משויכות לחלוקת האימון, A09–A16 לחלוקת הפיתוח ו–A17–A32 לחלוקת ההערכה. הבחנה זו רלוונטית גם למחקר הנוכחי, המשתמש בתת-קבוצה של מתקפות A09–A16: עצם השימוש בתת-קבוצה זו אינו מבטיח שמתקפות הבדיקה יהיו לא מוכרות למודל. כדי לבחון הכללה למתקפות שלא נראו באימון, יש ליצור חלוקה ייעודית השומרת מערכות זיוף מסוימות מחוץ לאימון.

התרומה המרכזית של ASVspoof 5 לסקירת הספרות אינה רק הצגת מאגר מתקדם יותר, אלא חידוד הדרישה להערכה המשקפת את המורכבות של העולם האמיתי. הצלחה על דוגמאות בעלות מאפיינים מוכרים אינה מספקת ראיה ליכולת להתמודד עם כל שילוב עתידי של דובר, ערוץ הקלטה, קודק ומערכת סינתזה.

CodecFake 2.2: הכללה למשפחות זיוף חדשות

Wu et al. (2024) [2] בוחנים את יכולתן של מערכות Anti-Spoofing לזהות דיבור שנוצר באמצעות מערכות סינתזה המבוססות על Neural Audio Codecs. החוקרים מצביעים על כך שמערכות זיהוי שאומנו על מאגרי זיוף מסורתיים אינן בהכרח מותאמות לארטיפקטים המאפיינים תהליכי קידוד ושחזור נוירוניים.

לצורך המחקר נבנה מאגר CodecFake, המבוסס על שש משפחות של קודקים נוירוניים ובסך הכול 15 מודלים. היבט מתודולוגי משמעותי הוא שדוגמאות הזיוף במאגר נוצרות באמצעות תהליך Codec Resynthesis: קידוד של דיבור קיים לייצוג בדיד ושחזורו באמצעות מפענח הקודק. תהליך זה מאפשר לבחון את ההשפעה של מנגנון הקידוד והשחזור עצמו, מבלי להיות תלויים בכל רכיביה של מערכת TTS מלאה.

החוקרים משתמשים בנתוני VCTK, תוך הפרדה בין דוברים בקבוצות האימון, הפיתוח והבדיקה. בהמשך נבחנים מודלים שאומנו על תת-קבוצות CodecFake שונות, ונבדקת יכולת ההכללה שלהם בין משפחות קודקים וביחס להקלטות שנוצרו באמצעות מערכות סינתזה אחרות. ממצאי המחקר מצביעים על ירידה

משמעותית בביצועי מערכות שאומנו על ASVspoof 2019 LA כאשר הן נבחנות על דוגמאות CodecFake. מנגד, אימון באמצעות נתונים הכוללים שחזורי Codec מסוימים משפר את יכולת הזיהוי של חלק ממערכות הסינתזה המבוססות על קודקים.

כך, למשל, החוקרים מדווחים על EER של 0.40% בזיהוי דוגמאות VALL-E עבור מודל שאומן בתנאי CodecFake מסוים. עם זאת, תוצאה זו מתייחסת לתצורה ניסויית מוגדרת ואינה מייצגת את הביצועים של כל מודלי CodecFake או את יכולת ההכללה לכל מתקפה המבוססת על .Codec

מבחינה מחקרית, CodecFake מדגיש הבדל בין הכללה בתוך משפחת זיופים לבין הכללה בין משפחות זיוף. מודל עשוי לזהות בהצלחה שחזורים שנוצרו באמצעות קודק מוכר, אך להתקשות בזיהוי שחזורים ממערכת בעלת מנגנון קידוד שונה. מכאן נובע שלא מספיק לדווח על EER כולל; יש לבחון כיצד התוצאות משתנות בהתאם לסוג מערכת הזיוף.

2.3 שלושה היבטים שונים של הכללה

שילוב ממצאי ASVspoof 5 ו-CodecFake מאפשר להבחין בין שלושה סוגים של שינויי התפלגות:

הכללה בין מתקפות (Attack Generalization): יכולת המודל לזהות שיטות TTS, VC או מערכות זיוף שלא נכללו באימון.

הכללה בין מאגרים (Cross-Dataset Generalization): יכולת לשמור על ביצועים כאשר משתנה מקור הנתונים, לרבות מאפייני דוברים, תוכן ותנאי הקלטה.

עמידות לשינויי ערוץ וקידוד (Channel and Codec Robustness): יכולת להבחין בין מאפייני זיוף לבין שינויים הנוצרים עקב דחיסה, שינוי רוחב פס או עיבוד האות.

שלושת ההיבטים קשורים זה לזה, אך אינם שקולים. כאשר מודל מציג ירידה בביצועים במעבר ממאגר אחד לאחר, לא ניתן לייחס אותה באופן אוטומטי למתקפות חדשות בלבד. ייתכן שחלק מהירידה נובע מהבדלי מקור שאינם קשורים ישירות לזיוף.

הבחנה זו מהווה בסיס מרכזי לגיבוש פרוטוקול הערכה תקף במחקר הנוכחי.

3. מאפיינים אקוסטיים קלאסיים: בין יעילות חישובית לרגישות למתקפות

3.1 ייצוג אקוסטי כאמצעי לזיהוי ארטיפקטים

גישות מוקדמות לזיהוי זיופים קוליים הסתמכו במידה רבה על חילוץ מאפיינים אקוסטיים מחושבים מראש (Handcrafted Features), כגון MFCC, LFCC ו-CQCC, ולאחר מכן על שימוש במסווגים סטטיסטיים כדוגמת .Gaussian Mixture Models

הנחת היסוד של גישות אלו היא שתהליכי סינתזה והמרת קול עלולים להשאיר באות הדיבור סימנים ספקטרליים או זמניים המבדילים אותו מדיבור טבעי. בחירה מתאימה של ייצוג אקוסטי עשויה להבליט סימנים אלה גם כאשר הם אינם ניכרים בהאזנה רגילה.

יתרונם של מאפיינים קלאסיים הוא היותם מוגדרים באמצעות תהליך חישובי ידוע, הניתן לשחזור ולניתוח. הם יכולים לשמש בסיס למודלים פשוטים יחסית, ולפיכך הם מתאימים במיוחד לניסויי Baseline שמטרתם לבחון באופן מבוקר את התרומה של שלבי חילוץ המאפיינים ושל המסווגים.

עם זאת, מאפיינים המוגדרים באמצעות נוסחה קבועה מגבילים את סוגי המידע הנשמרים בייצוג. במצב שבו מנגנון זיוף מצליח לחקות היטב מאפיינים מסוימים של דיבור אמיתי, מסווג המבוסס על אותם מאפיינים עלול שלא להבחין במניפולציה.

CQCC 3.2 וחשיבות הרזולוציה הספקטרלית

Todisco, Delgado and Evans (2017) [3] מציעים שימוש ב-Constant Q Cepstral Coefficients (CQCC) לזיהוי מתקפות נגד מערכות אימות דובר. השיטה משלבת Constant-Q Transform עם עיבוד Cepstral, במטרה לשמר מידע ספקטרלי המתאים לזיהוי ארטיפקטים הנוצרים במתקפות זיוף.

בניגוד לניתוח המבוסס על חלוקת תדרים ליניארית, Constant-Q Transform משתמש בחלוקה לוגריתמית של תחום התדרים, המאפשרת רזולוציית תדר גבוהה יותר בתדרים נמוכים ורזולוציה זמנית גבוהה יותר בתדרים גבוהים. מאפיינים אלה עשויים לספק רגישות לתבניות שלא נשמרות באותו אופן בייצוגים אקוסטיים אחרים.

המחברים בוחנים את CQCC בשלושה מאגרים הכוללים תרחישי זיוף שונים: ASVspoof 2015, AVspoof ו-RedDots Replayed. מעבר להדגמת יעילותו של הייצוג, המחקר מציג תובנה חשובה לגבי הכללה: תצורות CQCC המתאימות למאגר או לסוג מתקפה מסוים אינן בהכרח התצורות המתאימות ביותר למאגר אחר.

לכן תרומתו של CQCC למחקר הנוכחי אינה רק בהצעת מאפיין אקוסטי נוסף, אלא בהמחשת החשיבות של בחירת ייצוג בהתאם לאופי המתקפות ולתנאי ההערכה. העובדה שמאפיין מסוים משיג ביצועים טובים בתרחיש מוגדר אינה מבטיחה שהוא יהיה עמיד בפני שינוי התפלגות.

Feature Fusion 3.3 ושילוב מודלים סטטיסטיים ונוירוניים

כיוון נוסף מוצג על ידי Izrailov, Kotenko and Chechulin (2026) [8], המציעים מערכת לזיהוי זיופים קוליים בסביבת אימות ביומטרי באמצעות שילוב MFCC, Perceptual Linear Prediction (PLP), GMM–UBM ורשת CNN.

ההיגיון בשיטה הוא שמאפיינים אקוסטיים שונים עשויים לתאר היבטים משלימים של אות הדיבור. בעוד ש-MFCC מבוסס על ניתוח המעטפת הספקטרלית בסולם Mel, PLP משלב הנחות הקשורות לתפיסה שמיעתית ול-Linear Predictive Coding. השילוב נועד לאפשר זיהוי של תבניות שלא בהכרח מיוצגות היטב באמצעות סוג מאפיינים יחיד.

GMM–UBM משמש למידול סטטיסטי של התפלגות המאפיינים, ואילו ה-CNN מיועד ללמוד קשרים בתוך הייצוג המשולב. על ASVspoof 2019 LA החוקרים מדווחים על EER של 4.79% עבור הגישה ההיברידית, לעומת 6.27% עבור CQCC+GMM ו-7.44% עבור LFCC+GMM. בניסוי נוסף על נתוני TED-LIUM דווח על EER של כ-5.1%, בתנאי הערכה מוגבלים יותר.

תוצאות אלו מצביעות על פוטנציאל לשיפור באמצעות שילוב מאפיינים וגישות סיווג. עם זאת, המאמר אינו כולל ניסויי Ablation המבודדים באופן מלא את תרומת MFCC, PLP, GMM–UBM וה-CNN. מכאן שאין להסיק כי הוספת PLP לבדה היא הגורם לשיפור או ש-CNN מורכב בהכרח עדיף על מסווג פשוט באותו מרחב מאפיינים.

נוסף על כך, המאמר מציע מסגרת קבלת החלטות בעלת ארבע קטגוריות, המשלבת בין אימות דובר לבין רמות שונות של חשד לזיוף, בעוד שטבלת התוצאות המרכזית אינה מציגה הערכה נפרדת של כל ארבע הקטגוריות. לכן יש להבחין בין תיאור המערכת המוצעת לבין היקף הראיות הניסויות התומכות בה.

3.4 מסקנה אינטגרטיבית: בחירת ייצוג לפני הגדלת מורכבות

ממצאי CQCC והגישה ההיברידית מציעים שני כיוונים משלימים. הראשון מדגיש את חשיבותם של מאפיינים אקוסטיים בעלי תכונות שונות, והשני מציע לשלב מאפיינים ומודלים כדי לנצל מידע משלים.

עם זאת, שני הכיוונים אינם מוכיחים שהגדלת מספר המאפיינים או מורכבות המערכת מובילה בהכרח לשיפור. שילוב מאפיינים עשוי גם להגדיל את ממד הנתונים, להוסיף מידע כפול או להגביר רגישות למאפיינים לא רלוונטיים.

בהקשר של מאגר אימון מוגבל, יש הצדקה מחקרית להתחיל במודלים פשוטים עם מספר מצומצם של מאפיינים, ולבחון באופן מבוקר האם תוספת מידע באמת משפרת את הביצועים ואת ההכללה.

4. למידה עמוקה מקצה לקצה: זיהוי קשרים ספקטרליים וזמניים

מעבר לגישות המבוססות על מאפיינים מחושבים מראש, מחקרים רבים מציעים רשתות עמוקות הלומדות בעצמן ייצוגים רלוונטיים לזיהוי זיופים מתוך אות הדיבור.

אחת הגישות המרכזיות בכיוון זה היא AASIST — Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks, שהוצגה על ידי Jung et al. (2022) [4].

4.1 ארכיטקטורת AASIST

AASIST משתמשת ב-Encoder המבוסס על RawNet2 לצורך חילוץ ייצוגים מאותו דיבור, ולאחר מכן במנגנונים גרפיים המתארים קשרים בתחום הזמן ובתחום התדר.

החידוש המרכזי של המודל הוא שימוש ב-Heterogeneous Stacking Graph Attention Layer (HS-GAL), המאפשרת ללמוד קשרים בין ייצוגים זמניים וספקטרליים שונים. בכך המודל אינו מוגבל לבחינת כל תחום בנפרד, אלא יכול ללמוד קשרים בין ארטיפקטים המופיעים במיקומים שונים לאורך ההקלטה ובתחומי תדר שונים.

בנוסף, המודל כולל Max Graph Operation (MGO), המשלב שתי זרועות עיבוד באמצעות פעולת Maximum, ומנגנון Readout המשתמש בין היתר ב-Stack Node לצורך איגום מידע רלוונטי לסיווג.

ההנחה המחקרית היא שזיופים שונים עשויים להשאיר סימנים באזורים שונים של האות, ולכן מנגנון Attention המסוגל להתמקד בקשרים מגוונים עשוי להיות יעיל יותר מייצוג גלובלי פשוט.

4.2 תוצאות ותרומת הרכיבים

על ASVspoof 2019 LA, המחברים מדווחים על EER של 0.83% ועל min t-DCF של 0.0275 עבור התוצאה הטובה ביותר של AASIST. חשוב לציין שהתוצאות הללו הן של הריצה הטובה ביותר, בעוד שהממוצעים שדווחו על פני שלושה Seeds הם EER של 1.13% ו-min t-DCF של 0.0347.

החוקרים מציגים גם גרסה קלת משקל, AASIST-L, הכוללת כ-85 אלף פרמטרים ומשיגה EER של 0.99% בריצה הטובה ביותר. ממצא זה מדגים כי ניתן להשיג ביצועים תחרותיים באמצעות ארכיטקטורה קומפקטית יחסית, אם כי מספר פרמטרים קטן אינו שקול בהכרח לעלות חישובית נמוכה בכל סביבת חומרה.

בניסויי Ablation נמצא כי להסרת רכיבי HS-GAL, MGO או מנגנון ה-Readout קיימת השפעה שלילית על הביצועים, כאשר מנגנון ה-Heterogeneous Attention הציג את התרומה המשמעותית ביותר מבין הרכיבים שנבחנו.

4.3 מגבלות ההכללה של ארכיטקטורה ייעודית

למרות הישגיה, ההערכה המרכזית במאמר AASIST מתבצעת על ASVspoof 2019 LA. תוצאות אלו אינן מעידות לבדן על יכולת לזהות מתקפות עדכניות יותר, ובפרט זיופים המבוססים על Neural Audio Codecs.

בהקשר זה, ממצאי CodecFake [2] משמעותיים במיוחד: הם מצביעים על כך שמודלים בעלי ביצועים חזקים על מאגר ASVspoof 2019 LA עלולים להציג ירידה ניכרת כאשר הם נבחנים על זיופים ממשפחת Codec שונה.

שילוב שני המחקרים מלמד כי ארכיטקטורה המסוגלת ללמוד קשרים ספקטרליים וזמניים מורכבים אינה חסינה בהכרח מפני שינוי בהתפלגות המתקפות. איכות ייצוג הארטיפקטים היא גורם חשוב, אך גם המגוון והמאפיינים של נתוני האימון עשויים לקבוע אילו ארטיפקטים המודל לומד לזהות.

לפיכך, AASIST משמשת בסקירה זו כדוגמה לארכיטקטורה עמוקה ייעודית בעלת יכולות הבחנה גבוהות, אך לא כהוכחה ליכולת הכללה בלתי מוגבלת.

5. Self-Supervised Learning: ייצוגי דיבור מאומנים מראש כחלופה לאימון מאפס

גישה נוספת להתמודדות עם מגבלות נתונים היא שימוש במודלי דיבור שעברו Pre-training על כמויות גדולות של אודיו לא מתויג.

בניגוד למודלים המאמנים את כל רכיבי הייצוג ישירות על מאגר הזיופים, Self-Supervised Learning (SSL) מאפשר ללמוד מאפייני דיבור כלליים, ולאחר מכן להשתמש בייצוגים שנלמדו לצורך משימות נוספות.

5.1 wav2vec 2.0: למידת ייצוגים באמצעות משימה ניגודית

Baevski et al. (2020) [5] מציגים את wav2vec 2.0, ארכיטקטורה ללמידת ייצוגי דיבור מתוך Raw Waveform.

המודל משלב Convolutional Feature Encoder, Transformer Context Network ומנגנון Quantization המשמש בשלב האימון העצמי. במהלך Pre-training מוסתרים מקטעים מתוך הייצוג הרציף, והמודל נדרש לזהות את הייצוג הבדיד המתאים באמצעות Contrastive Learning, תוך הבחנה בין הייצוג הנכון לבין דוגמאות שליליות.

אופן אימון זה מאפשר למודל ללמוד ייצוגים המתארים קשרים זמניים והקשריים בדיבור, בלי להזדקק לתמלול עבור כל הקלטה במהלך ה-Pre-training.

המחברים מדגימים את יעילות השיטה בעיקר במשימות Automatic Speech Recognition (ASR), לרבות מצבים שבהם קיימת כמות מוגבלת של נתונים מתויגים. עם זאת, המדדים המרכזיים במאמר, כגון Word Error Rate (WER), אינם מדדים לזיהוי זיופים קוליים.

לכן תרומתו של wav2vec 2.0 למחקר הנוכחי היא בהצגת מנגנון יעיל ללמידת ייצוגי דיבור מאומנים מראש, ולא בהוכחה ישירה לכך שייצוגים אלה מזהים זיופים טוב יותר ממאפיינים אקוסטיים אחרים.

5.2 WavLM: הרחבת ייצוגי הדיבור למשימות מגוונות

Chen et al. (2022) [6] מציגים את WavLM, מודל SSL שנועד להפיק ייצוגים המתאימים למגוון רחב של משימות עיבוד דיבור, ולא רק לזיהוי התוכן המילולי.

המודל משלב Masked Speech Prediction עם Denoising במהלך ה-Pre-training, ומשתמש ב-Gated Relative Position Bias לצורך מידול קשרים זמניים. גרסת WavLM Large אומנה על כ-94 אלף שעות של אודיו ממקורות שונים.

אחד ההיבטים המרכזיים במחקר הוא ההבחנה בין סוגי המידע הקיימים בייצוגי דיבור. בעוד שמשימות ASR מתמקדות בעיקר בתוכן הנאמר, משימות אחרות דורשות מידע על זהות הדובר, אינטונציה, סביבה אקוסטית או קשרים בין דוברים.

המחברים מדגימים את יעילות המודל במגוון משימות במסגרת SUPERB ובמאגרי הערכה נוספים, לרבות Speaker Verification, Speaker Diarization ו-Speech Separation.

עם זאת, תוצאות EER המופיעות במאמר עבור Speaker Verification מתייחסות לאימות זהות הדובר, ולא לסיווג דיבור אמיתי מול דיבור מזויף. אין לפרש אותן כמדדי Deepfake Detection.

5.3 הרלוונטיות של ייצוגי SSL לזיהוי זיופים

שני המחקרים מציעים אפשרות להשתמש בידע שנלמד מנתוני דיבור נרחבים לצורך משימה בעלת מאגר מתויג קטן יחסית.

מבחינה יישומית, ניתן להשתמש ב-wav2vec 2.0 וב-WavLM כ-Encoders קפואים, לחלץ מהם Embeddings ולהעביר את הייצוגים למסווג פשוט. גישה זו מאפשרת לבחון את איכות הייצוג בלי לאמן מחדש את מיליוני הפרמטרים של המודל המקורי.

עם זאת, קיים מתח בין למידת ייצוגים כלליים לבין שימור הסימנים העדינים הדרושים לזיהוי זיופים. ייצוג המתאים היטב לזיהוי תוכן דיבור או לזהות דובר אינו בהכרח משמר את אותם ארטיפקטים ספקטרליים שמעידים על סינתזה מלאכותית.

כמו כן, שכבות שונות של מודל SSL עשויות לשמר סוגי מידע שונים. לפיכך בחירת ה-Layer, שיטת ה-Pooling ואופן התאמת המסווג עשויים להשפיע על ביצועי הזיהוי.

מכאן שהשימוש ב-Pre-trained Encoder הוא השערה מחקרית סבירה, אך לא פתרון מובטח לבעיית ההכללה. תרומתו צריכה להיבחן באופן אמפירי, תחת פרוטוקול זהה לזה של שיטות ההשוואה.

6. שיפור ייצוגים באמצעות שחזור מונחה והדגשת עקבות פורנזיות

המחקרים שנסקרו עד כה מתמקדים בעיקר בבחירת ייצוג הדיבור או בארכיטקטורת הסיווג. לעומתם, Wu et al. (2026) [7] במאמר *Robust Speech Forgery Detection via Enhanced Forensic Trace Generation*, מציעים לשפר את המידע המועבר למסווג באמצעות תהליך שחזור מונחה.

6.1 הרעיון המרכזי: שחזור כדרך להדגשת מידע מבחין

החוקרים משתמשים ב-Vector-Quantized Variational Autoencoder (VQ-VAE) לצורך שחזור מאפיינים ספקטרליים, ולאחר מכן משלבים את הייצוג המשוחזר עם הייצוג המקורי.

מטרת התהליך אינה רק לשחזר נאמנה את אות הדיבור, אלא לשפר את יכולת המסווג להבחין בין דיבור אמיתי למזויף. בהתאם לכך, המודל הגנרטיבי מאומן באמצעות אותות פיקוח המגיעים מ-Encoder של מסווג זיופים שאומן מראש ופרמטריו נשארים קפואים בשלב הנחיית השחזור.

החוקרים מציעים מספר רכיבי Loss המכוונים את תהליך השחזור. True Speech Consistency Loss נועד לשמר את הקרבה בין ייצוגים של דיבור אמיתי לבין שחזוריהם, ואילו Dual-Margin Triplet Loss משתמש גם בדוגמאות מזויפות כדי להגביר את ההבחנה בין דיבור אמיתי למזויף במרחב המאפיינים.

נקודה חשובה היא שהגישה אינה One-Class Learning במובנה המלא. אף שהשחזור מכוון לדיבור אמיתי, דוגמאות זיוף משמשות כאות פיקוח במהלך האימון, ולכן השיטה מסתמכת גם על מידע מפורש לגבי המחלקה המזויפת.

6.2 תוצאות ויכולת הכללה

המחקר נבחן על ASVspoof 2019 LA ועל ASVspoof 2021 LA, באמצעות מאפיינים אקוסטיים שונים ומסווג המבוסס על ResNet.

עבור Log-Power Spectrum (LPS), המערכת המבוססת על המאפיינים המקוריים השיגה EER של 1.22% על ASVspoof 2019 LA ו-22.64% על ASVspoof 2021 LA. לאחר שילוב המאפיינים המקוריים עם השחזור המונחה, התקבלו EER של 1.02% ושל 14.04%, בהתאמה.

כלומר, השיפור על ASVspoof 2021 LA היה משמעותי יותר מהשיפור על מאגר 2019, והדגים פוטנציאל לשיפור ביצועים תחת שינוי בתנאי ההערכה.

עם זאת, השיפור לא היה אחיד בכל הייצוגים. לדוגמה, עבור CQCC התקבלה הרעה מסוימת ב-EER על ASVspoof 2019 LA לאחר הוספת תהליך השחזור, לצד שיפור על ASVspoof 2021 LA. ממצא זה מחזק את הצורך להעריך את תהליך השיפור בהתאם לייצוג ולמאגר, ולא להניח ש-Feature Reconstruction מועיל בכל מצב.

בנוסף, השיטה מוסיפה עלות חישובית ביחס למסווג המקורי. החוקרים מדווחים על עלייה ממערכת הכוללת כ-2.34 מיליון פרמטרים וכ-1.25 מיליארד MACs למערכת הכוללת כ-5.67 מיליון פרמטרים וכ-3.12 מיליארד MACs. לפיכך, שיפור ה-EER מלווה בהגדלת מורכבות המערכת.

6.3 המשמעות המחקרית

המחקר מדגים כי שיפור ביכולת הזיהוי אינו חייב לנבוע מהחלפת המסווג כולו. ניתן גם לשנות את הייצוג המועבר למסווג, במטרה להדגיש מידע הקשור לזיוף.

עם זאת, אין להסיק שהתהליך יפעל באותה מידה על מאגרי CodecFake או ASVspoof 5, שלא נבחנו ישירות במאמר. בנוסף, מכיוון שהשיטה מסתמכת על רכיבים גנרטיביים ועל פונקציות אובדן נוספות, יש לבחון את היחס בין תרומתה לביצועים לבין העלות והמורכבות שהיא מוסיפה.

בהקשר של המחקר הנוכחי, שיטה זו מספקת כיוון אפשרי להרחבה עתידית, אך אינה מחייבת מימוש בשלב הראשוני של המחקר.

7. One-Class Learning: מידול הדיבור האמיתי במקום למידת מתקפות מוכרות

הגישות שנידונו עד כה משתמשות בעיקר בלמידה מפוקחת של ההבדל בין דיבור אמיתי למזויף, או בהדגשת מאפיינים באמצעות דוגמאות משתי המחלקות. גישה שונה מוצעת על ידי Yin and Lei (2026) [9], במאמר *A Novel Attack-Resistant Speech Forgery Detection Method Integrating One-Class Learning and Wav2vec2*.

7.1 שינוי פרדיגמת הלמידה

המחברים טוענים כי אחד הגורמים לפגיעה בהכללה הוא תלות בדוגמאות זיוף מתויגות, המייצגות רק חלק מהטכנולוגיות האפשריות. כדי להתמודד עם מגבלה זו, הם מציעים ללמוד את ההתפלגות של דיבור אותנטי בלבד, ולהגדיר דוגמאות החורגות ממנה כחשודות.

השיטה מבוססת על Deep Support Vector Data Description (Deep SVDD), שבמסגרתו רשת נוירונים ממפה דוגמאות אמיתיות למרחב ייצוגים ולומדת אזור קומפקטי סביבן. האזור מיוצג באמצעות Hypersphere, והמרחק ממרכזו משמש בסיס לציון החריגה של הקלטה חדשה.

יתרונה האפשרי של גישה זו הוא שהמודל אינו נדרש ללמוד את המאפיינים הייחודיים של כל טכנולוגיית זיוף. במקום זאת, הוא בוחן אם ההקלטה תואמת את התפלגות הדיבור האמיתי שנלמדה באימון.

7.2 שילוב Deep SVDD עם wav2vec 2.0

המערכת המוצעת משתמשת בייצוגי wav2vec 2.0 Base ובמאפייני LFCC. רשתות משנה הכוללות רכיבי Bi-LSTM ו-LCNN מפיקות ייצוגים המשמשים ללמידת גבולות Deep SVDD.

בנוסף, החוקרים מציעים מנגנון Weighted Fusion המשלב ציונים של ארבע רשתות משנה. משקלי השילוב נבחרים באמצעות Optuna, במטרה להפחית EER על קבוצת Validation.

באופן זה המחקר משלב שני רעיונות שונים: שימוש בייצוגי דיבור מאומנים מראש, ושינוי של פרדיגמת הסיווג מלמידה בינארית ללמידת חריגות.

7.3 תוצאות על מתקפות מוכרות ולא מוכרות

המחברים מדווחים על EER של 2.13% על ASVspoof 2019 LA ושל 6.89% על ASVspoof 2021 DF.

לשם השוואה, מודל wav2vec 2.0 עם מסווג בינארי מפוקח השיג EER של 2.35% על ASVspoof 2019 LA ושל 18.45% על ASVspoof 2021 DF.

התוצאות מצביעות על יתרון בולט של המערכת המשולבת על קבוצת ההערכה של ASVspoof 2021 DF, בהתאם לפרוטוקול המדווח.

עם זאת, יש להבחין בין תוצאה זו לבין הוכחה כללית לעדיפות של One-Class Learning. השיטה המוצעת אינה שונה מהמסווג הבינארי רק בפרדיגמת הלמידה; היא כוללת גם מספר רשתות משנה, שילוב ציונים ואופן ייצוג שונה. לכן אי אפשר לייחס את כל השיפור ל-Deep SVDD בלבד.

נוסף על כך, המעבר בין ASVspoof 2019 LA ל-ASVspoof 2021 DF כולל שינוי במאגר ובתנאי ההערכה, ולא רק החלפה של סוג המתקפה. לפיכך, הממצא מהווה ראיה מסוימת ליכולת להתמודד עם נתוני הערכה שונים, אך אינו מבודד באופן מלא הכללה למתקפות חדשות.

7.4 מגבלות מתודולוגיות של השיטה

המאמר מציג את השיטה ככזו שאינה דורשת דוגמאות זיוף מתויגות. אולם לצד אימון Deep SVDD על דיבור אמיתי, המחברים מתארים שימוש ב-EER לצורך Early Stopping ולבחירת משקלי ה-Fusion באמצעות Optuna.

מאחר שחישוב EER במשימת זיהוי זיופים דורש דוגמאות מתויגות משתי המחלקות, התיאור אינו מבסס במלואו את הטענה שהמערכת השלמה אינה תלויה כלל בדוגמאות זיוף. יש להבחין בין אימון מסווג החריגות עצמו לבין תהליך בחירת המודל וההיפר-פרמטרים.

כמו כן, בטבלת ה-Ablation של המאמר קיימות אי-התאמות בין שמות התצורות לבין הערכים וההסברים המילוליים. אי-התאמות אלה מגבילות את האפשרות לייחס בצורה מדויקת את השיפור לכל רכיב.

7.5 חריגה מההתפלגות אינה בהכרח זיוף

המגבלה העקרונית החשובה ביותר של One-Class Learning נובעת מן ההבחנה בין זיהוי חריגה לבין זיהוי זיוף.

הקלטה אמיתית עשויה להיות חריגה מהנתונים שעליהם אומן המודל בשל הבדלי דובר, שפה, מיקרופון, רעש רקע או מקור הנתונים. במקרה כזה המודל עלול לזהות דיבור אותנטי כזיוף.

מנגד, זיוף איכותי במיוחד עשוי להפיק ייצוג דומה מספיק להתפלגות הדיבור האמיתי, ולכן לא להתגלות כחריגה.

מכאן שהצלחת One-Class Learning תלויה לא רק באיכות גבול ההחלטה, אלא גם במידת הייצוגיות של דוגמאות הדיבור האמיתי ובאופן שבו מרחב המאפיינים מבדיל בין שינויים טבעיים לבין ארטיפקטים של זיוף.

לכן שיטה זו מחייבת הערכה ייעודית של שיעור הדחייה השגויה של דיבור אמיתי, במיוחד כאשר ההקלטות מגיעות ממקורות שונים.

8. סינתזה השוואתית של כיווני המחקר

המחקרים שנסקרו מייצגים גישות שונות לזיהוי זיופים ולהתמודדות עם בעיית ההכללה. ההבדלים ביניהם אינם מסתכמים בארכיטקטורה או במספר הפרמטרים, אלא נוגעים לשאלה איזה מידע נחשב רלוונטי לזיוף וכיצד המודל לומד להשתמש בו.

8.1 מפת המחקרים

מחקר	תרומה מרכזית	ראיות להכללה	מגבלה משמעותית
ASVspoof 5 [1]	מאגר ופרוטוקול הכוללים מתקפות ותנאים מגוונים	חלוקות מתקפה, דובר וערוץ	אינו מוכיח הכללה של מודל מסוים
CodecFake [2]	מאגר זיופים מבוססי Neural Codecs	Cross-Codec ו--Cross Dataset	הביצועים תלויים במשפחת ה-Codec ובתצורת האימון
CQCC [3]	ייצוג ספקטרלי בעל רזולוציה משתנה	הערכה במספר מאגרים	רגישות הייצוג לסוג המתקפה ולתנאי ההערכה
AASIST [4]	למידה עמוקה של קשרים ספקטרליים וזמניים	ביצועים חזקים על ASVspoof 2019 LA	הכללה למתקפות Codec חדשות אינה מובטחת
wav2vec 2.0 [5]	ייצוגי דיבור באמצעות SSL	הכללה למשימות ASR עם מעט תוויות	אין הוכחה ישירה לזיהוי זיופים במאמר המקורי
WavLM [6]	SSL למגוון משימות דיבור	ביצועים במשימות דיבור שונות	מדדי Speaker Verification אינם Spoof EER
Enhanced Forensic Trace [7]	שחזור ספקטרלי מונחה לצורך הדגשת ארטיפקטים	שיפור על ASVspoof 2021 LA	מורכבות נוספת ושיפור שאינו אחיד בין מאפיינים
Intelligent Voice Fraud [8]	שילוב MFCC, PLP, GMM–UBM ו-CNN	הערכה נוספת על TED-LIUM	היעדר Ablation ופירוט מימוש מלא
One-Class + wav2vec 2.0 [9]	מידול דיבור אמיתי באמצעות Deep SVDD	ביצועים משופרים על ASVspoof 2021 DF	רגישות ל-Domain Shift ואי-בהירות בפרוטוקול הכוונון

הטבלה משמשת להשוואה מושגית ומתודולוגית בין המחקרים. היא אינה מהווה דירוג ביצועים מספרי, מכיוון שהמאמרים נבדקו על מאגרים, משימות ופרוטוקולים שונים.

8.2 ארבע תובנות משותפות

ראשית, בחירת הייצוג משפיעה על יכולת זיהוי הזיופים. CQCC מדגים את חשיבות המבנה הספקטרלי, AASIST לומד קשרים זמניים וספקטרליים ו-SSL מספק ייצוגי דיבור מאומנים מראש. אולם אף אחד מהייצוגים אינו מבטיח לבדו עמידות לכל סוגי המתקפות.

שנית, שיפור ביכולת ההבחנה אינו שקול בהכרח לשיפור בהכללה. מודל עשוי להשיג EER נמוך על מאגר מוכר, אך להציג ירידה משמעותית כאשר משתנה מנגנון יצירת הזיוף. ממצאי CodecFake מדגימים בעיה זו באופן ישיר.

שלישית, קיימות דרכים שונות לצמצום התלות בדוגמאות זיוף מוכרות. שימוש בייצוגי SSL מבקש לנצל ידע שנלמד מדיבור בהיקף רחב, שחזור מונחה מבקש להדגיש מידע מבחין, ו-One-Class Learning מבקש להגדיר את תחום הדיבור האמיתי במקום ללמוד את כל צורות הזיוף.

רביעית, התועלת של מורכבות נוספת אינה מובטחת. Feature Fusion, VQ-VAE ו-Multi-Model Fusion עשויים לשפר ביצועים, אך גם להגדיל עלות חישובית, רגישות לכוונון והסיכון להתאמת יתר. כדי לקבוע את ערכם יש לבחון את תרומתם באמצעות ניסויים מבוקרים, ולא להסתמך רק על הביצועים הכוללים של מערכת מורכבת.

8.3 המתח בין ייצוג עשיר לבין ייצוג עמיד

אחת התובנות העולות מן הסינתזה היא שקיים מתח אפשרי בין העשרת ייצוג הדיבור לבין הפחתת רגישותו לשונות שאינה קשורה לזיוף.

ייצוג עשיר עשוי לשמר יותר פרטים, ובהם ארטיפקטים עדינים הנוצרים בתהליכי סינתזה. אולם הוא עשוי לשמר גם מידע על דובר, שפה, ערוץ הקלטה או מקור המאגר. אם המודל נשען על מידע זה, שיפור הביצועים על נתוני האימון אינו מבטיח יכולת הכללה.

מצד שני, ייצוג שמטרתו ללמוד תכונות כלליות ועמידות לשינויי סביבה עשוי לדכא חלק מהפרטים האקוסטיים הדרושים להבחנה בין דיבור טבעי למזויף.

האיזון בין שני הכיוונים אינו נפתר באופן חד-משמעי בספרות שנסקרה. הוא מצריך הערכה אמפירית הבוחנת לא רק את איכות הסיווג אלא גם את סוג המידע שעליו מתבססות החלטות המודל.

9. מדדי הערכה ותקפות המתודולוגיה

Equal Error Rate 9.1

EER הוא מדד מרכזי במחקרי Speech Anti-Spoofing. הוא מתקבל בנקודת סף שבה שיעור הדוגמאות המזויפות המתקבלות בטעות ושיעור הדוגמאות האמיתיות הנדחות בטעות משתווים.

ערך EER נמוך יותר מצביע על יכולת הבחנה טובה יותר בין המחלקות במסגרת קבוצת ההערכה הנתונה.

יתרונו של המדד בכך שהוא מבוסס על ציוני המודל ועל בחינת ספים שונים, ולא על Accuracy בסף החלטה יחיד. עם זאת, EER אינו מספק לבדו מידע מלא על עלויות השגיאות ביישום מסוים או על איכות כיול הציונים.

לצורך המחקר הנוכחי, נדרשת מוסכמת ציונים אחידה: ערך Score גבוה יותר צריך להעיד על סבירות גבוהה יותר לזיוף. במודלים שבהם ציון גבוה יותר מייצג דיבור אמיתי, יש להפוך את כיוון הציון לפני חישוב EER.

9.2 מדדי עלות והבדלים בין פרוטוקולים

לצד EER, הספרות עושה שימוש במדדים כגון minDCF, actDCF ו-min t-DCF. מדדים אלה נועדו להביא בחשבון עלויות החלטה, הנחות על שכיחות המחלקות או את האינטראקציה בין מנגנון Anti-Spoofing למערכת Speaker Verification.

חשוב להדגיש כי ערכי minDCF ו-min t-DCF אינם בהכרח בני-השוואה בין מחקרים המשתמשים בהגדרות שונות של פונקציית העלות ובפרוטוקולי הערכה שונים.

באופן דומה, מספרי EER שדווחו עבור ASVspoof 2019 LA, ASVspoof 2021 LA, ASVspoof 2021 DF או מאגרי CodecFake אינם מאפשרים דירוג ישיר בין המודלים כל עוד הם לא נבחנו על אותם נתונים ובאותו פרוטוקול.

9.3 הערכה לפי סוג מתקפה ומקור נתונים

EER כולל עשוי להסתיר הבדלים משמעותיים בין מתקפות. מודל מסוים עשוי לזהות היטב סוג אחד של זיופים ולהתקשות מאוד בסוג אחר, כאשר הממוצע הכולל מסתיר את הפער.

לפיכך נדרש, ככל שהנתונים מאפשרים, ניתוח נוסף לפי סוג מערכת הזיוף ולפי מקור הנתונים.

חישוב EER עבור מערכת זיוף מסוימת מחייב לכלול לצידה קבוצת דוגמאות אמיתיות מתאימה. לא ניתן לחשב EER מקבוצה המכילה רק דוגמאות מזויפות או רק דוגמאות אמיתיות.

כאשר מספר הדוגמאות קטן, גם EER מחושב עשוי להיות רגיש למספר קטן של החלטות שגויות. לכן יש לדווח על גודל קבוצות ההערכה ולהיזהר מהסקת מסקנות חזקות מתוך תוצאות המבוססות על מעט הקלטות.

9.4 מניעת Data Leakage

תקפות ההערכה תלויה גם באופן חלוקת הנתונים.

אם הקלטות של אותו דובר מופיעות הן באימון והן בהערכה, המודל עשוי לנצל מאפייני דובר במקום ללמוד תבניות הקשורות לזיוף. באופן דומה, אם דוגמאות הקשורות לאותה מערכת יצירה או לאותו תוכן מופיעות בשתי הקבוצות, התוצאה עלולה להיות אופטימית ביחס להכללה האמיתית.

משום כך, חלוקה אקראית של הקלטות ללא התחשבות בדוברים ובמערכות זיוף אינה מספיקה לצורך בדיקת יכולת הכללה.

הקפדה על חלוקת נתונים מתאימה, על הפרדה בין אימון לכוונון ועל מניעת שימוש בנתוני המבחן לצורך בחירת מודל היא תנאי יסודי לפרשנות תקפה של התוצאות.

10. הקשר למחקר הנוכחי: מאגר הנתונים והאתגרים הייחודיים

10.1 הרכב נתוני הפרויקט

המחקר הנוכחי מתבסס על מאגר הכולל 1,520 הקלטות קול באורך ארבע שניות, בקצב דגימה של 16kHz ובערוץ מונו, בהתאם למפרט הקורס.

הנתונים מגיעים משלושה מקורות:

מקור	דיבור אמיתי	דיבור מזויף	סך הכול
ASVspoof 5	300	300	600
CodecFake	300	300	600
M-AILABS	320	0	320
סה"כ	**920**	**600**	**1,520**

ASVspoof 5 כולל בתת-הקבוצה שנבחרה דוגמאות TTS ו-VC ממערכות A09–A16. CodecFake כולל דיבור שעבר תהליכי קידוד ושחזור באמצעות קודקים נוירוניים, ואילו M-AILABS מכיל דיבור אמיתי בלבד, שמקורו בהקלטות ספרי שמע.

מכאן שמאגר הפרויקט אינו כולל רק שתי מחלקות, אלא גם הבדלים מהותיים בין מקורות הנתונים.

10.2 הסיכון ללמידת קיצורי דרך

היבט מתודולוגי מרכזי נובע מכך שמקור M-AILABS מיוצג באמצעות דוגמאות אמיתיות בלבד.

כתוצאה מכך, המודל עשוי ללמוד שמאפיינים המזוהים עם M-AILABS מעידים על דיבור אמיתי, במקום ללמוד מאפיינים כלליים של אותנטיות. באופן דומה, הוא עשוי ללמוד לזהות תבניות הקשורות למקור ASVspoof 5 או CodecFake ולא למנגנון הזיוף עצמו.

בעיה זו מכונה לעיתים Shortcut Learning: המודל משיג התאמה טובה לנתונים באמצעות קשרים סטטיסטיים זמינים, אך קשרים אלה אינם בהכרח משקפים את המנגנון שאותו מבקשים לזהות.

דוגמה נוספת היא שימוש במאפייני הקלטה, כגון רמת עוצמה, רעש רקע, משך שקט, רוחב פס או ארטיפקטים הקשורים לקידוד. חלק ממאפיינים אלה עשויים להיות קשורים למקור ההקלטה ולא לעצם היותה מזויפת.

לכן הצלחה על חלוקה מסוימת של נתוני הקורס לא תספיק כשלעצמה כדי להוכיח שהמודל למד מאפייני זיוף בעלי יכולת הכללה.

10.3 האתגר של One-Class Learning בנתונים אלה

מבנה המאגר יוצר הזדמנות לבחון את רעיון הלמידה החד-מחלקתית שהוצג על ידי Yin and Lei (2026) [9], אך גם ממחיש את מגבלתו.

אפשר עקרונית לאמן מסווג חריגות על דוגמאות דיבור אמיתי בלבד. אולם אם דוגמאות האימון אינן מייצגות היטב את מגוון המקורות, המודל עלול לדחות דיבור אמיתי ממקור חדש.

לדוגמה, מודל שאומן על הקלטות אמיתיות מ-ASVspoof 5 עשוי להתקשות לקבל דיבור אמיתי מ-M-AILABS, לא בשל זיוף אלא בשל הבדלי דוברים, סגנון דיבור ותנאי הקלטה.

לכן תוצאה חיובית של One-Class Learning תצטרך להתפרש לצד ניתוח ייעודי של דוגמאות הדיבור האמיתי, ולא רק על פי ה-EER הכולל.

10.4 משמעות המגבלה בגודל המאגר

מאגר בן 1,520 הקלטות קטן יחסית לכמויות הנתונים שעליהן אומנו מודלי SSL גדולים. עובדה זו אינה שוללת שימוש בלמידה עמוקה, אך היא מחזקת את החשיבות של בחירת אסטרטגיית האימון.

אימון מודל גדול מאפס עלול להיות רגיש להתאמת יתר ולשונות בין חלוקות הנתונים. לעומת זאת, שימוש ב-Encoder מאומן מראש ומסווג פשוט מאפשר לנצל ייצוגים שנלמדו מנתוני דיבור רבים, בלי להידרש לאימון מחדש של כל רכיבי המודל.

עם זאת, גם ייצוגים קפואים יכולים לשמר מידע הקשור למקור הנתונים, ולכן אינם פותרים באופן אוטומטי את בעיית ה-Shortcut Learning.

ההחלטה על מורכבות המודל צריכה, לפיכך, להיות מבוססת על השוואה אמפירית ועל בחינת יציבות הביצועים, ולא רק על מספר הפרמטרים או על הצלחת הארכיטקטורה במחקר אחר.

10.5 מבחן התחרות לעומת ניסויי הכללה

לפי מסמך דרישות הקורס, קבוצת התחרות הסופית תידגם מאותם שלושה מאגרי נתונים. אולם אין בכך הבטחה שכל סוגי המתקפות בקבוצת המבחן יהיו חדשים ביחס לאימון.

משום כך יש להבחין בין שתי מטרות הערכה:

ביצועי תחרות: יכולת סיווג הקלטות שלא שימשו לאימון, מתוך מקורות הנתונים שהוגדרו בקורס.

יכולת הכללה מחקרית: יכולת לזהות מתקפות, מערכות או תנאים שלא נכללו באימון באופן מבוקר.

שתי המטרות חשובות, אך אינן חופפות לחלוטין. מודל יכול להגיע לתוצאה טובה בתחרות ועדיין להתקשות במתקפה חדשה, ולהפך.

מכאן נובע הצורך לבחון את שאלת ההכללה בניסוי ייעודי, גם כאשר הערכת התחרות אינה מבודדת את המשתנה הזה.

11. הפער המחקרי העולה מן הספרות

המחקרים שנסקרו מספקים ראיות לחשיבותם של ייצוגים אקוסטיים, ארכיטקטורות עמוקות, מודלים מאומנים מראש ושיטות זיהוי חריגות. עם זאת, נותרת שאלה מעשית משמעותית לגבי היחס בין איכות ייצוג הדיבור, פרדיגמת הלמידה ויכולת ההכללה.

הספרות מצביעה על כמה מגבלות שאינן נפתרות באופן אחיד:

פער ראשון — הבחנה בין זיהוי מתקפות מוכרות להכללה למתקפות חדשות. תוצאות גבוהות במאגר מוכר אינן מבטיחות ביצועים דומים במעבר למשפחת זיופים שונה, כפי שעולה ממחקר CodecFake ומניתוחי ההכללה במחקרים נוספים.

פער שני — הקושי לבודד את תרומת הייצוג מהמסווג. מחקרים מסוימים מציגים שיפור הנובע ממערכת הכוללת מספר רכיבים חדשים, ללא ניסוי המאפשר לזהות באופן חד-משמעי את תרומתו של כל רכיב.

פער שלישי — תלות במקור הנתונים. כאשר מאגרים שונים נבדלים גם בדוברים, בתנאי ההקלטה ובשכיחות המחלקות, קשה לקבוע אם המודל למד מאפייני זיוף או מאפייני מקור.

פער רביעי — הערכת One-Class Learning. למידה חד-מחלקתית מציעה אפשרות לזהות מתקפות ללא אימון ישיר על דוגמאות זיוף, אך עשויה להיות רגישה לשונות טבעית בדיבור. בנוסף, יש להבחין בין אימון ללא תוויות זיוף לבין בחירת מודל המסתמכת על תוויות כאלה.

פער חמישי — היחס בין מורכבות ליכולת הכללה. שיטות הכוללות Reconstruction, Feature Fusion או רשתות משנה מרובות עשויות לשפר ביצועים, אך נדרשת בדיקה האם היתרון נשמר תחת פרוטוקול הוגן והאם הוא מצדיק את המשאבים הנוספים.

בהתבסס על פערים אלה, המחקר הנוכחי אינו מבקש להניח מראש שארכיטקטורה מסוימת היא הטובה ביותר. מטרתו לבחון, במסגרת מאגר הקורס, אילו מאפיינים ואסטרטגיות למידה מציגים ביצועים יציבים יותר כאשר משתנים מקור ההקלטה או שיטת יצירת הזיוף.

חשוב להדגיש שהפער המתואר הוא **פער אמפירי ומעשי ביחס לשאלת המחקר ולפרוטוקול הנתונים הנוכחי.** אין להסיק מתשעת המאמרים שהשוואות בין כל הגישות הללו מעולם לא נערכו בספרות הרחבה.

12. גזירת שאלת המחקר

מתוך הסינתזה עולה צורך לבחון בנפרד שני מרכיבים מרכזיים של מערכת לזיהוי זיופים: ייצוג הדיבור שעליו היא מתבססת ופרדיגמת הלמידה שבה היא משתמשת.

בחירת ייצוג הדיבור עשויה להשפיע על סוג הארטיפקטים שהמודל מסוגל לזהות. פרדיגמת הלמידה עשויה להשפיע על מידת תלותו בדוגמאות זיוף מוכרות ועל אופן התמודדותו עם חריגות.

לפיכך מוצעת שאלת המחקר המרכזית הבאה:

באיזו מידה בחירת ייצוג הדיבור ופרדיגמת הלמידה משפיעות על יכולתה של מערכת לזיהוי זיופים קוליים להכליל למתקפות ולמקורות נתונים שלא נכללו באימון, תחת פרוטוקול הערכה מבוקר?

משאלה זו נגזרות מספר שאלות משנה:

RQ1 — ייצוג הדיבור: כיצד נבדלים מאפיינים אקוסטיים קלאסיים, כגון MFCC ו-CQCC, מייצוגי SSL מאומנים מראש, כגון wav2vec 2.0 ו-WavLM, מבחינת ביצועי זיהוי והכללה?

RQ2 — פרדיגמת הלמידה: האם מסווג חד-מחלקתי המבוסס על דיבור אמיתי בלבד מציג יתרון על פני מסווג בינארי מפוקח בזיהוי מתקפות שלא נכללו באימון?

RQ3 — רגישות למקור הנתונים: כיצד משתנים שיעורי השגיאה כאשר עוברים בין ASVspoof 5, CodecFake ו-M-AILABS, ובאיזו מידה השינויים עשויים להעיד על תלות במאפייני מקור במקום במאפייני זיוף?

RQ4 — מורכבות מול תועלת: האם הרחבות כגון Feature Fusion או למידה של ייצוגי חריגה מורכבים משפרות את הביצועים באופן יציב המצדיק את עלותן הנוספת?

שאלות אלו אינן קובעות מראש את תוצאות המחקר. הן מספקות מסגרת מושגית שממנה ניתן לגזור השערות מדידות ופרוטוקול ניסויים בשלב תכנון המחקר.

13. מסקנות סקירת הספרות

הסקירה האינטגרטיבית של תשעת המחקרים מצביעה על התקדמות משמעותית בשיטות לזיהוי זיופים קוליים, אך גם על מגבלה מרכזית שנותרה לאורך גישות שונות: ביצועי זיהוי גבוהים בתנאי הערכה מוכרים אינם מבטיחים יכולת הכללה לתנאים חדשים.

מאפיינים אקוסטיים קלאסיים מספקים נקודת ייחוס פשוטה וניתנת לניתוח, אך יעילותם עשויה להשתנות בהתאם למאפייני המתקפה. ארכיטקטורות עמוקות כדוגמת AASIST מאפשרות ללמוד קשרים מורכבים בין אזורים זמניים וספקטרליים, אך יכולתן להתמודד עם משפחות זיוף חדשות תלויה גם בנתוני האימון.

מודלי Self-Supervised Learning, ובהם wav2vec 2.0 ו-WavLM, מציעים שימוש בייצוגי דיבור מאומנים מראש, שעשויים להיות שימושיים במיוחד כאשר היקף הנתונים המתויגים מוגבל. עם זאת, הצלחה במשימות דיבור אחרות אינה ראיה ישירה לעמידות בזיהוי זיופים.

שיטות המבוססות על שחזור מונחה או Feature Fusion מציעות להעשיר את הייצוג ולשפר את יכולת ההבחנה, אך מחייבות בחינה של תרומת הרכיבים ושל העלות החישובית הנוספת. במקביל, One-Class Learning מציע להפחית את התלות בדוגמאות זיוף מוכרות, אך מחייב התמודדות עם העובדה שחריגה מהתפלגות הדיבור האמיתי אינה בהכרח תוצאה של זיוף.

מן המחקרים עולה אפוא שאין פתרון יחיד שהוכח כעדיף בכל מאגר, משפחת מתקפות ותנאי הקלטה. מסקנה זו מחזקת את הצורך בהשוואה מבוקרת, שבה ביצועי המודלים נבחנים באותן חלוקות נתונים, תוך הפרדה בין דוברים ומערכות זיוף וניתוח שגיאות בהתאם למקור הנתונים.

בהקשר של המחקר הנוכחי, המשמעות היא שהשאיפה אינה רק להשיג EER נמוך ככל האפשר, אלא להבין **אילו מאפיינים מאפשרים למודל לזהות זיוף, באילו תנאים יכולת זו נשמרת, ומתי היא נפגעת כתוצאה משינוי בהתפלגות הנתונים**.

מכאן נגזרת הצדקה להתחיל ממודלים פשוטים וניתנים לפרשנות, להשוות אותם לייצוגי SSL ולבחון בהמשך גישות למידה חד-מחלקתיות, תוך שמירה על עקביות מתודולוגית ועל דיווח מלא של תוצאות חיוביות ושליליות.

סקירת הספרות מספקת בכך את הבסיס התיאורטי לשלב תכנון הניסויים, שבו יוגדרו ההשערות, שיטות החלוקה, מדדי ההערכה וקריטריוני ההשוואה באופן שיאפשר לבחון את שאלת ההכללה ולא רק את ביצועי הסיווג על קבוצת נתונים יחידה.

מקורות ביבליוגרפיים

Wang, X., Delgado, H., Tak, H., Jung, J., Shim, H., Todisco, M., et al. (2024). *ASVspoof 5:* **[1]** *Crowdsourced Speech Data, Deepfakes, and Adversarial Attacks at Scale*. arXiv:2408.08739. https://arxiv.org/abs/2408.08739

Wu, H., Tseng, Y., & Lee, H.-y. (2024). *CodecFake: Enhancing Anti-Spoofing Models* **[2]** *Against Deepfake Audios from Codec-Based Speech Synthesis Systems*. Interspeech 2024. https://arxiv.org/abs/2406.07237

Todisco, M., Delgado, H., & Evans, N. (2017). *Constant Q Cepstral Coefficients: A Spoofing* **[3]** *Countermeasure for Automatic Speaker Verification*. https://www.eurecom.fr/en/publication/5146

Jung, J.-w., Heo, H.-S., Tak, H., Shim, H.-j., Chung, J. S., Lee, B.-J., Yu, H.-J., & Evans, N. **[4]** (2022). *AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks*. ICASSP 2022. https://doi.org/10.1109/ICASSP43922.2022.9747766

Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for* **[5]** *Self-Supervised Learning of Speech Representations*. Advances in Neural Information Processing Systems. https://arxiv.org/abs/2006.11477

Chen, S., Wang, C., Chen, Z., Wu, Y., Liu, S., et al. (2022). *WavLM: Large-Scale Self-* **[6]** *Supervised Pre-Training for Full Stack Speech Processing*. IEEE Journal of Selected Topics in Signal Processing. https://arxiv.org/abs/2110.13900

Wu, S., Cheng, Y., Wang, R., & Yan, D. (2026). *Robust Speech Forgery Detection via* **[7]** *Enhanced Forensic Trace Generation*. Signal, Image and Video Processing, 20, Article 130. https://doi.org/10.1007/s11760-026-05167-y

Izrailov, K. E., Kotenko, I. V., & Chechulin, A. A. (2026). *Intelligent Voice Fraud Detection* **[8]** *Methods in Authentication Systems*. Pattern Recognition and Image Analysis, 36(2), 391–399. https://doi.org/10.1134/S1054661826700203

Yin, J., & Lei, S. (2026). *A Novel Attack-Resistant Speech Forgery Detection Method* **[9]** *Integrating One-Class Learning and Wav2vec2*. 2026 International Conference on Communication Networks and Machine Learning (CNML), 415–419. IEEE. https://doi.org/10.1109/CNML68938.2026.11452384

מקור להגדרת המשימה ונתוני המחקר

מסמך הנחיות הקורס, *זיהוי זיופים קוליים: אמיתי או מזויף?*, נושאים מתקדמים בלמידת מכונה, HIT, אוקטובר 2026. מקור זה משמש לתיאור מאגר הנתונים, דרישות הפרויקט ופרוטוקול ההערכה הנדרש; הוא אינו נכלל כתשיעי המאמרים המחקריים בסקירת הספרות.

הערה על היקף הסקירה: זהו מסמך סקירה אינטגרטיבית המבוסס על תשעה מקורות שנבחרו בשל רלוונטיותם לשאלת המחקר. אין מדובר בסקירה שיטתית ממצה של כלל הפרסומים בתחום. תוצאות מספריות המובאות במסמך הן תוצאות שדווחו במחקרים המקוריים, ולא תוצאות של ניסוי שבוצע במסגרת פרויקט הקורס. שאלות המחקר והשלכותיהן על המאגר הנוכחי הן סינתזה ופרשנות מחקרית שלנו, ולא מסקנות שאומתו במשותף על ידי מחברי המאמרים.