Document B — Research Synthesis & Experimental Blueprint

תוכנית מחקר וניסויים לזיהוי זיופים קוליים ולהערכת הכללה למתקפות לא מוכרות

פרויקט: Fake or Real: Voice Deepfake Detection **חוקרים:** Shlomi Hazan & Mayan Adler **מסגרת:** Advanced Topics in Machine Learning, HIT **בסיס מחקרי:** תשעה מאמרים אקדמיים, 2017–2026
גרסה: 1.0 — 2 בנובמבר 2026 **מעמד המסמך:** תכנון מחקר מוצע — לפני הערכה אמפירית

תקציר מנהלים

מטרתו של מסמך זה היא לתרגם את המסקנות שהתקבלו מסקירת הספרות האינטגרטיבית לתוכנית מחקר וניסויים ניתנת לביצוע ולשחזור עבור פרויקט זיהוי זיופים קוליים.

הבעיה המחקרית המרכזית היא יכולת ההכללה של מודלים לזיהוי זיופים קוליים למתקפות ולמקורות נתונים שלא נכללו באימון. הספרות מצביעה על כך שמודלים עשויים להציג ביצועים גבוהים בתנאי הערכה מוכרים, אך להתקשות כאשר משתנים מנגנון יצירת הזיוף, זהות הדובר, מקור ההקלטה או תנאי הערוץ.

המחקר הנוכחי יבקש לבחון שני גורמים מרכזיים העשויים להשפיע על יכולת ההכללה:

1. **ייצוג הדיבור (Feature Representation):** השוואה בין מאפיינים אקוסטיים מחושבים מראש לבין ייצוגים עמוקים שהופקו ממודלי Self-Supervised Learning.
2. **פרדיגמת הלמידה (Learning Paradigm):** השוואה בין סיווג בינארי מפוקח לבין זיהוי חריגות באמצעות One-Class Learning.

הניסויים יתבססו על 1,520 הקלטות מארבע שניות, שמקורן בשלושה מאגרים: ASVspoof 5, CodecFake ו-M-AILABS. ההערכה תתמקד במדד Equal Error Rate (EER), לצד ניתוח שגיאות לפי מקור, סוג זיוף ודובר, בהתאם לזמינות המטא-נתונים.

המחקר יתבצע בגישה מדורגת. תחילה ייבנה Baseline פשוט המבוסס על MFCC ו-Logistic Regression. בהמשך ייבחנו לפחות שתי גישות נוספות: ייצוג אקוסטי חלופי באמצעות CQCC, וייצוג SSL מאומן מראש עם מסווג קל. לאחר מכן, בהתאם לתוצאות ולמשאבים, תיבחן למידה חד-מחלקתית באמצעות One-Class SVM על אותם ייצוגי SSL.

ארכיטקטורות מורכבות יותר, כגון AASIST-L, Deep SVDD, Feature Reconstruction ו-Multi-Model Fusion, מוגדרות כאפשרויות הרחבה ולא כהתחייבויות מימוש ראשוניות.

העיקרון המנחה הוא להעדיף ניסויים המאפשרים להסיק מסקנות מחקריות תקפות על פני הגדלת מורכבות המערכת ללא בקרה. בפרט, השוואת מודלים תתבצע על חלוקות נתונים משותפות, תוך מניעת דליפה בין קבוצות, הפרדה בין בחירת מודל להערכתו והבחנה בין ביצועי סיווג כלליים לבין יכולת הכללה

אמיתית.

1. מטרת המסמך והיקפו

מסמך זה מהווה את בסיס תכנון המחקר והניסויים של הפרויקט.

הוא נועד למלא ארבעה תפקידים:

א. לקשר בין סקירת הספרות לבין המחקר האמפירי. להראות כיצד המסקנות מן המאמרים מובילות לבחירת שאלות מחקר, מודלים, מדדים וניסויים.

ב. להגדיר תהליך ניסויי תקף. לתאר מראש את אופן חלוקת הנתונים, השוואת המודלים, הערכת ההכללה ומניעת הטיות.

ג. להבחין בין ניסויי חובה להרחבות. להבטיח שהעבודה תעמוד בדרישות הקורס, בלי להתחייב מראש למימושים מורכבים שאינם נדרשים.

ד. לתמוך בשחזוריות. לתעד החלטות, גרסאות, Seeds, הגדרות אימון ותוצאות, כך שאפשר יהיה לשחזר את הממצאים ולפרש אותם באופן ביקורתי.

המסמך אינו מחליף את מחברת ניתוח הנתונים, את קוד המודלים או את דוחות ההגשה. הוא משמש תוכנית-אב שממנה ייגזרו אותם תוצרים.

1.1 הבחנה בין סוגי מידע

לשם שמירה על דיוק אקדמי, לאורך הפרויקט נבחין בין שלושה סוגי טענות:

סוג	משמעות	דוגמה
ממצא מן הספרות	נתון או טענה המדווחים במאמר מחקרי	CodecFake מצא ירידה בהכללה של מודלים מסוימים שאומנו על ASVspoof
השערת מחקר	טענה שנרצה לבדוק אך עדיין לא אומתה אצלנו	ייצוגי SSL ישפרו EER לעומת MFCC
ממצא אמפירי שלנו	תוצאה שהתקבלה מניסוי שביצענו ותיעדנו	EER של Baseline על חלוקה מוגדרת

לא נהפוך השערה לממצא ללא ניסוי, ולא נייחס למאמר מסקנות שלא נבדקו בו במפורש.

2. דרישות הקורס והקשר לתוכנית המחקר

2.1 שלבי הפרויקט

שלב	מועד	משקל	דרישות מרכזיות
Stage 1 — Review	שבוע 4	15%	סקירת ספרות, ניתוח נתונים, Baseline עם EER
Stage 2 — Experiment Design	שבוע 7	15%	שאלת מחקר, השערות, לפחות שתי גישות נוספות, פרוטוקול וסיכונים
Stage 3 — Results	שבוע 12	30%	ניסויים, השוואות, ניתוח שגיאות, דוח וקוד לשחזור
Presentation	שיעור אחרון	20%	הצגה של הבעיה, השיטה, הממצאים והמסקנות
Competition	לקראת ההצגות	20%	EER על מבחן נסתר ואיכות התהליך המחקרי

2.2 תוצרים לפי שלב

Stage 1: מסמך בן 2–3 עמודים ומחברת Notebook. הסקירה תתבסס על לפחות חמישה מקורות, ניתוח הנתונים יכלול התפלגות לפי מאגר, דובר ומערכת זיוף לצד בדיקות האזנה וספקטרוגרמות, וה-Baseline יציג EER שנמדד בפועל.

Stage 2: מסמך תכנון בן שני עמודים ופגישת משוב. עליו להציג שאלת מחקר ממוקדת, השערות, לפחות שתי גישות מעבר ל-Baseline, פרוטוקול הערכה, ניסויי הכללה, Ablations וסיכונים מתודולוגיים.

Stage 3: דוח בן 6–8 עמודים, קוד המאפשר לשחזר את התוצאות וקובץ תחרות. יידרשו השוואה הוגנת, ניתוח טעויות, דיון בהכללה ודיווח גם על תוצאות שאינן תומכות בהשערות.

המסמך הנוכחי הוא מסמך עבודה מורחב. הוא אינו כפוף בעצמו למגבלת שני העמודים של Stage 2.

3. מפת הראיות: מה תשעת המאמרים תורמים לתכנון?

מס'	מאמר	הידע המרכזי שניקח	החלטה ניסויית הנובעת ממנו
01	ASVspoof 5	הכללה, מתקפות לא מוכרות, הפרדה בין דוברים ומדדי הערכה	חלוקה מבוקרת וניתוח לפי מתקפה
02	CQCC	השפעת הבחירה בייצוג ספקטרלי על זיהוי זיופים	Baseline נוסף עם CQCC
03	AASIST	למידת קשרים זמניים וספקטרליים באמצעות Graph Attention	מועמד למודל עמוק מתקדם
04	wav2vec 2.0	למידת ייצוגי דיבור מאומנים מראש	Frozen SSL Encoder עם מסווג
05	WavLM	ייצוגי דיבור כלליים, כולל מידע הקשור לדובר ולסביבה	Encoder חלופי ל-wav2vec 2.0
06	CodecFake	קושי בהכללה לזיופים מבוססי Neural Audio Codecs	ניסויי Cross-Codec ו--Cross Dataset
07	Enhanced Forensic Trace Generation	שחזור מונחה יכול להדגיש ארטיפקטים	הרחבת Feature Reconstruction מותנית
08	Intelligent Voice Fraud Detection	שילוב מאפיינים אקוסטיים ומודלים סטטיסטיים ועמוקים	Ablation של Feature Fusion, אם ייבחן
09	One-Class Learning + wav2vec 2.0	מידול דיבור אמיתי במקום למידת מתקפות מוכרות	השוואת Binary Classification ל-One-Class

3.1 מסקנות תכנוניות

מן הספרות עולים חמישה עקרונות:

1. אין להסיק על יכולת הכללה מתוך EER נמוך על מאגר אחד בלבד.
2. בחירת מאפיינים עשויה להיות חשובה לא פחות ממורכבות המסווג.
3. ייצוגים מאומנים מראש עשויים להתאים למאגר מתויג קטן, אך תרומתם לזיהוי זיופים מחייבת בדיקה.
4. One-Class Learning מציע אפשרות לזהות מתקפות לא מוכרות, אך עלול לזהות שונות טבעית בדיבור כחריגה.
5. כל רכיב נוסף צריך להיבחן באמצעות השוואה מבוקרת, תוך התחשבות במחיר החישובי וביציבות התוצאות.

3.2 מגבלות ראייתיות שיש לשמר

AASIST: תוצאותיו החזקות על ASVspoof 2019 LA אינן מוכיחות עמידות ל-ASVspoof 5 או ל-CodecFake. בנוסף יש להבחין בין הריצה הטובה ביותר לבין ממוצע על פני Seeds.

wav2vec 2.0 ו-WavLM: ביצועי ASR או Speaker Verification אינם מדדי Anti-Spoofing. ההצדקה לשימוש בהם היא איכותם כמודלי ייצוג, לא תוצאה מוכחת מראש על המאגר שלנו.

Enhanced Forensic Trace Generation: שיפור בעקבות שחזור מונחה אינו אחיד בין סוגי המאפיינים, ומלווה בהגדלת מורכבות המערכת.

Intelligent Voice Fraud Detection: ללא Ablation מפורט לא ניתן לקבוע איזו תוספת אחראית לשיפור.

One-Class Learning + wav2vec 2.0: יש אי-בהירות בתיאור בחירת המודל באמצעות EER וקיימות אי-התאמות בטבלת ה-Ablation. לכן לא נבסס תכנון על שיוך לא מאומת של כל שיפור לרכיב מסוים.

המשמעות: מטריצת התוצאות מהספרות היא כלי לבניית השערות, לא טבלת דירוג שממנה בוחרים אוטומטית את המודל הטוב ביותר.

4. הגדרת בעיית המחקר

4.1 המשימה

המשימה היא Binary Audio Classification:

- Bona Fide — דיבור אמיתי.
- Spoof — דיבור מזויף.

בהינתן הקלטה (x), המערכת מחזירה ציון רציף $(s(x))$ המייצג עד כמה ההקלטה חשודה כמזויפת.

המוסכמה בפרויקט היא:

Score גבוה יותר = סבירות גבוהה יותר לזיוף.

הערכה תתבצע בראש ובראשונה באמצעות EER.

4.2 הבעיה שמעבר לסיווג

הבעיה המחקרית אינה רק ללמוד פונקציית סיווג המבחינה בין שתי המחלקות בנתונים נתונים.

נרצה לבדוק האם ההבחנה שנלמדה נשמרת כאשר משתנים מאפייני ההקלטות או מנגנון יצירת הזיוף.

בפרט, ננסה להבחין בין שלושה תרחישים:

- ביצועים על דוברים שלא נראו באימון, במסגרת אותם מקורות.
- ביצועים על מערכות זיוף שלא נכללו באימון.
- ביצועים על מקור נתונים אחר, הכולל שינוי אפשרי גם במאפייני הדוברים, ההקלטות והזיופים.

4.3 שאלת המחקר המרכזית

כיצד משפיעים ייצוג הדיבור ופרדיגמת הלמידה על יכולת ההכללה של מודלים לזיהוי זיופים קוליים, כאשר משתנים סוג מתקפת הזיוף או מקור הנתונים, תוך שמירה על פרוטוקול הערכה מבוקר?

זוהי שאלת-העל של המחקר. כדי לענות עליה נצמצם את הניסויים למספר השוואות מוגדרות.

4.4 שאלות משנה

RQ1 — Representation: האם ייצוגי SSL מאומנים מראש משפרים את ביצועי הזיהוי וההכללה לעומת מאפיינים קלאסיים?

RQ2 — Learning Paradigm: האם One-Class Learning מספק יתרון בזיהוי מתקפות שלא נראו באימון, בהשוואה למסווג בינארי המשתמש באותו ייצוג דיבור?

RQ3 — Domain Shift: באיזו מידה ביצועי המודלים מושפעים מהבדלי מקור ודובר שאינם קשורים ישירות לזיוף?

RQ4 — Complexity: האם שיפור שמתקבל מתוספת ייצוג, מסווג או מנגנון Fusion מצדיק את מורכבותו ואת משאביו?

לצורך השלמת דרישות הקורס בזמן, RQ1 ו-RQ2 יהיו מרכזיות, RQ3 תשמש בעיקר לבקרת תקפות ולפרשנות, ו-RQ4 תיבחן רק עבור הרחבות שימומשו בפועל.

5. נתוני המחקר

5.1 הרכב המאגר

בהתאם להנחיות הקורס:

מקור	אמיתי	מזויף	סה"כ	אופי הנתונים
ASVspoof 5	300	300	600	TTS / VC, מערכות A09–A16
CodecFake	300	300	600	שחזור וקידוד באמצעות Neural Codecs
M-AILABS	320	0	320	דיבור אמיתי מתוך ספרי שמע
סה"כ	**920**	**600**	**1,520**	

כל הקלטה אמורה להיות באורך 4 שניות, בתדר דגימה של 16kHz ובערוץ מונו.

קובץ `train.csv` אמור לכלול תווית, מקור, מזהה דובר ומערכת זיוף. לפני בניית צינור העיבוד יש לבדוק את שמות העמודות והערכים בקובץ עצמו, ולא להניח שמות שדות מראש.

5.2 מאפיינים הידועים מראש

שלושת המאגרים שונים באופי ההקלטות ובמנגנוני יצירת הזיופים.

בנוסף, M-AILABS כולל רק דוגמאות אמיתיות. עובדה זו יוצרת קשר בין מקור הנתונים למחלקה ומחייבת זהירות בהערכת המודלים.

5.3 מאפיינים שעדיין לא אומתו אמפירית

לפני קביעת החלוקות יש לבדוק:

- מספר הדוברים הייחודיים בכל מקור.
- מספר הדוגמאות לכל דובר.
- מספר הדוגמאות לכל מערכת זיוף.
- השילוב בין מקור, דובר ומחלקה.
- קיום דוברים או הקלטות המופיעים ביותר ממקור אחד.
- קיום הקלטות מקור וזיוף שהופקו מאותו משפט או מאותה הקלטה.
- התפלגות עוצמות, שקט, רוחב פס ותכונות אקוסטיות אחרות.
- תקינות התוויות ומספרי הדוגמאות.

לא נבחר מראש מספר Folds או חלוקת אחוזים סופית לפני שנדע אם מספר הדוברים והמערכות מאפשר זאת.

6. סקירת נתונים ראשונית — Data Audit

סקירת הנתונים היא חלק מחייב של Stage 1 וגם תנאי מקדים לתכנון ניסויים תקף.

6.1 בדיקות מבניות

הבדיקות הראשונות יהיו:

1. מספר ההקלטות הכולל.
2. מספר ההקלטות מכל מקור.
3. התפלגות אמיתי/מזויף.
4. מספר מערכות הזיוף והדוגמאות של כל מערכת.
5. מספר דוברים ומספר דוגמאות לדובר.
6. משך ההקלטות, Sample Rate ומספר ערוצים.
7. זיהוי קבצים פגומים, רשומות חסרות וכפילויות לפי Metadata.

6.2 בדיקות אקוסטיות

נבחן דוגמאות מייצגות של דיבור אמיתי ומזויף באמצעות האזנה והצגת Waveforms ו-Spectrograms.

לצד זאת נמדוד מאפיינים כגון RMS Energy, שיעור שקט, עוצמת שיא, DC Offset ומאפייני התפלגות אנרגיה בתדרים.

מטרת הבדיקות אינה לקבוע חזותית אם הקלטה מזויפת, אלא לזהות הבדלים בין מקורות או מחלקות שעשויים להשפיע על התנהגות המודל.

6.3 כלל חשוב בניתוח הנתונים

ניתן לחשב תיאורים סטטיסטיים לצורך הבנת המאגר, אך כל שלב שנלמד מהנתונים ומשמש כחלק ממודל — למשל StandardScaler, PCA, Feature Selection או בחירת סף — יותאם על קבוצת האימון בלבד בתוך כל Fold.

אין לבצע Feature Selection על כלל הנתונים לפני החלוקה.

7. פרוטוקול חלוקת הנתונים

זהו אחד החלקים החשובים ביותר בתוכנית, משום שתוצאות ההערכה יהיו תקפות רק אם מנענו זליגת מידע.

7.1 עקרון יסוד: Speaker-Disjoint Split

הקלטות של אותו דובר לא יופיעו הן באימון והן בהערכה.

נבחן שימוש ב-StratifiedGroupKFold או בחלוקה מקובצת אחרת, בהתאם למספר הדוברים ולהרכב המחלקות.

המטרה היא לשמור ככל האפשר על ייצוג שתי המחלקות והמקורות, בלי להפר את הפרדת הדוברים.

אם מזהי הדוברים אינם ייחודיים בין מקורות, יהיה צורך לבדוק את משמעותם ולא להסתפק בשרשור טכני של שם המאגר והמזהה.

7.2 הפרדת שלוש קבוצות

נשתמש בהבחנה בין:

Training: התאמת המודל, חישוב מאפייני נרמול ולמידת הפרמטרים.

Validation: בחירת היפר-פרמטרים ומודלים, וכיול ספי החלטה כאשר נדרש.

Internal Evaluation: הערכה שמורה של המודל שנבחר, בלי לשנות את המודל בעקבות תוצאותיה.

קבוצת התחרות הרשמית של הקורס תישאר נפרדת מכל אלה.

אם מבנה הנתונים אינו מאפשר חלוקה משולשת תקפה תוך הפרדת דוברים, נשקול Grouped Cross-Validation לצורך בחירת המודל והערכתו, עם תיעוד מפורש של המגבלה.

7.3 אותו Split לכל המודלים

כל הגישות ייבחנו על אותן קבוצות Training, Validation ו-Evaluation ככל האפשר.

אין להשוות מודל אחד שנבדק על חלוקה קלה למודל אחר שנבדק על חלוקה קשה.

קובצי הגדרת החלוקות יישמרו באופן המאפשר שחזור, ללא חשיפת נתוני הקורס בריפו הציבורי.

7.4 מניעת Leakage נוסף

בנוסף להפרדת דוברים, יש לבדוק האם דוגמאות שונות חולקות הקלטת מקור, טקסט או תוכן כמעט זהה.

הדבר משמעותי במיוחד עבור Codec Resynthesis, שבו דוגמה מזויפת עשויה להיות שחזור של הקלטה אמיתית.

אם ניתן לזהות קשרים כאלה באמצעות Metadata, יש לשמור דוגמאות מקושרות באותו Fold. אם לא ניתן, נתעד את הסיכון ולא נטען שהצלחנו למנוע באופן מלא דליפה ברמת ההקלטה המקורית.

8. פרוטוקולי ההערכה

נגדיר שלוש רמות הערכה, לפי סדר עדיפות.

P1 — Speaker-Disjoint In-Domain Evaluation

מטרה: למדוד ביצועים כאשר קבוצות האימון וההערכה נפרדות בדוברים, אך עדיין מיוצגות בהן אותן משפחות נתונים.

שיטה: חלוקה מקובצת לפי דובר, תוך שמירה ככל האפשר על שתי המחלקות ועל התפלגות המקורות.

מדד ראשי: EER כולל.

מדדים משלימים: EER לפי מקור בעל שתי מחלקות, טעויות לפי מערכת זיוף ו-False Rejection לפי מקור אמיתי.

זהו פרוטוקול הבסיס להשוואה בין המודלים.

P2 — Leave-One-Attack/System-Out

מטרה: לבחון זיהוי מתקפות שלא נכללו באימון.

שיטה מוצעת: לשמור מערכת זיוף או קבוצת מערכות מחוץ לאימון, ולהעריך עליהן את המודל.

ב-ASVspoof 5 נבחן שימוש במזהי A09–A16. ב-CodecFake נשתמש במזהי מערכות ה-Codec שיימצאו ב-Metadata.

בקרה הכרחית: דוגמאות ה-Spoof של המערכת המוחזקת בחוץ לא ישמשו לאימון או לבחירת מודל. בנוסף יש לשמור על הפרדת דוברים מול נתוני האימון, או לדווח במפורש על מגבלה אם הדבר אינו ישים.

תנאי לביצוע: קיום מספר מספיק של מערכות, דוברים ודוגמאות לבניית חלוקה תקפה.

הסתייגות: אם הקבוצה הנותרת קטנה מדי לחישוב EER יציב, נעדיף לדווח על המדגם והמגבלה במקום להציג אומדן מדויק לכאורה.

P3 — Cross-Dataset Evaluation

מטרה: לבחון את התנהגות המודל כאשר משתנה מקור הנתונים.

ניסוי אפשרי ראשון: אימון על ASVspoof 5 והערכה על CodecFake.

ניסוי אפשרי שני: אימון על CodecFake והערכה על ASVspoof 5.

בכל אחד מהם נשמור את מקור ההערכה מחוץ לאימון ומבחירת ההיפר-פרמטרים.

מכיוון שבשני המקורות קיימות דוגמאות אמיתיות ומזויפות, ניתן לחשב EER עבור כל כיוון בנפרד.

מגבלה חשובה: תוצאה בניסוי זה מערבת שינויי מקור ושינויי מנגנון זיוף. לפיכך היא אינה מודדת באופן מבודד רק הכללה למתקפות חדשות.

תפקיד M-AILABS

M-AILABS מכיל דוגמאות אמיתיות בלבד, ולכן לא ניתן לחשב עליו EER עצמאי.

נוכל להשתמש בו לצורך בחינת דחייה שגויה של דיבור אמיתי (Bona Fide False Rejection), תוך שימוש בסף שנקבע על Validation ולא על M-AILABS עצמו.

נבחן בנפרד שתי אפשרויות:

- שימוש ב-M-AILABS כמקור אמיתי שאינו נכלל כלל באימון, לצורך Audit חיצוני.
- הכללת דוגמאות ממנו באימון לצורך בדיקת השפעת מגוון מקורות הדיבור האמיתי.

אין להשתמש באותן הקלטות M-AILABS גם לשיפור המודל וגם להצגתן כהערכה חיצונית עצמאית.

9. מדדי ההערכה

Primary Metric — EER 9.1

EER הוא המדד המרכזי בהתאם לדרישות הקורס.

הציון שהמודל מחזיר יהיה רציף, עם הכיוון:

Label 1 = Spoof; higher score = more likely Spoof.

נשתמש בפונקציית EER משותפת לכל המודלים, ונבדוק אותה באמצעות Unit Tests.

הפונקציה תטפל בהגדרת מחלקה חיובית, כיוון הציון, ספים ושוויוני Scores באופן מתועד ועקבי.

9.2 מדדים משלימים

מדד	למה נשתמש בו?
EER כולל	מדד ההשוואה הראשי
EER לפי מקור	בדיקת הבדלי ביצועים בין ASVspoof 5 ל-CodecFake
EER לפי מערכת זיוף	זיהוי מתקפות קשות, כאשר יש קבוצת דיבור אמיתי להשוואה
Bona Fide FPR / False Rejection	בדיקת דחייה שגויה של דיבור אמיתי
Spoof Miss Rate	זיהוי זיופים שהמודל מקבל בטעות
ROC / Score Distributions	ניתוח התנהגות ציוני המודל
Runtime / Memory	הערכת עלות חישובית של הרחבות

לצורך דיוק במינוח: כאשר Score גבוה מייצג זיוף, דחייה שגויה של דיבור אמיתי שקולה ל-False Positive ביחס למחלקת Spoof. בדוח נשתמש במונחים מוגדרים היטב ונציין את כיוון המחלקות.

9.3 EER לפי מערכת זיוף

עבור מערכת זיוף מסוימת, EER יחושב באמצעות דוגמאות הזיוף שלה מול קבוצת דוגמאות אמיתיות מתאימה.

נעדיף להשתמש בדוגמאות אמיתיות מאותו מקור, ובמידת האפשר בהתאמה לדוברים או לתנאי ההערכה.

נדווח תמיד על מספר דוגמאות הזיוף ומספר הדוגמאות האמיתיות המשמשות לחישוב.

אין לחשב EER מדוגמאות זיוף בלבד.

9.4 הפרדה בין EER לסף הפעלה

EER הוא מדד רטרוספקטיבי המבוסס על שינוי סף ההחלטה.

במערכת מעשית נדרש סף קבוע. אם נדווח על טעויות בסף הפעלה, הסף ייבחר על קבוצת Validation ויישמר ללא שינוי בזמן הערכת קבוצת הבדיקה.

לא נבחר סף על סמך תוצאות קבוצת המבחן.

9.5 שונות ואי-ודאות

כאשר הדבר ישים, נריץ מספר חלוקות או Seeds קבועים מראש ונדווח על ממוצע ופיזור.

נשקול רווחי סמך המתחשבים בקיבוץ לפי דובר, כאשר מספר הקבוצות מאפשר זאת.

לא נפרש הבדלים קטנים ב-EER כמובהקים ללא ביסוס מתאים. במיוחד, תוצאה המבוססת על מעט דוגמאות עשויה להשתנות עקב מספר קטן של טעויות.

10. תוכנית המודלים

10.1 עקרון ההשוואה

כל מודל חדש צריך לענות על שאלה ברורה.

נרצה להבחין בין שינוי בייצוג, שינוי במסווג ושינוי בפרדיגמת הלמידה. לכן נימנע ככל האפשר מהוספת מספר רכיבים בו-זמנית בלי Baseline מתאים.

10.2 מטריצת מודלים

ID	ייצוג	מסווג	פרדיגמה	מעמד
M0	MFCC	Logistic Regression	Binary	Baseline — חובה
M1	CQCC	Logistic Regression	Binary	גישה נוספת 1
M2	Frozen wav2vec 2.0	Logistic Regression	Binary	גישה נוספת 2
M3	Frozen wav2vec 2.0	One-Class SVM	One-Class	ניסוי מחקרי מרכזי, מותנה בישימות
M4	Frozen WavLM	Logistic Regression	Binary	חלופה / הרחבה
M5	Frozen WavLM	One-Class SVM	One-Class	הרחבה מבוקרת
M6	AASIST-L	Neural Binary Classifier	Binary	הרחבה מתקדמת
M7	SSL + Deep SVDD	Deep One-Class	One-Class	הרחבה מתקדמת
M8	Feature Fusion / Reconstruction	מסווג מתאים	בהתאם לתצורה	הרחבה בלבד

התחייבות המינימום למחקר היא M0, M1 ו-M2.

M3 הוא הניסוי המועדף הבא משום שהוא מאפשר לבחון את שאלת ה-One-Class תוך שימוש באותו Encoder של M2.

M4 ו-M5 ייבחנו אם יהיה ערך מחקרי ומשאבים להשוואת wav2vec 2.0 ל-WavLM.

M6–M8 אינם תנאי להצלחה מחקרית ואינם נדרשים לשלב הראשון.

11. הגדרת ה-Baseline הראשון

M0 — MFCC + Logistic Regression

11.1 מטרת הניסוי

לבנות מערכת פשוטה, שקופה וניתנת לשחזור, שתשמש נקודת ייחוס לכל הניסויים הבאים.

11.2 מוצע Pipeline

Audio WAV

→ Feature Extraction: MFCC

→ Temporal Statistical Pooling

→ StandardScaler

→ Logistic Regression

→ Continuous Spoof Score

→ EER.

11.3 תצורת פתיחה מוצעת

- תדר דגימה: 16kHz.
- אורך Frame: כ-25ms.
- Hop Length: כ-10ms.
- מספר מקדמי MFCC ראשוני: 20.
- Pooling: ממוצע וסטיית תקן לאורך הזמן.
- מסווג: Logistic Regression.
- שימוש ב-StandardScaler שנלמד על Training בלבד.
- קביעת Random Seed וגרסאות ספריות.

הערכים הם החלטות מימוש מוצעות, לא פרמטרים שנדרשו בהנחיות או הוכחו כאופטימליים.

בשלב הראשון נעדיף תצורה פשוטה אחת. כוונון יבוצע רק אחרי שה-Pipeline פועל והתוצאה נמדדת בצורה תקינה.

11.4 תוצאות נדרשות

- EER ראשון בפועל.
- התפלגות ציוני Bona Fide ו-Spoof.
- ביצועים לפי מקור.
- ניתוח שגיאות ראשוני.
- תיעוד חלוקת הנתונים.
- תיעוד זמן האימון והחיזוי בקירוב.

11.5 קריטריון השלמה

ה-Baseline נחשב מושלם רק כאשר ניתן להריץ את המחברת מההתחלה ועד הסוף, לקבל את אותן הגדרות הניסוי ולשחזר את תוצאת ה-EER.

12. שתי הגישות הנוספות הנדרשות ל-Stage 2

M1 — CQCC + Logistic Regression

שאלת הניסוי

האם החלפת הייצוג האקוסטי מ-MFCC ל-CQCC משפרת את הזיהוי וההכללה?

תכנון

נשתמש באותו מסווג ובאותו פרוטוקול כמו M0.

ישתנה רכיב חילוץ המאפיינים בלבד, ככל האפשר.

לצורך השוואה הוגנת נשמור על אותו מנגנון Train/Validation/Evaluation ועל שיטת Pooling מתאימה ומתועדת.

מה נלמד?

אם מתקבל שיפור, תהיה ראיה לכך שלייצוג האקוסטי יש תרומה מעבר לבחירת המסווג.

אם לא מתקבל שיפור, נוכל לדון בכך שרזולוציה ספקטרלית שונה אינה מבטיחה יתרון בנתונים הנוכחיים.

מקור מחקרי: Todisco et al. (2017) — CQCC [3].

M2 — Frozen wav2vec 2.0 + Logistic Regression

שאלת הניסוי

האם ייצוג דיבור מאומן מראש מספק יתרון על פני מאפיינים אקוסטיים מחושבים מראש, כאשר המסווג נשאר פשוט?

תכנון

נשתמש ב-wav2vec 2.0 Base כ-Encoder קפוא.

נחלץ Embeddings מתוך שכבה מוגדרת מראש, נבצע Pooling לאורך ציר הזמן ונאמן Logistic Regression על הייצוגים.

אין צורך להתחיל ב-Full Fine-Tuning של המודל.

בקרת ניסוי

כדי לבודד את תרומת הייצוג, נעדיף לשמור על אותו מסווג המשמש ב-M0 וב-M1.

השינויים בממד המאפיינים ובעלות החילוץ יתועדו, משום שהייצוגים אינם זהים בגודלם.

מה נלמד?

נוכל להעריך האם ייצוגי SSL משפרים EER והכללה, או שמא הם משמרים בעיקר מידע אחר שאינו מועיל לזיהוי הזיוף בנתוני הקורס.

מקורות מחקריים: Baevski et al. (2020) [5]; Chen et al. (2022) [6].

13. ניסוי One-Class Learning

M3 — Frozen wav2vec 2.0 + One-Class SVM

13.1 מטרת הניסוי

לבחון האם שינוי פרדיגמת הלמידה מסיווג בינארי לזיהוי חריגות משפר את יכולת הזיהוי של מתקפות שלא נראו באימון.

13.2 עקרון ההשוואה

נשתמש באותו wav2vec 2.0 Encoder ובאותה שיטת חילוץ ייצוגים ששימשו את M2.

ההבדל העיקרי יהיה המסווג:

M2: מסווג בינארי שאומן על דוגמאות אמיתיות ומזויפות.

M3: One-Class SVM שאומן רק על דוגמאות הדיבור האמיתי בקבוצת האימון.

כך נוכל להשוות את השפעת פרדיגמת הלמידה בלי להחליף במקביל גם את ה-Encoder.

13.3 בחירת היפר-פרמטרים

נבחין בין שני פרוטוקולים אפשריים.

Pure One-Class: בחירת הגדרות המסווג בלי להשתמש בתוויות של דוגמאות זיוף, באמצעות תצורה מוגדרת מראש או בקרת התפלגות על דיבור אמיתי בלבד.

One-Class with Supervised Validation: אימון המסווג על דיבור אמיתי בלבד, אך בחירת היפר-פרמטרים לפי EER על Validation הכולל שתי מחלקות.

שני הפרוטוקולים לגיטימיים כשאלות ניסוי שונות, אך אין להציג את השני כגישה שאינה משתמשת בתוויות זיוף כלל.

ההבחנה נובעת מן הביקורת על פרוטוקול הבחירה המתואר אצל Yin and Lei (2026).

13.4 הערכה

הניסוי ייבחן באותו Internal Evaluation ובאותם תרחישי הכללה כמו M2.

נמדוד EER, ובנוסף נבחן את התנהגות הציונים של דיבור אמיתי ממקורות שונים.

13.5 סיכון מחקרי מרכזי

One-Class SVM עלול לזהות הקלטות אמיתיות ממקור חדש כחריגות.

לכן הצלחה בזיהוי זיופים חייבת להיבחן יחד עם שיעור הדחייה השגויה של Bona Fide.

13.6 למה לא להתחיל ב-Deep SVDD?

One-Class SVM מאפשר לבדוק את השערת המחקר המרכזית בלי להוסיף מראש רשת נלמדת נוספת, פונקציית אובדן מורכבת ותהליך אימון רגיש.

אם התוצאות יצביעו על פוטנציאל, נוכל להמשיך ל-Deep SVDD. אם לא, עדיין נקבל תוצאה מחקרית משמעותית לגבי מגבלות One-Class Learning על הנתונים שלנו.

מקור מחקרי: Yin and Lei (2026) [9].

14. השערות מחקר

ההשערות מנוסחות מראש כדי לאפשר הפרכה ולא רק אישור.

ID	השערה	השוואה	מדד מרכזי	מה יפריך אותה?
H1	ייצוגי SSL יספקו הכללה טובה יותר ממאפיינים קלאסיים	M2 מול M0/M1	EER על מתקפות מוחזקות בחוץ	EER דומה או גבוה יותר ב-M2
H2	One-Class Learning עשוי לשפר זיהוי מתקפות לא מוכרות ביחס ל-Binary Classification	M3 מול M2	Unseen-Attack EER	M3 אינו משפר EER או מציג הרעה
H3	One-Class Learning עלול להיות רגיש יותר לשינוי מקור של דיבור אמיתי	M3 מול M2	Bona Fide False Rejection לפי מקור	אין הבדל מהותי או M3 יציב יותר
H4	שילוב ייצוגים קלאסיים ועמוקים עשוי להוסיף מידע משלים	Fusion מול הרכיבים בנפרד	EER ואבלציה	Fusion אינו משפר או פוגע
H5	מורכבות נוספת לא בהכרח תוביל לשיפור יציב המצדיק את עלותה	מודל מורכב מול פשוט	EER, שונות ועלות	שיפור גדול, עקבי ובעלות סבירה

H1–H3 הן ההשערות המרכזיות הרצויות.

H4–H5 ייבחנו רק אם נחליט לבצע הרחבות מתקדמות.

ההשערות אינן קביעה מראש לגבי התוצאות. מטרתן להגדיר מה בדיוק ייחשב תמיכה או אי-תמיכה בכיוון המחקרי.

15. ניסויי Ablation

Ablation נועד לבודד את השפעת רכיב מסוים ולאפשר הסבר של השינוי בביצועים.

15.1 Ablation בסיסי — Representation

נשווה:

- MFCC + Logistic Regression.
- CQCC + Logistic Regression.
- Frozen wav2vec 2.0 + Logistic Regression.

בשלושת הניסויים נשמור על אותו פרוטוקול הערכה.

זוהי השוואה בין ייצוגים, ולא השוואה מושלמת של עלותם החישובית, משום שחילוץ SSL עשוי להיות יקר יותר.

15.2 Ablation של פרדיגמת הלמידה

נשווה:

- Frozen wav2vec 2.0 + Binary Classifier.
- Frozen wav2vec 2.0 + One-Class SVM.

השוואה זו משמעותית במיוחד משום שהיא שומרת על אותו Encoder.

עם זאת, יש להכיר בכך שמספר התוויות ודוגמאות המחלקות המשמשות לאימון שונה במכוון בין שתי הגישות. זהו חלק מהשאלה המחקרית, ולא מצב של תקציב תוויות זהה.

15.3 Ablation של Preprocessing

אם בניתוח הנתונים יימצאו הבדלים משמעותיים ברמות שקט או עוצמה, נוכל לבחון את השפעת הסרת השקט או נרמול העוצמה.

השערה אפשרית היא שפעולות כאלה יפחיתו תלות במאפייני מקור.

מנגד, הן עלולות להסיר מידע המועיל לזיהוי זיופים.

לפיכך לא נבצע אותן כשלב אוטומטי בלי לתעד את השפעתן.

15.4 Ablations מתקדמים — מותנים

אם נגיע למודלים מורכבים יותר, נגדיר Ablation מתאים לכל רכיב:

- wav2vec 2.0 מול WavLM.
- שכבה אחת מול Weighted Layer Pooling.
- LFCC/SSL בנפרד מול Feature Fusion.
- One-Class SVM מול Deep SVDD.
- Feature Reconstruction עם ובלי שחזור.
- מערכת בעלת מסווג יחיד מול Multi-Model Fusion.

לא נבצע את כל הניסויים רק משום שהם אפשריים. נבחר אותם לפי שאלת המחקר, הזמן והתרומה הצפויה.

16. בדיקות Shortcut Learning ו-Data Leakage

זהו מרכיב הכרחי בתוכנית המחקר ולא נספח אופציונלי.

16.1 הסיכון לזיהוי מקור במקום זיוף

מאחר ש-M-AILABS כולל דיבור אמיתי בלבד, מודל יכול לנצל קשר בין מקור הנתונים למחלקה.

כדי לאתר סיכון זה נבצע:

בדיקת התפלגות Scores לפי מקור: נבדוק אם דוגמאות אמיתיות מ-M-AILABS מקבלות ציונים שונים באופן עקבי מדוגמאות אמיתיות בשני המקורות האחרים.

Dataset Probe: נבחן האם ניתן לחזות את מקור ההקלטה מתוך המאפיינים או ה-Embeddings, במיוחד כאשר משתמשים רק בדוגמאות אמיתיות מכל המקורות.

יכולת גבוהה לזהות מקור אינה מוכיחה שהמסווג הסופי משתמש במידע זה, אך היא מעידה שהמידע זמין במרחב המאפיינים.

השוואת Pooled לעומת Cross-Dataset: נבדוק אם ביצועים טובים בהערכה מעורבת נשמרים גם במעבר בין מקורות.

16.2 ארטיפקטים שאינם קשורים לזיוף

נבדוק האם ציוני המודל מושפעים באופן חריג מ:

- Loudness.
- DC Offset.
- שיעור שקט בתחילת ההקלטה או בסופה.
- Bandwidth Cutoff.
- Padding או מאפייני עיבוד של מקטעים באורך קבוע.
- Compression ו-Codec Fingerprints.
- מאפיינים הקשורים למקור ההקלטה.

לא כל קשר בין המאפיינים הללו לבין הזיוף הוא פסול: חלק מהארטיפקטים עשויים להיות תוצאה אמיתית של תהליך הזיוף. השאלה היא האם המודל מסתמך על סימנים שמכלילים באופן סביר או על קשר מקרי הספציפי למאגר.

16.3 בדיקות שליליות

ניתן להשתמש בניסויי בקרה פשוטים, כגון מסווג מקור או בדיקת מאפיין יחיד, כדי להעריך האם קשרים טריוויאליים מסבירים חלק משמעותי מהביצועים.

תוצאות אלה ישמשו לאבחון, לא כתחליף להערכת המודל המרכזי.

17. ניתוח שגיאות

לא נסתפק בדיווח על EER כולל.

17.1 שני סוגי הטעויות

Missed Spoof: הקלטה מזויפת שמתקבלת כאמיתית.

False Alarm / Bona Fide Rejection: הקלטה אמיתית שמסווגת כמזויפת.

לשני סוגי השגיאות משמעות שונה במערכות יישומיות, ולכן יש לנתח אותם בנפרד.

17.2 פירוק לפי מערכת זיוף

נבדוק אילו מערכות קשות יותר לכל מודל, והאם הכשלים מרוכזים במשפחה מסוימת של מתקפות.

17.3 פירוק לפי מקור

נבדוק האם מודל מסוים מציג ביצועים טובים בעיקר על אחד המאגרים.

במקרה כזה נצטרך להבחין בין חוסר הכללה לזיופים לבין רגישות למאפייני המקור.

17.4 ניתוח Scores

נציג התפלגויות של ציוני Bona Fide ו-Spoof, ונבדוק את מידת החפיפה ביניהן.

עבור One-Class Learning נבחן במיוחד האם דוגמאות אמיתיות ממקור חדש מקבלות ציוני חריגה גבוהים.

17.5 פרשנות זהירה

לא נייחס טעות למאפיין אקוסטי מסוים ללא ראיה תומכת. אם לא ניתן לקבוע האם מקור השגיאה הוא Codec, דובר, רעש או סוג מתקפה, נציג זאת כמגבלה ולא כהסבר מוכח.

18. שחזוריות ותיעוד ניסויים

18.1 עקרונות

כל ניסוי חייב להיות ניתן לשחזור באמצעות קוד, הגדרות וגרסאות מתועדות.

לכל הרצה יירשמו לפחות:

- Experiment ID.
- שם מודל וגרסה.
- מקור הנתונים והחלוקה.

- Seed.
- תצורת חילוץ המאפיינים.
- Hyperparameters.
- גרסת מודל מאומן מראש, אם רלוונטי.
- EER ומדדים משלימים.
- זמן אימון וחיזוי, אם נמדד.
- גרסת Git / Commit SHA.
- הערות על בעיות או מגבלות.

18.2 תיעוד קונפיגורציות

נעדיף Config נפרד לכל ניסוי, למשל YAML או JSON.

כל קונפיגורציה תגדיר את הנתונים, המודל, הפרמטרים והמדדים, כדי למנוע שינוי ידני לא מתועד בין הרצות.

18.3 קוד הערכה משותף

פונקציית EER אחת תשמש את כל המודלים, עם Unit Tests המוודאים כיוון ציונים והתנהגות במקרי קצה.

לא נשתמש במימושי EER שונים למודלים שונים.

18.4 עבודה עם מודלי SSL

משקלי המודל המאומן מראש יישמרו מחוץ לריפו.

Embeddings יחושבו באמצעות סקריפט נפרד ויוכלו להישמר ב-Cache מקומי כדי למנוע חילוץ חוזר שלא לצורך.

ה-Cache לא יישמר בריפו הציבורי.

18.5 תיעוד מקורות חיצוניים

לכל מודל מאומן מראש, ספרייה או קוד מחקרי נרשום את המקור, הגרסה והרישיון הרלוונטי.

נבחן גם את מקור נתוני ה-Pre-training במידת האפשר, כדי לתעד סיכון אפשרי לחפיפה בין נתוני אימון מוקדם לבין נתוני ההערכה.

18.6 דרישות פרטיות הקורס

לא נעלה לריפו הציבורי קובצי אודיו, את `train.csv`, את קובצי המבחן או נתונים פרטניים הנגזרים מהם.

ניתן לשמור קוד, תיעוד מתודולוגי, תצורות ותוצאות מסוכמות המותרות לפי הנחיות הקורס.

18.7 שימוש בכלי AI

בהתאם להנחיות הקורס, ננהל תיעוד של פרומפטים שבהם נעשה שימוש בכלי AI.

התיעוד יאפשר להבחין בין החלטות מחקריות שלנו, מידע שנלקח מן המקורות וסיוע שהתקבל מכלי AI.

19. ניהול סיכונים

סיכון	השפעה אפשרית	אמצעי התמודדות
Speaker Leakage	EER אופטימי ולא מייצג	Grouped Split
חפיפה בין מקור לזיוף	מודל מזהה מאגר במקום זיוף	Source Audit ו-Cross-Dataset
מעט דוגמאות למתקפה	EER לא יציב	דיווח ספירות, הגבלת פרשנות
Overfitting	שיפור באימון אך לא בהערכה	מודלים פשוטים, Validation, רגולריזציה
שינויי Codec וערוץ	ירידה בהכללה	Cross-Codec Analysis
One-Class רגיש למקור	דחייה שגויה של דיבור אמיתי	Real-Only Audit
מודל SSL גדול מדי	עלות חישובית גבוהה	Frozen Encoder ו-Cache
Feature Fusion מיותר	מורכבות ללא יתרון	Ablation
כוונון על Test	הטיית תוצאות	בחירת מודל על Validation בלבד
חוסר יכולת לשחזר	פגיעה בתקפות המדעית	Configs, Seeds ו-Experiment Log
חפיפה ב-Pre-training	הערכה אופטימית אפשרית	בדיקת מקור המשקלים ותיעוד מגבלה

19.1 שער עצירה מתודולוגי

אם לא ניתן לבנות חלוקה המונעת דליפה ברמת דובר או ברמת ההקלטה המקורית, לא נציג את התוצאה כאומדן אמין להכללה.

נעדיף לתקן את הפרוטוקול, לצמצם את היקף הניסוי או לציין מגבלה מפורשת.

19.2 שער עצירה של מורכבות

לא נוסיף מודל מורכב רק משום שהוא הוצג במאמר.

נדרוש לפחות אחד מאלה:

- שיפור מדיד ועקבי בתוצאות.
- יכולת לענות על שאלת מחקר שאי אפשר לבדוק במודל פשוט יותר.
- יתרון מובהק בפרופיל שגיאות מסוים.
- הצדקה חישובית או יישומית ברורה.

שיפור זניח או לא יציב אינו מצדיק אוטומטית תוספת מורכבות.

20. תוכנית הביצוע לפי שלבי הקורס

Stage 1 — Review

מטרת השלב: להכיר את הנתונים, לבסס את הבחירות המחקריות ולהפיק נקודת ייחוס אמפירית ראשונה.

פעולות נדרשות

1. השלמת סקירת הספרות המקוצרת מתוך Document A.
2. טעינת `train.csv` ובדיקת המבנה האמיתי שלו.
3. סקירת התפלגויות לפי מחלקה, מקור, דובר ומערכת זיוף.
4. האזנה לדוגמאות והצגת ספקטרוגרמות מייצגות.
5. זיהוי סיכוני Leakage וקיצורי דרך.
6. קביעת חלוקה ראשונית מבוקרת לפי דוברים.
7. מימוש MFCC + Logistic Regression.
8. חישוב EER ותיעוד הניסוי.
9. ניסוח ראשוני של הממצאים והמגבלות.

תוצרי Stage 1

Report: מסמך בן 2–3 עמודים המכיל סקירת ספרות, ניתוח נתונים, Baseline וממצאים ראשוניים.

Notebook: מחברת ניתנת להרצה המציגה את הבדיקות ואת מדידת ה-EER.

תנאי סיום: קיימת תוצאת EER אמיתית, עם תיאור ברור של הנתונים והחלוקה שעליהם נמדדה.

Stage 2 — Experiment Design

מטרת השלב: להגדיר מראש מה בודקים, כיצד בודקים ומה ייחשב ראיה להשערות.

פעולות נדרשות

1. ניסוח סופי של שאלת המחקר.
2. בחירת ההשערות המרכזיות.
3. אישור M1 ו-M2 כשתי הגישות הנוספות.
4. החלטה אם M3 ייכלל בניסויים המרכזיים.
5. הגדרת פרוטוקול Speaker-Disjoint.
6. הגדרת Cross-Dataset ו-Leave-One-System-Out בהתאם לישימות.
7. הגדרת מדדי EER וניתוח שגיאות.
8. קביעת Ablations.
9. תיעוד הסיכונים והפתרונות.
10. תיעוד ההחלטות לפני הפעלת הניסויים המתקדמים.

תוצר Stage 2

מסמך תכנון בן שני עמודים, שייגזר מן המסמך הנוכחי.

המסמך המקוצר יתמקד בעיקר בשאלת המחקר, בהשערות, במודלים שנבחרו, בפרוטוקול ובסיכונים.

Stage 3 — Results

מטרת השלב: לבצע את ההשוואות שתוכננו, להסביר את התוצאות ולהגיע למסקנה מחקרית תקפה.

פעולות נדרשות

1. הרצת המודלים הנבחרים על אותן חלוקות.
2. תיעוד EER, מדדים משלימים ומאפייני הריצה.
3. ביצוע הניסויים לבחינת הכללה.
4. הרצת Ablations שנבחרו מראש.
5. ניתוח טעויות לפי מקור ומערכת זיוף.
6. בדיקת יציבות התוצאות ככל שהנתונים מאפשרים.
7. דיון בתוצאות שאינן תומכות בהשערות.
8. הכנת דוח תוצאות וקוד לשחזור.
9. בחירת המודל הסופי באמצעות Validation בלבד.
10. הקפאת המודל וה-Inference Pipeline לפני פרסום מבחן התחרות.

תוצרים

- דוח בן 6–8 עמודים.
- קוד לשחזור הניסויים.
- תיעוד מלא של התצורות והתוצאות.
- קובץ הגשה לתחרות בהתאם לפורמט הרשמי.

21. תוכנית התחרות והמודל הסופי

21.1 הפרדה בין בחירת מודל לבדיקתו

כל החלטה על ארכיטקטורה, Hyperparameters, סף החלטה או שיטת Preprocessing תתבסס על נתוני האימון וה-Validation המותרים בלבד.

לא נשתמש בקבוצת התחרות לצורך בחירת מודל.

21.2 אימון סופי

לאחר בחירת התצורה, ניתן יהיה לאמן מחדש את המודל על נתוני האימון הזמינים בהתאם לפרוטוקול שנקבע, כל עוד הדבר מתבצע לפני שחרור נתוני המבחן.

נשתמש באותו Pipeline שמתואר בדוח, ללא שינוי מהותי שלא תועד.

Freeze 21.3

לפני פרסום נתוני התחרות נקפיא את:

- ארכיטקטורת המודל.
- המשקלים הסופיים.
- סדר שלבי ה-Preprocessing.
- פרמטרי חילוץ המאפיינים.
- שיטת חישוב הציון.
- גרסת קוד ה-Inference.

21.4 קובץ ההגשה

בהתאם למסמך הקורס, קובץ ההגשה יהיה CSV הכולל:

```
id,score
```

כל הקלטה תקבל ציון אחד, וציון גבוה יותר יצביע על סבירות גבוהה יותר לזיוף.

אין לאמן על נתוני המבחן, לבצע Pseudo-Labeling, לתייג אותם ידנית או לחפש את ההקלטות במאגרים המקוריים כדי לחשוף את התוויות.

22. מפת החלטות המחקר

כדי להימנע מהרחבת יתר של הפרויקט, נגדיר מה כבר החלטנו ומה עדיין תלוי בנתונים ובניסויים.

החלטה	סטטוס	הסבר
משימת Binary Anti-Spoofing	מאושר	דרישת הקורס
מדד ראשי EER	מאושר	דרישת הקורס
Score גבוה = Spoof	מאושר	פורמט התחרות
MFCC + Logistic Regression	מאושר כ-Baseline	פשוט, ניתן להסבר ולשחזור
CQCC + Logistic Regression	מוצע כגישה נוספת 1	בדיקת Feature Representation
Frozen wav2vec 2.0 + Logistic Regression	מוצע כגישה נוספת 2	בדיקת SSL Representation
One-Class SVM על SSL	ניסוי מועדף נוסף	בדיקת Learning Paradigm
WavLM כ-Encoder חלופי	מותנה	נבחן אם יתרום לשאלת המחקר
AASIST-L	אופציונלי	מורכבות גבוהה יותר
Deep SVDD	אופציונלי	רק אחרי ניסוי One-Class פשוט
VQ-VAE Reconstruction	לא בעדיפות ראשונה	מורכבות וחישוב נוספים
Multi-Model Fusion	לא בעדיפות ראשונה	נדרש להוכיח מידע משלים
מספר Folds	טרם נקבע	תלוי במספר הדוברים בפועל
מערכות שיוחזקו מחוץ לאימון	טרם נקבע	תלוי ב-Metadata ובספירות
EER של Baseline	טרם נמדד	מחייב הרצת ניסוי

סטטוס "מאושר" מתייחס למסגרת שכבר נקבעה בפרויקט. סטטוס "מוצע" מתייחס להחלטת תכנון מחקרית שטרם אומתה בניסוי.

23. מסלול מינימלי ומסלול הרחבה

Minimum Viable Research 23.1

המסלול המינימלי המחקרי כולל:

M0: MFCC + Logistic Regression.

M1: CQCC + Logistic Regression.

M2: Frozen wav2vec 2.0 + Logistic Regression.

Evaluation: Speaker-Disjoint Evaluation, EER לפי מקור, ניתוח שגיאות והכללה לפי מתקפה או מקור ככל שהנתונים מאפשרים.

מסלול זה עומד בדרישת שתי גישות נוספות מעבר ל-Baseline, ומאפשר לענות על RQ1.

Preferred Research Extension 23.2

הרחבה מועדפת:

M3: Frozen wav2vec 2.0 + One-Class SVM.

כך ניתן יהיה להוסיף את RQ2 ולבחון השפעת פרדיגמת הלמידה תוך שמירה על אותו Encoder.

זוהי הרחבה בעלת ערך מחקרי גבוה יחסית למורכבותה, משום שהיא מאפשרת לבדוק רעיון חדש מהספרות בלי לבנות מערכת עמוקה מורכבת מאפס.

Advanced Extensions 23.3

אם הניסויים הראשונים יהיו יציבים ונישאר עם משאבים מתאימים, אפשר יהיה לבחור הרחבה אחת בלבד מבין:

- WavLM כ-Encoder חלופי.
- Deep SVDD.
- AASIST-L.
- Feature Fusion.
- Feature Reconstruction.

הבחירה תתבסס על השאלה המחקרית שהניסוי יוכל לענות עליה, ולא על מורכבות הארכיטקטורה כשלעצמה.

24. תוצרים מחקריים צפויים

בסיום המחקר נרצה להציג:

1. סקירת ספרות הממקמת את העבודה ביחס לשיטות קלאסיות, עמוקות וחד-מחלקתיות.
2. ניתוח של מאגר הנתונים ושל הסיכונים המתודולוגיים שלו.
3. Baseline ראשון עם EER מאומת.
4. השוואה בין לפחות שלוש גישות תחת פרוטוקול אחיד.

5. ניסוי הכללה למתקפות או למקורות שלא נכללו באימון.
6. ניתוח ההשפעה של ייצוג הדיבור על ביצועי הזיהוי.
7. בחינה של One-Class Learning אם ייכלל בהיקף הניסוי.
8. ניתוח שגיאות לפי מקור ומערכת זיוף.
9. הערכת מורכבות ומשאבים עבור הרחבות שמומשו.
10. מסקנה מחקרית המבוססת על תוצאות, לרבות תוצאות שליליות.
11. קוד ותיעוד המאפשרים שחזור של הניסויים.
12. מודל סופי העומד בפרוטוקול התחרות של הקורס.

אין דרישה שכל ההשערות יתאמתו. הצלחה מחקרית תימדד גם ביכולת להסביר מדוע גישה מסוימת לא שיפרה את התוצאות או כשלה בהכללה.

25. מסקנה תכנונית

סקירת הספרות מצביעה על כך שזיהוי זיופים קוליים אינו רק בעיית סיווג, אלא גם בעיית הכללה תחת שינויי התפלגות.

המחקרים שנבחנו מדגישים את חשיבותם של מאפיינים ספקטרליים, למידה עמוקה, ייצוגי SSL, שחזור מונחה ולמידה חד-מחלקתית. עם זאת, אין די בתוצאות שדווחו במאמרים כדי לקבוע מראש איזו גישה תשיג את הביצועים הטובים ביותר על מאגר הפרויקט הנוכחי.

לכן המחקר יאמץ אסטרטגיה מדורגת, המתחילה ב-Baseline פשוט ומתקדמת לגישות נוספות בהתאם לשאלות מחקר מוגדרות.

ההשוואה הראשונה תבחן את השפעת ייצוג הדיבור באמצעות MFCC, CQCC ו-wav2vec 2.0.

לאחר מכן נבחן, ככל שהמשאבים והנתונים יאפשרו, את השפעת פרדיגמת הלמידה באמצעות השוואה בין Binary Classification ל-One-Class Learning על אותו ייצוג SSL.

בכל שלב נשים דגש על מניעת Data Leakage, על בדיקת תלות במקור הנתונים, על הפרדה בין אימון להערכה ועל דיווח מלא של תוצאות חיוביות ושליליות.

העיקרון המחקרי המרכזי הוא שמודל טוב אינו רק מודל שמציג EER נמוך, אלא מודל שהביצועים שלו נמדדו באופן תקף, שהמגבלות שלו מובנות, ושאפשר להסביר באילו תנאים הוא צפוי להכליל — ובאילו תנאים לא.

תוכנית זו נועדה לספק בסיס מדעי עקבי לכל שלבי הפרויקט, תוך איזון בין איכות אקדמית, מורכבות ניסויית ומשאבי הביצוע הזמינים.

נספח A — מיפוי ישיר למסמכי הריפוזיטורי

בהתאם למבנה הריפו הקיים:

תיקייה	תוצרים שיוכנו
`/literature`	תשעת כרטיסי המחקר והסיכומים; Document A
`/stage1-review/report`	Stage 1 Report
`/stage1-review/notebooks`	Data Audit ו-Baseline Notebook
`/stage2-design`	Stage 2 Design Report מתוך Document B
`/stage3-results/src`	קוד מודלים, חילוץ מאפיינים, הערכה וניסויים
`/stage3-results/report`	דוח התוצאות הסופי
`/stage3-results/competition`	קובץ הגשה לתחרות
`/prompts`	תיעוד פרומפטים בהתאם להנחיות
`/data`	נתונים מקומיים בלבד, ללא העלאה לריפו

מסמך B עצמו הוא מסמך מחקר מורחב. מיקומו הסופי ייקבע בהתאם למבנה התיעוד שנרצה לשמור בריפו, בלי להניח שיש צורך ליצור תיקיות חדשות.

נספח B — מקורות המחקר

[1] Wang et al. (2024). *ASVspoof 5: Crowdsourced Speech Data, Deepfakes, and Adversarial Attacks at Scale*. arXiv:2408.08739.

[2] Wu, H., Tseng, Y., & Lee, H.-y. (2024). *CodecFake: Enhancing Anti-Spoofing Models Against Deepfake Audios from Codec-Based Speech Synthesis Systems*. Interspeech 2024.

[3] Todisco, M., Delgado, H., & Evans, N. (2017). *Constant Q Cepstral Coefficients: A Spoofing Countermeasure for Automatic Speaker Verification*.

[4] Jung et al. (2022). *AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks*. ICASSP 2022.

[5] Baevski et al. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. NeurIPS.

[6] Chen et al. (2022). *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing*. IEEE Journal of Selected Topics in Signal Processing.

[7] Wu, S., Cheng, Y., Wang, R., & Yan, D. (2026). *Robust Speech Forgery Detection via Enhanced Forensic Trace Generation*. Signal, Image and Video Processing.

[8] Izrailov, K. E., Kotenko, I. V., & Chechulin, A. A. (2026). *Intelligent Voice Fraud Detection Methods in Authentication Systems*. Pattern Recognition and Image Analysis.

Yin, J., & Lei, S. (2026). *A Novel Attack-Resistant Speech Forgery Detection Method* [9] *Integrating One-Class Learning and Wav2vec2*. CNML 2026.

מקור דרישות: *זיהוי זיופים קוליים: אמיתי או מזויף?* — הנחיות פרויקט הקורס, נושאים מתקדמים בלמידת מכונה, HIT, 2026.

הערת תוקף: מסמך זה נכתב לפני ביצוע ניתוח הנתונים והניסויים. הוא כולל החלטות תכנון מוצעות, השערות ומגבלות ידועות מן הספרות ומדרישות הקורס. הגדרות חלוקה התלויות ב-Metadata, תוצאות EER, מדדי יציבות ומסקנות אמפיריות ייקבעו ויתועדו רק לאחר הרצת הניסויים בפועל.