Document B — Research Synthesis & Experimental Blueprint

Fake or Real: Voice Deepfake Detection — מסמך תכנון מחקר וניסויים

חוקרים: Shlomi Hazan & Maayan Adler

קורס: Advanced Topics in Machine Learning, HIT

גרסה: 2.2 — 7 בנובמבר 2026

סטטוס: Pre-EDA — Experimental Blueprint; **פרוטוקול ההכרעה מוגדר אך החלוקות עצמן טרם אומתו**

מסמך בסיס: *Document A — Integrated Literature Review, Final Revised (HE)*

תשתית ספרותית: 12 מאמרים שנלמדו בקריאה מודרכת; תשעת מאמרי המחקר המקוריים, Research Paper 10 — AT-ADD, ושני מאמרי המאגרים MLAAD ו-PhonemeDF.

> **הערת תוקף:** v2.2 משמרת את תיקוני v2.1 ומחדדת שני חוזי ניסוי: (א) OC-Pure מחייב גם בחירה מראש של Checkpoint/Layer/Pooling ללא תוויות Fake; (ב) Contrast S מגדיל Real ו-Fake חיצוניים באופן פרופורציונלי ושומר ככל האפשר על יחס המחלקות **הכולל**. אין בכך ראיה שנוצר Split Manifest או שהורצו EDA, Model Selection, Bootstrap או Dataset Admission Gates.

הערת מסגרת: זהו מסמך-אב פנימי, לא דוח Stage 2 בן שני עמודים. הוא מרכז החלטות, תוכניות מותנות וכללי תקפות; מתוך המסמך ייגזרו מסמכי ההגשה והמחברות. כל תוצאה מספרית שמיוחסת למאמר היא **ממצא שפורסם** ולא תוצאה של הפרויקט. אין כאן טענה שהמאגר החיצוני כבר הורד, שנבדקו מזהי הדוברים בקובץ הקורס או שהורץ מודל.

תקציר מנהלים

הפרויקט מבקש לבנות גלאי לזיהוי דיבור אמיתי לעומת דיבור מזויף, ולבחון לא רק את איכות הסיווג על דוגמאות מוכרות אלא גם את יכולת ההכללה תחת שינויי מערכות יצירה, מקור דיבור ותנאי עיבוד. כדי לעשות זאת בלי להפוך ניסוי קורס למחקר בלתי-מוגבל, נתקדם לפי **שני צירי ליבה וציר שלישי מותנה**: (1) ייצוג הדיבור — MFCC/CQCC לעומת ייצוגי SSL; (2) פרדיגמת למידה — סיווג בינארי לעומת One-Class על אותו Encoder; (3) הרחבת האימון — הבחנה ניסויית בין *כמות דוגמאות* לבין *מגוון מערכות יוקר*, אם בדיקות הגישה, הרישוי וה-Metadata יאפשרו זאת. שכבת הערכה משותפת תבחין בין הערכה פנימית, Leave-One-System-Out (LOSO), מעבר בין מאגרים ועמידות לשינויי אות.

מאגר הקורס מכיל **1,520 קטעי WAV, באורך ארבע שניות, 16kHz, מונו**: 300 Real ו-300 Fake מ-ASVspoof 5, 300 Real ו-300 Fake מ-CodecFake ו-320 Real מ-M-AILABS. בסך הכול **920 Real** ו-**600 Fake**. קבוצת מבחן תחרותית נפרדת תפורסם בהמשך, ללא תוויות, והפרויקט מחויב להפיק עבורה

CSV בפורמט `id,score`, כאשר ציון גבוה משמעו חשד גבוה יותר לזיוף. האימון הראשון יהיה **MFCC + Logistic Regression**; השוואת הייצוגים המינימלית תכלול גם **CQCC + Logistic Regression** ו-**Frozen wav2vec 2.0 + Logistic Regression**; לאחר מכן **M3 — One-Class SVM** על אותם ייצוגי wav2vec 2.0 הוא **ניסוי ליבה מתוכנן** לבחינת ציר הלמידה, בכפוף לשערי היתכנות מתועדים. WavLM, AASIST-L, Deep SVDD, Feature Fusion, Forensic Reconstruction ו-Ensemble יישארו הרחבות מנומקות, לא התחייבויות אוטומטיות.

המסמך מעגן את הלקחים מן המאמרים החדשים: **MLAAD** מציע מגוון TTS ושפות אך אינו מוכיח ש-v11 עדיפה בזכות המגוון, שכן ניסויי ההכללה במאמר נעשו על v1; **PhonemeDF** מאפשר מקור/תוצר מקבילים וניתוח פונטי, אך מחייב קיבוץ משפחות מקור והבחנה בין KLD/Accuracy ברמת פונמה ל-EER ברמת הקלטה; **AT-ADD** מדגים כי הצלחה על Dev אינה מבטיחה Robustness ב-Eval, וכי Macro-F1, מדדי Real/Fake וניתוח שגיאות משלימים מדד אחד, אך האודיו שלו **אינו מקור אימון/בדיקה זמין ומאומת** עבורנו. המסמך שומר על כל ההחלטות המוקדמות, ומוסיף פרוטוקול הרחבה שניתן להפרכה ולא רק טיעון ש"יותר נתונים" אמור לעזור.

1. מטרת המסמך, מקורות וסוגי הטענות

1.1 תפקידי Document A ו-Document B

- **Document A**: מציג מה ידוע בספרות, הראיות והפערים, ואת ההצדקה לבחירת שאלות המחקר.
- **Document B**: מתרגם את המסגרת לסדר פעולות, ניסויים, בקרות, כללי עצירה, בחירת מודלים ומדדים.
- **Stage 1/2/3**: מסמכי הגשה קצרים או דוח תוצאות, שנגזרים משני המסמכים; אינם העתק של מסמך-האב.

לא נייחס למאמר יכולת או תוצאה שלא נמדדו בו; נפריד במפורש בין **ממצא מדווח**, **הסקה זהירה**, **השערת הפרויקט**, **החלטה מאושרת** ו-**תנאי שטרם אומת**. המונח "מאושר" משמעו החלטת עבודה של הצוות, ולא תוצאה מחקרית שכבר נבדקה.

1.2 רישום החלטות: מה נשמר ומה התחדש

רכיב	החלטה שנשמרת	מה נוסף בעקבות שלוש הקריאות והעריכה של A
שאלת המחקר	הכללה לזיופים ומקורות שלא נראו באימון	שלושה צירים מתועדפים ושכבת הערכה משותפת
מודל ראשוני	MFCC + Logistic Regression	שימור M0 כנקודת ייחוס מחייבת, בלי להעמיס ארכיטקטורות
ייצוגים	CQCC, wav2vec 2.0 ובהמשך WavLM	בקרה על בחירת שכבה/Pooling, והפרדה בין ידע של ASR/דיבור לראיות Anti-Spoofing
One-Class	השוואה על אותו Encoder קפוא	הפרדה ברורה בין Pure One-Class לבין Supervised Validation
חלוקה	Speaker-aware, מניעת Leakage	הבחנה בין Leakage אמיתי ל-Protocol Mismatch; קיבוץ נגזרות מקור
הערכה	EER מרכזי, בדיקה לפי מקור/מערכת	Macro-F1, Real/Fake Recall, CI, תיעוד תנאי Threshold והגדרת שלושה סוגי Shift
הרחבת אימון	לא הוחלט מראש על מאגר חיצוני	MLAAD ו-PhonemeDF כ-*Conditional GO* בלבד; ניסויים לבידוד גודל מול גיוון
AT-ADD	אינו מופיע במסמך B הישן	מקור מתודולוגי בלבד, לא Dataset זמין; אימוץ ניתוח כשלי Replay/BigVGAN ו-Real Shift
תנאי קורס	1,520 הקלטות, תחרות נפרדת	עדיפות לכך שכל חידוש יעמוד בדרישות ויהיה ניתן לשחזור

1.3 גבולות הפרויקט

המשימה היא **Recording-Level Binary Speech Deepfake Detection**, לא Speaker Verification, זיהוי מוזיקה מלאכותית, הגנה קריפטוגרפית או זיהוי זיוף מקומי בתוך משפט. חלק מן המאמרים עוסקים בנושאים רחבים יותר; מהם ניקח רעיונות שיש להם הצדקה למשימה שלנו, ולא נרחיב את יעד הפרויקט ללא צורך. אין להתחייב מראש לביצוע Fine-Tuning של כמה Encoders גדולים או לשחזור מערכת תחרותית כמו WaveShield.

2. בסיס מחקרי — מהן הראיות שמצדיקות את התוכנית?

מקור	תרומה לתכנון	מגבלה שחייבים לזכור
ASVspoof 5 [1]	אתגר מתקפות חדשות, דוגמאות עוינות, EER/minDCF ותוקף חלוקות	תנאי הערכה של Benchmark מלא אינם בהכרח מתקיימים בתת-מדגם הקורס
CodecFake [2]	שינוי משפחת הזיוף בעקבות Codec Resynthesis	Codec processing לגיטימי של Real אינו תמיד Fake; לא להסיק כלל גלובלי על "ארטיפקט של Codec"
CQCC [3]	ייצוג ספקטרלי קלאסי להשוואת תכונות	תוצאה על Benchmark מסוים אינה מעידה על יתרון קבוע על נתוני הקורס
AASIST [4]	למידה גרפית ספקטרלית-זמנית; מועמד הרחבה	התוצאות הקלאסיות על ASVspoof 2019 LA אינן הוכחת הכללה לנתוני הקורס
wav2vec 2.0 [5]	Encoder קפוא כבסיס להשוואת ייצוג	Pretraining לדיבור/ASR לא מוכיח יכולת זיהוי זיוף כשלעצמו
WavLM [6]	Encoder חלופי, אפשרות לניתוח שכבות	Denoising/ייצוג עשיר עשויים גם לטשטש ארטיפקטים — לבדיקה ולא להנחה
Enhanced Forensic Trace [7]	Reconstruction ו-Feature Enhancement כהרחבה	תועלת אינה אחידה בין תכונות; עלות חישובית וקיימים במאמר ניסויי Ablation, אך לא על נתוני הקורס ולא לכל הרחבה המוצעת אצלנו
Intelligent Voice Fraud [8]	Fusion ושילוב רמזים	אין לבודד השפעת רכיב כאשר המחקר אינו עושה זאת
One-Class + wav2vec2 [9]	השוואת זיהוי חריגות לסיווג בינארי	Validation עם Fake והבדלי רכיבים מונעים ייחוס שיפור אוטומטי ל-One-Class בלבד
MLAAD [10]	מאגר TTS רב-לשוני ומטא-דאטה של מודלי יצירה	תוצאות Cross-Dataset דווחו על v1; v11 ו-205 מערכות אינם ניסוי הוכחה של "יותר גיוון"
PhonemeDF [11]	TTS+VC מקבילים, יישור פונמות, מקור משותף לניסויי בקרה	KLD/Accuracy ברמת פונמה אינם EER ברמת קליפ; רישוי/קיבוץ מקור דורשים בדיקה
AT-ADD [12]	הפרדת Generators, מדדי Macro-F1, Real Recall, ניתוח תנאי ערוץ ודירוג יציב	Shift משולב אינו מאתר סיבה; 18 דוברי Common Voice חופפים; גישה לאודיו לא אומתה

השלכה מרכזית: התועלת של **שינוי ייצוג**, **שינוי למידה** או **שינוי מאגר האימון** צריכה להימדד בניסוי שמפריד בין שינויים אלה. יתרון מספרי בטבלה מסוימת אינו הוראה להעתיק את המודל שדווח, ומדדים ממאגרים שונים אינם מהווים דירוג משותף.

3. ניסוח שאלת המחקר וההשערות

3.1 שאלת-העל

כיצד בחירת ייצוג הדיבור, פרדיגמת הלמידה והרכב נתוני האימון משפיעים על ביצועי זיהוי זיופים קוליים ועל יכולת ההכללה למערכות ולמקורות שלא נראו באימון, במסגרת פרוטוקולי הערכה שניתן לאמת?

3.2 שלושה צירי מחקר מתועדפים

RQ1 — Representation (ליבת חובה). כיצד משתנים EER ודפוסי השגיאה כשמחליפים MFCC ב-CQCC ובייצוגי wav2vec 2.0, עם אותו ראש סיווג פשוט, אותן חלוקות ואותו תהליך בחירה? השוואת WavLM היא הרחבה ישימה אם תוספת החילוץ מוצדקת.

RQ2 — Learning Paradigm (ליבה מתוכננת). האם על אותו Encoder קפוא, One-Class SVM שמאומן על Real בלבד מתמודד טוב יותר עם מתקפות לא מוכרות לעומת Logistic Regression בינארי? לכל תוצאה יצוין אם נעשה שימוש בתוויות Fake ב-Validation.

RQ3 — Training Data Diversity (מותנה ב-Gates). עבור אותו תקציב דוגמאות אימון, האם הגדלת מספר מערכות/משפחות TTS/VC משפרת הכללה ל-Generators שלא נכללו באימון, מעבר להשפעת הוספת מספר דוגמאות מאותה משפחה? אם לא ניתן לבודד את המשתנים, השאלה תוגדר כניסוי תיאורי מוגבל, ולא כהוכחת סיבתיות.

שכבת הערכה רוחבית: Speaker-Disjoint, Leave-One-System-Out, Cross-Dataset, תנאי ערוץ וניתוח לפי מקור; אינה אוסף שאלות מחקר עצמאיות. התאמת כל פרוטוקול לנתונים תהיה תלויה ב-EDA וב-Metadata.

3.3 השערות ניתנות להפרכה

מזהה	השערה פרה-רשומה	מבחן מכריע	גבול ההסקה
H1 — Representation	Frozen wav2vec 2.0 + LR (M2) יציג EER נמוך יותר מ-M0 על **פרוטוקול ההכללה הראשי שייבחר לפני אימון**	הפרש EER מזווג EER(M2) − EER(M0) שלילי, מדווח עם פיזור/אי-ודאות	יתרון נקודתי בלבד, היפוך בין Folds או יתרון In-domain בלבד אינם אישור גורף
H1b — Alternative Classical	M1 יבדל מ-M0 במאפייני הכשל / EER	M1 לעומת M0 באותם Folds, אותו מסווג ותקציב כוונון	H1b משנית; אין לבחור בדיעבד כיוון חיובי לפי תוצאה
H2 — Learning Paradigm	M3 עשוי להשיג EER נמוך יותר ממערכת M2 במבחן ההכללה הראשי	EER(M3) − EER(M2) עם Real Recall ו-False Alarms על מקור Real חדש	השוואת פרדיגמות שלמות ותקציב תוויות שונה, לא בידוד המסווג לבדו
H3a — Size	תוספת פרופורציונלית של Real ו-Fake מאותו תמהיל Generators עשויה לשפר הכללה	E1 מול E2 על Holdout קבוע, תוך בקרת יחס המחלקות הסופי ב-Train	אינה בודדת את מגוון Generators; אם האיזון משתנה יש לדווח על Confounding
H3b — Diversity Allocation	באותו מספר Fake ו-**Real** חיצוניים, פיזור ה-Fake בין יותר Generators/משפחות עשוי לשפר הכללה	E3 מול E4 עם N ו-R קבועים, רפליקציות הרכב מערכות ו-Real תואם	בוחן **מדיניות הקצאת תקציב**; מספר דוגמאות לכל Generator משתנה בהכרח
H4 — Augmentation	עיבוד מאוזן ב-Real וב-Fake עשוי לשפר עמידות	Perturbed EER ללא פגיעה בלתי סבירה ב-Clean EER	ניתוח משני/הרחבה
H5 — Error Heterogeneity	התפלגות שגיאות אינה אחידה לפי Generator ומקור Real	Fake/Real Recall ותיאורי התפלגות Scores לפי תת-קבוצה	אינו מוכיח איזה מאפיין סיבתי המודל למד

כלל פרה-רישום: "יבחר endpoint ראשי אחד לפי שערי סעיף 6.7, לפני אימון ולפני צפייה בציוני מודל על Test. ההכרעה תדווח כנתמכת / לא נתמכת / לא מוכרעת בגלל אי-ודאות או היתכנות. אין להכריז על הצלחת H1/H2 על בסיס Fold אחד שנבחר בדיעבד. H3a/H3b מותנות בגישה, זכויות, הרכב נתונים ו-Gates, ולא תנאי לסיום הקורס.

4. נתוני הקורס, תוויות והגדרת משימה

4.1 הרכב ידוע ומגבלות מיידיות

מקור	Real	Fake	סה״כ	תפקיד מיועד
ASVspoof 5	300	300	600	אימון/הערכה ובחינת מתקפות TTS/VC
CodecFake	300	300	600	אימון/הערכה ומבחני משפחות Codec
M-AILABS	320	0	320	Real, בקרה על מקור, ותכנון הכללה
סה״כ	**920**	**600**	**1,520**	16kHz, מונו, 4 שניות

לפי מסמך הקורס, `train.csv` כולל תווית, מקור, דובר ומערכת זיוף. **שמות העמודות, מספר המערכות בפועל, זהויות הדוברים והקשרים בין נגזרות לא נבדקו עדיין.** לפני כתיבת קוד חלוקה יש לבחון את הקובץ עצמו, ולא להסיק שה-IDs בעולם המלא של ASVspoof 5/CodecFake מיוצגים במלואם בתת-מדגם.

4.2 שלוש שכבות הגדרה שאסור לערבב

1. **אותנטיות לפי המשימה:** Real/Bona Fide מול Fake/Spoof — משתמשים בתווית הקורס כ-Target מחייב להגשה.
2. **מנגנון יצירת הדוגמה:** TTS, VC, Codec Resynthesis, Neural Vocoder או מנגנון אחר, כשהתיעוד מאפשר.
3. **תנאי עיבוד/ערוץ:** MP3/Opus, Resampling, Replay, רעש או שינוי עוצמה, שאינם בהכרח משנים אותנטיות.

לכן אין לקבוע כלל ש"כל מה שעבר Neural Codec הוא זיוף". בהגדרת CodecFake, Codec Resynthesis מסוים מתויג כ-Spoof; במאגרים אחרים עיבוד דיבור אמיתי בקודק עשוי לשמר תווית Real. בניסויי Robustness נשמרת **תווית הקורס** לאחר עיבוד מותר אלא אם מדובר בפרוטוקול מפורש היוצר דוגמת זיוף חדשה. סתירה אפשרית בין הגדרות מאגרים תתועד ולא תטושטש.

4.3 מוסכמות מודל והערכה

- `label=1` מציין Spoof/Fake ו-`label=0` מציין Real/Bona Fide, אחרי אימות הסכמה בפועל.
- `score` רציף, **גבוה יותר = יותר חשד ל-Fake**; אינו חייב להיות הסתברות מכוילת.
- סף `t` נלמד רק באמצעות Validation כשנדרשת החלטה בינארית; EER מחושב מסריקת ספים אך אינו סף פריסה ידוע מראש.
- אם מסווג One-Class מחזיר ציון "יותר נורמלי", נהפוך את כיוונו פעם אחת, באופן מתועד, לפני כלל ההערכות.

4.4 הבעיה הייחודית של M-AILABS

על M-AILABS לבדו אין Fake ולכן **לא ניתן לחשב EER עצמאי**. ניתן לדווח Real Recall, False Alarm Rate ביחס למחלקת Spoof, התפלגות ציוני Real וביצועי מערכת בסף שנבחר מחוץ ל-M-AILABS. אין להציג שילוב של Real מ-M-AILABS עם Fake ממאגר אחר כאילו היה "EER של M-AILABS"; זהו מבחן מורכב ומוטה פוטנציאלית למקור ודורש תווית פרוטוקול מפורשת. אם M-AILABS נכנס לאימון, לא ניתן באותו ניסוי להציג את אותן הקלטות כ-OOD Real Test.

5. Stage 1 — EDA, Audit ו-Gates לתוקף

5.1 Audit לקובץ הקורס

מכיוון שטרם נפתח `train.csv` וטרם נבדקו מזהי מקור ודובר, הסכמה הבאה היא **סכמת Audit מוצעת**, לא טענה שהשדות קיימים בקבצים. לכל קליפ נוודא: path ומשך תקינים, sample rate, ערוצים, תווית, מקור, דובר, מערכת/משפחה, מקור אותנטי, גרסאות נגזרות ויכולת איתור חפיפות.

שדה Audit	משמעות והערת תקפות
`clip_id`, `path`, `label`	מזהה הקלטה, נתיב מקומי, Real/Fake לפי משימת המקור
`dataset_id`	ASVspoof5 / CodecFake / M-AILABS / MLAAD / PhonemeDF — *שם המאגר אינו מזהה הקלטת אב*
`speaker_id_raw`, `speaker_namespace`, `speaker_global_id`	מזהה מקור, מרחב מזהים, איחוד זהויות רק כשקיימת ראיה
`original_recording_id`	מזהה הקלטת האב הספציפית, אם ידוע; אחרת `UNKNOWN`
`derivation_group_id`	קבוצת מקור וכל נגזרותיה (VC, Codec resynthesis, חלונות, Augmentation), אם ניתנת לזיהוי
`generator_id`, `generator_family`	מערכת ספציפית מול TTS/VC/Vocoder/Codec-resynthesis; `UNKNOWN` אם אין ראיה
`channel_condition`, `processing_chain`	Codec / Noise / Replay / Resampling ותנאי קליטה, אם ידועים
`transcript_id`, `reference_speaker_id`	מזהי טקסט/דובר ייחוס, בהקלטות שתלויות בהם
`audit_confidence`, `audit_evidence`	רמת ביטחון וקישור לראיית המקור עבור קשרים משוערים

בניית יחידת Group: כאשר קליפ קשור לכמה קליפים דרך הקלטת אב, דובר, קטע ארוך או נגזרת, ננהל גרף קשרים ונחשב *רכיבי קשירות* לפי סוגי הקשרים הנדרשים לפרוטוקול. עמודה יחידה אינה מספיקה בהכרח. ברמת source-disjoint נוודא שאין אף קשת נגזרת בין חלקי החלוקה; ברמת speaker-disjoint נוסיף גם קשתות זהות דובר. רכיבי קשירות גדולים מדי יובילו לבדיקה מחדש של היתכנות החלוקה, **לא** לפיצול שרירותי.

תוצר: `metadata_audit` מקומי, `unknowns_report`, רשימת Group IDs ואימות מספר דוגמאות Real/Fake לכל קבוצת Holdout; אין להציג אי-ידיעה כ-Audit שעבר.

5.2 בדיקות התפלגות ו-Shortcut

נפיק טבלאות וצילומים: מקור × תווית, Generator × תווית, דובר × תווית, מספר דוגמאות למערכת/דובר, משכים ותקינות אות. נבדוק גם RMS, Peak, שיעור שקט, DC Offset, רוחב פס, רמות עוצמה, מאפייני Codec/תדר וגבולות חיתוך; נבצע האזנה וספקטרוגרמות לדוגמאות מייצגות. נבדוק אם ניתן לחזות את מקור ההקלטה מתוך מאפיינים על **Real בלבד**, כאבחון של מידע דומייני זמין ולא הוכחה שהמסווג הסופי משתמש בו.

5.3 Provenance ו-Pretraining

- **Source/Derivative Integrity:** כל נגזרת של אותה הקלטת אב חייבת להשתייך לאותה קבוצת פיצול בניסוי הדורש Source-Disjoint. נבדוק גם קטעים שנחתכו מתוך אותה הקלטה ארוכה, השמעות/הקלטות מחדש וגרסאות שעברו Codec Resynthesis.
- **איתור קשרים:** נתיבי מקור, מזהי דובר, Transcript/Content ID, Metadata וקבצים זהים או כמעט זהים. Hash מדויק אינו מגלה Resampling, Codec או סינתזה מחדש; כל התאמה משוערת תקבל רמת ביטחון.
- **Encoder Pretraining:** עבור כל Checkpoint נרשום את נתוני האימון המקדים הידועים, רשימת המקורות שדווחה ואת רמת הוודאות לגבי חפיפה ל-Test. חשיפה לאודיו ללא תוויות אינה בהכרח דליפת תוויות מפוקחת, אך מגבילה טענות של אי-תלות מוחלטת.
- **מאגרים חיצוניים:** לא נניח שאין חפיפה בין M-AILABS ובין MLAAD, או בין LibriSpeech/LibriVox לבין תת-דגימות של ASVspoof/PhonemeDF. בדיקה תבוצע ברמת מקור ככל שהמידע מאפשר.
- **Gate:** חפיפה אסורה מוכחת → תיקון חלוקה או פסילת ניסוי; מקור לא ידוע → ניסוי מוגבל בלבד עם סייג גלוי. אין להחליף את התווית `UNKNOWN` ב-`PASS`.

5.4 Gate-0: האם ניתן בכלל לבצע פרוטוקול חמור?

לפני קביעת יחס Train/Validation/Test נדרש Audit של מספר קבוצות דוברים, מערכות, Real נגיש לכל תנאי, וקשרי מקור. לא נקבע מספר Folds מראש. אם לא ניתן לשמור יחד **Speaker-Disjoint, Source-Family Grouping** **וייצוג שתי המחלקות**, נבחר פרוטוקול חלופי שניתן להצדיק ונדווח במפורש מה לא הושג. **אין לשנות את החלוקה בדיעבד כדי לקבל EER נמוך יותר.**

6. ארכיטקטורת החלוקות ופרוטוקולי הכללה

6.1 קונספט: שלושה פרוטוקולים שונים, לא שמות שונים לאותו מבחן

פרוטוקול	מה מוחזק בחוץ	מה הוא מודד	מה אינו מוכיח לבדו
In-domain grouped evaluation	דוברים ומשפחות מקור (ככל שניתן)	זיהוי על אותה תערובת מקורות בתנאי חלוקה	זיהוי Generator חדש או Domain Shift רחב
Leave-One-System-Out (LOSO)	Generator מסוים או משפחה מוגדרת של זיופים	Unseen-Generator Detection בתנאים שהוגדרו	שינוי מאגר שלם, שינוי ערוץ או דוברים אוטומטית
Cross-Dataset Holdout	כל דוגמאות מאגר היעד	Transfer למקור/דומיין אחר	בידוד סיבת הירידה (מערכת, דובר, Codec, ערוץ)
Perturbation Robustness	וריאציות עיבוד של אותן דוגמאות שמורות	רגישות לשינוי אות מוגדר	Unseen TTS / VC

LOSO פירושו **Leave-One-System-Out** בלבד במסמך זה; אין לבלבל עם Leave-One-Speaker-Out. לא נקרא להערכה "Data Leakage Within-Distribution" רק משום שאותן מערכות יצירה מופיעות משני צדי הפיצול; זהו **Protocol Mismatch** רק אם משתמשים בה לטעון ל-Unseen-Generator Generalization. Leakage אמיתי כולל חציית נגזרות מקור, התאמת Preprocessing על Test או שינוי בחירה לפי ביצועי Test.

6.2 פרוטוקול P0 — הערכה פנימית מאוגדת

1. מתחילים מיחידות Group שלא חופפות ברמת דובר ונגזרות מקור; יחידת קיבוץ מחמירה ככל שהנתונים מאפשרים.
2. בונים Train/Validation/Internal Test או Grouped Nested CV כאשר מדגם הדוברים קטן מדי. מבנה ונימוק מקובעים לפני אימון.
3. מאמנים וכיוונון על Train/Validation בלבד; Internal Test נשמר לדיווח סופי (או משתמשים ב-Outer Folds קבועים מראש).
4. שומרים בדיוק את אותם קבצי חלוקה לכל המודלים להשוואה מזווגת.
5. מדווחים EER כולל, כיוון Scores, מספר Real/Fake, ומדדי החלטה בסף Validation.

סיכון: דובר יכול להופיע בשני מאגרים תחת מזהים שונים; בלי אימות אי אפשר להכריז Speaker-Disjoint מלא. חלוקת Test המכילה רק מחלקה אחת לא תספיק לחישוב EER.

6.3 פרוטוקול LOSO — P1, Unseen Systems

הגדרה: Leave-One-System-Out, לא Leave-One-Speaker-Out. לפני הכנת Split נזהה Generator מועמד g, ואת הקלטות Real המתאימות שייכללו במבחן. כל Fake של g תוחזק מחוץ ל-Train **ומכל בחירת Hyperparameters, שכבה, Pooling וסף**.

Strict LOSO (ברירת מחדל לטענת הכללה מחמירה): כאשר מזהי הקלטות אב ידועים, **כל נגזרת של כל מקור הקלטה הנמצא ב-Test חייבת להיות מחוץ ל-Train/Validation**, גם אם היא נוצרה ב-Generator אחר. זאת בנוסף לאי-חשיפה למערכת g. נוודא זאת בבדיקת רכיבי קשירות. אם נטען גם ל-Speaker Generalization, נדרוש *בנוסף* הפרדת זהויות דוברים. העברה של נגזרת Codec A של מקור X ל-Train ושל Codec B של אותו X ל-Test **לא תעבור** .**Strict LOSO**

Generator-Held-Out מוגבל: אם אין מזהים שמאפשרים לאמת את אי-התלות ברמת המקור, עדיין אפשר לפרסם תוצאה מותנית שמערכת g עצמה לא נראתה באימון, אך עם תווית `source independence unverified` וללא טענת Strict LOSO או Speaker-Disjoint.

Real Controls: נבחר Real באופן מוגדר מראש, רצוי מאותו מאגר ובתנאים תואמים, ותוך מניעת חפיפת משפחות מקור. לא ניצור מצב שבו Fake של Generator חדש נבדק מול Real ממאגר אחר ללא הודעה מפורשת על Dataset–Label Confounding. לכל Fold נרשום מספר `n_real`, `n_fake`, `n_speakers`, `n_derivation_groups`, `generator_id` וגרסת חלוקה.

Nested Selection / Evaluation: לכל Generator מוחזק בחוץ, בחירת המודל תתבצע רק על Train/Inner Validation מתוך המערכות המותרות; נתוני g לא ישמשו לשום התאמה. סף קבוע יוצא מ-Validation, לא מה-Fold החיצוני. אם קבוצת המבחן אינה מכילה שתי מחלקות או קטנה מדי, נדווח מגבלה ונימנע מ-EER שאינו מוגדר או אינו יציב/Recall.

תנאי ביצוע: בדיקת היתכנות של מזהי Generators, נגזרות, דוברים וגדלים ב-EDA; לא נניח שמזהים מן המאמר המלא (כגון A09–A16) נמצאים אוטומטית במדגם הקורס.

6.4 פרוטוקול P2 — Cross-Dataset

דרישת הערכה בעדיפות גבוהה הנגזרת מהקורס: בכפוף לנתוני מקור תקינים, נבצע את שני הכיוונים:

1. אימון + בחירת מודל על ASVspoof 5 בלבד; הערכה חיצונית שמורה על CodecFake.
2. אימון + בחירת מודל על CodecFake בלבד; הערכה חיצונית שמורה על ASVspoof 5.

לכל כיוון יש קבוצת יעד בעלת Real ו-Fake, ולכן EER מוגדר כאשר שתי המחלקות מיוצגות בפועל. כל הקלטות מאגר היעד נשארות מחוץ לאימון, להחלטות עיצוב, לבחירת Hyperparameters ול-Threshold. **אין לשלב M-AILABS או מאגר חיצוני בתוך אימון הניסוי ולתאר אותו כ-Train-on-Source-Only**; אפשר לתכנן ניסוי תוספת נפרד בשם אחר. אם יתגלו חפיפות מקור/דובר לא פתירות, נתקן את הניסוי או נסמן את המגבלה ונעלה את הסוגיה מול המרצה — לא נבטל בשקט דרישת Cross-Dataset.

גבולות הטענה: המעבר מערב Generator, דובר, מקור וערוץ; ההבדל אינו אפקט סיבתי של Generator בלבד. כל כיוון ידווח בנפרד, ללא חיבור אוטומטי של Scores או השוואה כאילו הם אותה אוכלוסייה.

M-AILABS: Real-only Audit בסף קבוע על קבוצה שהוחזקה מחוץ לאימון; או Real נוסף לאימון בניסוי אחר. אין EER עצמאי למאגר אמיתי-בלבד ואין שימוש באותם קליפים בו-זמנית בשני תפקידים.

6.5 פרוטוקול P3 — Acoustic/Channel Shift

על Test שמור יוצרים **העתקים מתועדים** של אותן הקלטות עם עיבודים כגון MP3/Opus compression, resampling, רעש/הדהוד, שינויי עוצמה או Replay *רק אם קיימת סביבה מתאימה*. נגזרות Test נועדו **להערכת Robustness בלבד**; לא לאימון או בחירת מדיניות Augmentation. אם משנים אותו קליפ במספר דרכים, היחידה הסטטיסטית נשארת **הקלטת המקור**, לא כל עותק כעצמאי.

יש לשמור אותן טרנספורמציות והתפלגות עוצמות/רעש ב-Real וב-Fake כדי לא ליצור קיצור דרך של מחלקה. Replay פיזי אינו שקול להדמיית קודק תוכנתית, ולא נטען שבדקנו Replay אמיתי אם ביצענו רק דחיסה. הבדלי Clean vs Perturbed יוצגו עם אי-ודאות וברמת תנאי.

6.6 מיקום מבחן התחרות

קבוצת התחרות של הקורס **אינה** Internal Test לצורך מחקר ותכוונון. לאחר בחירת תצורה באמצעות הנתונים המותרים, נבצע `Final Model Freeze` לפני שחרור קובצי המבחן: Hash של משקלים, Encoder, Preprocessing, Feature Order, Scaler/Normalizer, Threshold אם קיים, Score Direction, תוכנה ו-Dependencies, Config ו-Commit SHA. אם מחליטים לבצע *Final Refit* על Train+Validation, המדיניות והתצורה ייקבעו מראש, והאימון יסתיים **לפני פרסום קטעי המבחן** ובהתאם להנחיות הקורס.

לאחר פרסום Test: Inference בלבד; מותרת בדיקת פורמט/שלמות הקובץ ולא התאמת מודל. תוצר `id,score` עם Score גבוה = יותר Spoof, שורה אחת לכל ID. לא עושים Pseudo-Labeling, חיפוש דוגמאות מקוריות, ניתוח שמטרתו לנחש תוויות או אימון מחדש בעקבות הבדיקה; מתכננים מראש את ההגשה היחידה.

6.7 בחירת פרוטוקול ההערכה הראשי ו-Test Governance — החלטה לפני מודלים

Decision Gate אחרי EDA ולפני אימון/בחינת Scores: ננעל `evaluation_contract.yaml` ובו: (1) פרוטוקול מחקר ראשי; (2) Folds/Groups ורשימות Hash; (3) endpoint ראשי EER והגדרת חישוב; (4) כללי Aggregation ו-Uncertainty; (5) מטריצת השוואות M0–M3; (6) מועדי חשיפה מותרת של תוצאות Test.

היררכיית בחירה: `P1 Strict LOSO` אם קיימת חלוקה עם מקור/מערכות ודוגמאות Real+Fake מספיקות, וניתן להבטיח את אי-התלות הנדרשת; אחרת `P2 Cross-Dataset` כ-endpoint הראשי כשהוא ישים ונקי מחפיפות מהותיות, עם שני כיוונים מדווחים בנפרד וכיוון ראשי שנקבע מראש; אחרת `P0 Grouped Internal Evaluation` בלבד, עם הודעה שטענת unseen-generator לא נבדקה. **בלי קשר ל-endpoint הראשי, P2 נשאר יעד הערכה בעדיפות גבוהה לפי דרישות הקורס**. הכשל בהיתכנות מתועד מבלי להחליף פרוטוקול לאחר ראיית תוצאות המודלים.

שכבת נתונים	פעולות מותרות	מה אסור
Train	התאמת מאפיינים נלמדים, Scaling, אימון מודלים	חשיפה לקליפי Eval/נגזרותיהם
Inner Validation	בחירת Hyperparameters/Architecture/Layer/Pooling, Calibration	השתתפות ב-EER הסופי כאילו לא שימשה לבחירה
Internal Test קבוע או Outer Fold	**מדידת תצורות ונוהל בחירה שנקבעו מראש בלבד**	בחירת מודל חדש/Prompt/Threshold בעקבות ביצועי ה-Test
Competition Test	Inference בפייפליין קפוא	אימון, בחירת מודל, כיול, Pseudo-labeling

חלופת הערכה אחת: ניתן לבחור `Train + Validation + Locked Internal Test` או `Nested Grouped CV` בהתאם למספר קבוצות האימון, לא את שתיהן יחד ללא סיבה. ב-Nested CV נעשית כל בחירת פרמטרים בתוך Inner Folds; Outer Folds מיועדים להערכת תהליך הבחירה. אם השוואת מודלים על Internal Test מגלה צורך בשינוי מחקרי, ניתן לרשום את התובנה כ-*Exploratory* ולבצע כוונון רק בנתוני אימון/Validation; אין לדווח שיפור מאוחר על אותו Test כאישור עצמאי. לצורך אימות חדש דרוש Holdout/ניסוי חיצוני שלא השפיע על ההחלטה.

פרה-רישום סטטוס: אחרי EDA תופק רשומת `PRIMARY_PROTOCOL_LOCKED` לפני תוצאות M0–M3. כל שינוי בהמשך מקבל `protocol_deviation` עם סיבה ותוצאה על תוקף ההסקה.

7. מדדים, ספים, סטטיסטיקה והשוואה הוגנת

7.1 מדד ראשי: Equal Error Rate

מערכת משיבה לכל קליפ ציון Spoof רציף. נגדיר `FPR_spoof(t)` כיחס Real שסווגו כ-Fake ו-`FNR_spoof(t)` כיחס Fake שסווגו כ-Real. EER הוא שיעור השגיאה סביב סף שבו שני השיעורים שווים, לפי כלל אינטרפולציה או בחירת סף מוגדר מראש ואחיד לכל המודלים. **EER נמוך יותר טוב יותר.** תעדוף דיוק סף האינטרפולציה פחות חשוב מעקביות החישוב; נבדוק זאת ב-Unit Tests ובדוגמאות ידועות.

7.2 מדדי החלטה משלימים

- `Macro-F1 = (F1_Real + F1_Fake)/2`, כאשר הסף נבחר **רק ב-Validation.**
- `Fake Recall = TP_fake / N_fake`, כלומר שיעור הזיופים שזוהו.
- `Real Recall = TN_real / N_real`, כלומר שיעור ההקלטות האמיתיות שנשמרו כאמיתיות.
- `False Alarm on Real = 1 - Real Recall`; עבור M-AILABS זהו מדד Real-only חוקי.

- Precision, Confusion Matrix, התפלגות Scores ו-Balanced Accuracy במידת הצורך.

Macro-F1 תלוי בסף ובשכיחות המחלקות ואינו זהה ל-EER. לא נשווה מספרית 90.71% Macro-F1 של AT-ADD ל-EER של מודל אחר. `minDCF` ו-`min t-DCF` רלוונטיים להבנת ספרות ASV אך לא יחליפו את EER של מטלת הקורס, אלא אם יוגדרו מראש עלויות והסתברויות תקפות.

7.3 תכנון Threshold ושמירת ציונים

לכל מודל נגדיר Score Direction, ורק לאחר מכן נבחר Threshold על Validation לצורך מדדים המחייבים החלטה. את סף Validation נקפיא לכל קבוצות Test, כולל OOD. נשמור ציונים רציפים, תוויות ומזהי קבוצה מקומיים (לא בפרסום אסור) כדי לחשב ROC/EER וניתוח כשל. אין לבחור סף OOD בדיעבד לפי שיפור Macro-F1.

7.4 Uncertainty ו-Statistical Stability

- לכל Fold ולכל Generator בנפרד: `n_fake`, `n_real`, קבוצות מקור, EER, FPR/FNR בסף Validation, נתוני Generator ומקור. מדד שאינו מוגדר במבחן חד-מחלקתי יישאר `NA`, לא יוחלף ב-Accuracy.
- הדיווח הראשי על מספר Folds הוא **EER לכל Fold וממוצע/חציון ופיזור בין Folds**, תוך הצגת גדלים. ממוצע לא משוקלל מעניק משקל שווה ל-Folds; לכן נדווח את המשקל וההגדרה במפורש.
- **לא מאחדים Scores של מודלים שונים בין Outer Folds ל-EER גלובלי בלי הצדקת כיול וסולם משותף**, שכן אף אם ציון כל מודל מדורג היטב, סולם הציונים עשוי להשתנות בין אימונים.
- נשווה מודלים על אותם קליפים באותו Fold באמצעות `ΔEER = EER(candidate) − EER(reference)`; ערך שלילי טוב יותר, אך בלי CI/יציבות לא נטען למובהקות. מספר Seeds ו-Repeats ייקבעו ב-Experiment Contract לפני ריצה.
- Bootstrap ברמת Group/דובר/מקור לפי היחידה המתאימה כאשר מספר הקבוצות מאפשר זאת; נוודא שבכל דגימה חוזרת קיימות שתי המחלקות. עבור מדגם דל נדווח אי-ודאות מהותית ולא נסתיר אותה מאחורי CI צר מדי.
- הסקת מסקנות תבחין בין שונות Data Splits, שונות Training Seeds ושונות דגימת Generators. אלה שלושה מקורות אי-ודאות שונים; לא נשתמש ב-SD בין Seeds בלבד כ-CI של הכללה.
- אם העלות החישובית שונה במידה משמעותית, נדווח זמן חילוץ/אימון/חיזוי וזיכרון לצד איכות, ולא נבחר אוטומטית במודל גדול בשל שיפור זעיר.

7.5 איסור על Data Leakage וסיווג נכון של Protocol Mismatch

Leakage: שימוש ב-Test לצורך Selection, חציית נגזרות מקור, Feature Scaling על כל המידע, שימוש ב-Labels של Test, או כיול על מדגם הערכה. **Protocol Mismatch:** מבחן תקין בתוך אותו Generator שמתואר בטעות כהכללה ל-Generator שלא נראה. **Confounding:** שינוי משולב של Generator, דובר, מקור וערוץ גם כשהחלוקה תקינה. ההבחנות יופיעו בכל דיווח ניסוי.

7.6 Primary Endpoint, קריטריון הכרעה ובחירת מודל תחרות

Primary Research Endpoint: EER בפרוטוקול ההכללה הראשי שנגעל בסעיף 6.7. השוואת H1: M2 מול M0; השוואת H2: M3 מול M2. M1 מול M0 ניתוח ייצוג משני מתוכנן. מכיוון שכיוונים/מופעי Generator אחדים עשויים להיות שונים בקושי שלהם, נדווח פר-Fold ונמנע מבחירת ה-Fold המיטיב בדיעבד.

Secondary Endpoints: P0 in-domain EER, שני כיווני P2 (אם אינם Primary), Real Recall על M-AILABS מוחזק, Fake Recall לפי Generator, Macro-F1 בסף Validation, Confidence/יציבות, והתפלגות עלויות חישוב.

כלל הכרעה איכותני, ללא סף שרירותי שהומצא: (1) האם כיוון ההפרש ב-Primary Endpoint מתאים להשערה? (2) מה גודלו ופיזורו על פני Folds/Repeated Sampling? (3) האם השיפור מלווה בהחמרה משמעותית ב-Real Recall או בתנאי OOD אחרים? (4) האם ההשוואה תקפה לפי Split Audit? (5) מהי עלות המודל? נסכם `supports / does not support / inconclusive`, ולא נבחר תוצאה נעימה אחת מתוך שורה של תוצאות.

בחירת המודל לתחרות היא החלטה נפרדת: מתבצעת על Validation שמייצג את נתוני הקורס/מטרת התחרות, לפני Test, ויכולה להעדיף מודל שאינו בעל EER ההכללה הטוב ביותר. שתי הבחירות והתוצאות יופיעו בגלוי בדוח; אין להציג הצלחה תחרותית כהוכחה לאותה השערת הכללה.

8. תוכנית מודלים מדורגת

8.1 מטריצת מודלים

מזהה	Input/Encoder	Classifier	תפקיד	סטטוס
M0	MFCC, סטטיסטיקה בזמן	Logistic Regression	Baseline; השוואת ייצוג	**ליבה מחייבת**
M1	CQCC, Pooling תואם	Logistic Regression	השוואת ייצוג קלאסי	**ליבה מחייבת**
M2	Frozen wav2vec 2.0 Base, שכבה/Pooling מוגדרים	Logistic Regression	ייצוג SSL והשוואה ל-M0	**ליבה מחייבת**
M3	Frozen wav2vec 2.0 אותו	One-Class SVM	בחינת RQ2 על אותו Encoder	**ליבה מתוכננת; Gate/Stop מפורש**
M4	Frozen WavLM	Logistic Regression	השוואת Encoders	הרחבה
M5	SSL + Pooling/Layer אחר	ראש קל	מידע מקומי/שכבות	הרחבה
M6	AASIST-L / Deep SVDD	ייעודי	מודל עמוק	הרחבה
M7	Feature Fusion / Reconstruction / Ensemble	משולב	בידוד רכיב חדש	הרחבה

השלישייה M0–M2 מקיימת את דרישת Baseline + שתי גישות נוספות. **M3 הוא הניסוי המתוכנן לשאלת הליבה RQ2**, משום שה-Embeddings כבר חושבו; ויתור עליו יהיה החלטת Stop מתועדת בשל בעיית תקפות, נתונים או משאבים, ו-RQ2 לא תדווח כנבחנת במקרה כזה. M4–M7 אינם התחייבות.

8.2 M0 — MFCC + Logistic Regression

Pipeline: WAV → בדיקת MFCC (תצורה ראשונית: 20 מקדמים; Frame ~25ms; Hop ~10ms) → Mean+Std Pooling לאורך זמן → StandardScaler על Train בלבד → Logistic Regression → Spoof Score רציף. הערכים המוצעים אינם אופטימליים מוכחים. נבחר בתחילה תצורה פשוטה אחת כדי לקבוע EER ראשון, ולא נפתח חיפוש Hyperparameters לפני תקינות ה-Pipeline.

Acceptance: Notebook בר-הרצה מהתחלה; EER שנמדד בפועל; Confusion Matrix בסף Validation קובע חלוקה ו-Config; גרסאות ספריות ו-Seed; היעדר שימוש ב-Test לבחירת תצורה.

8.3 M1 — CQCC מול MFCC

נחליף את המאפיינים ל-CQCC, תוך שימוש ב-Logistic Regression ובאותם Splits ו-Endpoint. לצורך שחזור יש לקבע ב-Config: גרסת מימוש CQT/CQCC, טווח תדרים, bins-per-octave, מספר coefficients, טיפול ב-C0, Delta/Delta-Delta, Frame/Hop או זמן יחידה, Preprocessing, Mean/Std

Pooling, ממד הפלט וספריות. ערכים שלא נבחרו עדיין ייסגרו ב-Validation ולא יומצאו במסמך.

הוגנות: נשמור אותו סוג מסווג, אותו Budget לחיפוש Hyperparameters (למשל אותה רשת ערכי C), אותו Inner CV ואותו מדד בחירה — **לא בהכרח אותו ערך C נבחר**, מפני שממדי והתפלגויות הייצוג שונים. נתעד את היקף המאפיינים ואת העלות הנוספת.

M2 — Frozen wav2vec 2.0 + Logistic Regression 8.4

Checkpoint של wav2vec 2.0 Base ייקבע במפורש (`model_id`, revision/hash, Processor ו-library versions), ויטען ב-Eval Mode עם משקלים **קפואים**. יירשמו: Sample Rate, נרמול Waveform, טיפול ב-Padding/Attention Mask, חילוץ Hidden State מאיזו שכבה, מסכת זמן שנכנסת ל-Pooling, Mean או Mean+Std, ממד Embeddings, תצורת Chunking ולוגיקת חיתוך אורך. **לצורך השוואת הליבה RQ2 (M2 מול M3-OC-Pure), ה-Checkpoint, השכבה וה-Pooling ייקבעו לפני ניסוי הסיווג לפי כלל בלתי-מפוקח או החלטה מתועדת מראש, ללא בחירה לפי תוויות Fake או EER מתויג.** ערכי הייצוג המשותף יינעלו ב-Experiment Contract לפני התאמת ה-Downstream. מותר לערוך *בנפרד* ניסוי שיפור ייצוג עבור M2 בלבד, שבו שכבה/Pooling נבחרים ב-Inner Validation מתויג; תוצאותיו לא ישנו בדיעבד את ייצוג RQ2 ולא ייקראו OC-Pure אם יועברו ל-M3. כל חיפוש ייחשב Hyperparameter Search ויתועד.

נחלץ Embeddings על 4 *שניות* עם Cache מקומי שמפתחו `clip hash + checkpoint` `revision + feature config`, ונאמן Logistic Regression עם **אותו תקציב כוונון** של M0/M1. Scaling מותאם על Train בלבד. אין לבחור שכבה או Training Seed לפי Test. חישוב Embeddings ב-Apple Silicon יתועד עם Device, Batch Size, RAM וזמן חילוץ.

M3 — Binary 8.5 לעומת One-Class

יעד ליבה: השוואת M2 ל-M3 על אותו Encoder, אותה תצורת Embeddings **שנבחרה ללא תוויות Fake מראש** ואותן קבוצות Evaluation — אך תחת תקציבי מידע שונים במכוון. התואר OC-Pure חל על **כל שרשרת בחירת הייצוג, ההתאמה, הכוונון והסף** (למעט Pretraining כללי של Encoder שקיים קודם ושיתועד בנפרד), ולא רק על ה-`fit()` של המסווג.

שלב	M2 Binary	M3 `OC-Pure`	M3 `OC-Supervised-Val` (ניתוח משני)
Checkpoint / Layer / Pooling	**נעולים מראש ל-RQ2, ללא Fake-labelled selection**	**אותו ייצוג נעול, ללא Fake-labelled selection**	אותו ייצוג נעול לצורך בידוד השפעת הכוונון; בחירה מפוקחת של הייצוג תחייב ניסוי נפרד שאינו OC-Pure
PCA, `StandardScaler.fit`, Feature Selection אם נלמדים	Train Real+Fake	**Train Real בלבד**	Train Real בלבד, כל עוד מטרתנו לבודד השפעת Validation ולא לשנות את האימון
Classifier	LR על Real+Fake Train	One-Class SVM על Real Train בלבד	אותו One-Class SVM על Real בלבד
Hyperparameters (`nu`, `gamma`)	LR `C` מ-Inner Val מתויג	קבועים מראש / Real-only Inner Validation	מתויגים ב-Inner Validation עם Fake; חובה לכתוב זאת
Threshold בסיווג קשה	Inner Val מתויג	כלל Real-only, לדוגמה quantile שהוגדר מראש	Inner Val מתויג
Model Selection	מתויג	**ללא גישה לתוויות Fake, גם לא בשלבים נלמדים מקדימים**	תוויות Fake נגישות רק ב-Validation
Test/Eval	אותו Manifest	אותו Manifest	אותו Manifest

Score Direction: `OneClassSVM.decision_function` גבוה יותר עבור Inlier; נגדיר `spoof_score = -decision_function` לכל בדיקות ה-EER. היפוך הכיוון אינו משתנה נלמד. עבור סטיית Pretraining של Encoder כללי, נתוני אימון מוקדם יתועדו בנפרד ולא יוצגו כאימון One-Class המפוקח.

בחירת `nu` ו-`gamma` ב-OC-Pure: ברירת המחדל היא לקבע *מראש* `nu` ו-policy של `gamma` (למשל כלל מחושב מ-Real Train בלבד) לפני צפייה בציוני Fake או בתוצאות Test, ולתעד את הערכים או את הפונקציה המדויקת בקובץ Config. לחלופין, מותר להשתמש בקריטריון Real-only **לא טריוויאלי** שנרשם מראש ונמדד על Real Validation שאינו משמש להתאמה; יש לציין במפורש מה הקריטריון ואיך הוא מופרד מכיול הסף. **אין לבחור `nu`/`gamma` לפי Real Recall כאשר לכל מועמד מכיילים על אותה קבוצת Real Validation סף לאחוזון קבוע**, משום ששיעור הדחייה יהיה כמעט קבוע בהגדרה ולכן אינו מבחין בין המועמדים. סף הפעלה, אם נדרש, ייקבע לפי כלל Real-only מוגדר מראש; EER יחושב לאחר מכן

בדיעבד על Eval עבור כל המודלים, ללא שימוש בו בכוונון OC-Pure. ב-OC-Supervised-Val אפשר לבחור פרמטרים וסף לפי Validation מתויג, אבל יש לסמן את התוצאה כגרסת One-Class עם בחירה מפוקחת, ולא כ-OC-Pure.

פירוש מותר: השוואה בין *פרוטוקול בינארי מתויג ל-פרוטוקול חד-מחלקתי ללא בחירה מפוקחת ב-Fake לאורך כל שרשרת התאמת ה-Downstream ובחירת הייצוג הנעול*, הכוללת את ההבדל ב-Scaler וב-Classifier. היא אינה Ablation המבודד רק את פונקציית הסיווג. נבדוק גם False Alarms על Real ממקור חדש כדי לזהות האם One-Class מסווג שונות אותנטית כזיוף.

Stop: אם אין מספיק Real עצמאיים ב-Train/Inner Validation או שה-Scores דגנרטיביים, נתעד אי-ישימות; לא נשנה את הגדרת OC-Pure רק כדי לשפר תוצאה.

8.6 WavLM, AASIST ו-Pooling מקומי כהרחבות

WavLM מספק תחרות על ייצוג SSL, לא הבטחת שיפור. AASIST-L אפשרי אם יש הצדקה לניסוי ייעודי ויכולת חישובית. PhonemeDF מצביע על שונות ארטיפקטים לפי פונמה; מכאן **השערה שלנו** ש-Temporal Mean Pooling עלול להחליש סימני זיוף מקומיים. ניסוי בין Mean לבין Max/Attention Pooling יכול להיבחן מאוחר יותר, אך אין לטעון שמאמר PhonemeDF כבר הוכיח זאת ברמת הקלטה. חלונות הקלטה ארוכים/Sliding Windows אינם עדיפות כשכל קליפ קורס הוא ארבע שניות.

9. פרוטוקול חדש: הרחבת אימון מבוקרת באמצעות MLAAD ו-PhonemeDF

9.1 תפקיד המקורות והחלטת גישה

מקור	מה הוא תורם	סיכון בולט	החלטת שימוש
MLAAD (גרסת v11 מתוארת)	מאגר סינתטי בעיקר TTS, 205 מודלים, 54 שפות, מטא-דאטה	אין Real בהפצה עצמה; מקור M-AILABS; רישיונות ותלות דובר/טקסט	Conditional GO לפיילוט קטן בלבד
PhonemeDF	4 TTS + 3 VC, 28,539 משפחות מקור מ-LibriSpeech, הקלטות/TextGrid מקבילים	נגזרות מאותה הקלטה; רישוי נגזרות וגבולות פונמה	Conditional GO לפיילוט קטן; עדיפות לדוגמאות Record-Level
AT-ADD Track 1	פרוטוקול הערכה ל-Unseen Generators ו-Channel Shift	אין גישה מעשית מאומתת; תנאי רישוי לא נבדקו	**לא** לאימון ולא ל-Test ישיר בשלב זה

התוצאות שדווחו על MLAAD אינן מאמתות שגרסת v11 משפרת הכללה לעומת v1. התוצאות הפונטיות של PhonemeDF אינן מאמתות שיפור EER בהרחבת אימון. לכן כל החלטת שילוב מותנית **בניסוי שלנו** וב-Gates של סעיף 9.2.

9.2 Dataset Admission Gates — לפני הורדת אודיו בהיקף משמעותי

G1 — Access: URL, הרשאות הורדה, היקף קבצים ותיעוד הגרסה ניתנים לאימות. **G2 — License:** זכויות השימוש, ההפצה והנגזרות של ה-Audio, המודל, קובצי ה-Real והמקורות בנפרד מאומתות; מחקר אקדמי אינו פוטר מבדיקת תנאים. עבור MLAAD הוצהר CC BY-NC 4.0 בדף המאגר שנבחן; יש לאמת בעת ההורדה ולבדוק את מקורות ה-Real בנפרד. עבור PhonemeDF אין להניח שכל נגזרות הסינתזה מורשות אוטומטית לפי רישיון Source IDs. **G3 — Provenance:** LibriSpeech, דוברים, טקסטים, Generator/Family, קבצי ייחוס וקשרי מקור זמינים ומובנים. **G4 — Overlap:** אין חפיפה אסורה לקליפי הקורס המוחזקים ב-Test או ל-Negatives שמיועדים להערכה חיצונית; בודקים במיוחד M-AILABS/MLAAD ו-LibriSpeech/LibriVox. **G5 — Compute:** פיילוט קטן ניתן לעיבוד מקומי ומשאיר זמן להרצת הניסויים הראשיים. **G6 — Balance:** ניתן ליצור קבוצות Real+Fake בעלות הרכב מקור נשלט ונתוני Eval שאינם זולגים ל-Train. **G7 — Reproducibility:** מזהים, גרסה, סקריפט בחירה, רשימת דוגמאות ו-seed נשמרים.

כל Gate יירשם כ-`PASS`, `FAIL` או `UNKNOWN`, עם ראיה. **UNKNOWN אינו PASS**. אם G2/G3/G4 נכשלים, אין לכלול את המאגר בניסוי עיקרי ולא להציג מסקנת גיוון. אם ניתן להשתמש רק ב-Fake ולא ניתן ליצור Real מתאים, נדווח שהניסוי חשוף ל-Dataset–Label Confounding, ולא נטען שניטרלנו אותו.

9.3 סיכוני מקור ואיזון מחלקות

MLAAD מבוסס על הקלטות/טקסטים הקשורים ל-M-AILABS. לכן **הרחבת Fake מ-MLAAD מול Real קבוע ממקור אחר** יכולה לגרום למסווג ללמוד מקור במקום Fake. PhonemeDF מאפשר Real תואם מאותו LibriSpeech, אבל כל 7 הנגזרות של מקור צריכות להישמר באותה חלוקה, ובחירת TTS מול VC עשויה לשנות את סט הדוברים, אופן ההתניה והערוץ. אם נשתמש רק ב-Fake מסוים ו-Real ממאגר אחר, נדרש להציג זאת כתנאי מוגבל; עדיפות ניסויית היא **paired/matched-source** כאשר הרישוי והנתונים מאפשרים.

בעיית התחרות הפנימית: 320 דוגמאות M-AILABS הן Real בלבד. אין לבחור אוטומטית בדוגמאות Real אלה כ"חצי מאוזן" לכל ה-Fake החיצוני ולקרוא לתוצאה מבוקרת; זה עלול להגדיל Shortcut Learning. נעדיף Real תואם לכל מקור, ואם אינו זמין נבחן אפשרות לעכב את ניסוי ההרחבה.

9.4 מטריצת הניסויים: Size × Diversity

נסמן N כמספר **דוגמאות Fake חיצוניות** שנבחרות בנוסף ל-Train הקבוע של הקורס; R כמספר **דוגמאות Real חיצוניות**; K כמספר מערכות Generator ייחודיות; F כמספר משפחות Generator (TTS/VC/Codec, כשזמין). את מקור, טקסט, שפה, מספר משפחות מקור עצמאיות ויחס המחלקות **הסופי בכלל Train** נתעד בנפרד. **ב-Contrast S (E1 מול E2) N ו-R יגדלו יחד באופן פרופורציונלי**, כך שהיחס בין המחלקות והתמהיל הכולל יישמרו ככל האפשר. אי אפשר לשמור גם על R קבוע וגם על יחס מחלקות קבוע כאשר N משתנה. לעומת זאת, **ב-Contrast D (E3 מול E4) גם N וגם R יישארו קבועים**, כדי לבחון הקצאת אותו תקציב למגוון Generators. **N ו-R אינם כוללים Validation/Test**; אין להעביר נגזרות של אותו מקור בין החלוקות.

ניסוי	Train של הקורס	Fake חיצוני	Real חיצוני	גיוון	השאלה הנבדקת	פירוש מותר
E0 — Course Only	קבוע	0	0	בסיס	עוגן ביצועים	EER ללא הרחבת אימון
E1 — Size Low	זהה ל-E0	`N_low`	`R_low`	`K=K0`	השפעת הגדלת הכמות בהרכב קבוע ככל האפשר	מגמה לפי נפח, כאשר יחס המחלקות נבדק ומבוקר
E2 — Size High	זהה ל-E0	`N_high`	`R_high`	אותו `K0` ומשקל פרופורציות	שינוי כמות Real ו-Fake יחד	Size בתנאי תמהיל, לא Diversity
E3 — Diversity Low	זהה ל-E0	`N_high`	`R_high`	`K0` מערכות	קבוצת בקרה ב-N/R קבועים	בסיס להשוואת מגוון
E4 — Diversity High	זהה ל-E0	**אותו `N_high`**	**אותו `R_high`**	`K1>K0` ו/או `F1>F0`	הקצאת אותה כמות דוגמאות ליותר Generators	השפעת הקצאת N קבוע בין יותר Generators, בכפוף לבקרות
E5 — Both Sources	זהה ל-E0	תקציב מוגדר מראש	Real תואם לפי Gate	MLAAD + PhonemeDF	העברה בין מקורות/משפחות	ניסוי משולב, לא בידוד רכיב יחיד

הערה: E2 ו-E3 יכולים להשתמש **באותה זרוע ניסוי**; הם מופיעים בשני תפקידים אנליטיים. אין לטעון ל"שש זרועות עצמאיות" אם חלק מהנתונים זהים. ערכי `N_low`, `N_high`, `K0`, `K1` לא ייקבעו עד ל-Gates ו-EDA. יש להבטיח שמספר משפחות המקור עצמן אינו משתנה באופן מכוון כאשר מנסים לבודד רק את K, ושהשוואות אינן עוברות מ-TTS בלבד ל-TTS+VC תוך טענה שמדדו רק מספר Generators. **מספר Generators ומספר משפחות הן שתי רמות שונות של מגוון.**

9.5 השוואות ראשיות וכיצד מונעים Confounding

Contrast S — Size Effect: E1 מול E2, עם אותה רשימת Generators בקירוב, אותן משפחות ומקורות Real, אותם יחסי TTS/VC ואותן שיטות עיבוד. נגדיל את **`N_low` → `N_high`** ואת **`R_low` → `R_high` באותו גורם גידול**, ככל שהזמינות של מקורות Real תואמים מאפשרת, ונוודא את שיעור המחלקות **בכלל Train לאחר צירוף בסיס הקורס הקבוע**, ולא רק בחלק החיצוני. מכיוון שיחס הבסיס הוא Real 920 מול Fake 600, הוספה ביחס 1:1 לא תשמור בהכרח על יחס הבסיס. אפשר לבחור יחס תוספת התואם את בסיס הקורס או מדיניות דגימה/איזון זהה ומוצהרת בכל הזרועות; אם ההרכב הסופי אינו נשמר, נדווח שההשוואה כוללת גם שינוי Class Balance ולא נייחס את התוצאה ל-Size לבדו. נקבע

מראש תמהיל מקור/דובר/שפה, דגימה פרופורציונלית לכל Generator ומדיניות Balance/Weights קבועה, ונתעד את מספר ההקלטות **העצמאיות ברמת מקור** לצד מספר הקבצים. נעדיף זרוע קטנה שהיא תת-דגימה מקובצת של הזרוע הגדולה, בלי שימוש בתוצאות Eval לבחירה.

E3 **Contrast D — Diversity Allocation:** מול E4 עם **אותו N ואותו R בדיוק**, אותו יחס מחלקות כולל ואותה מדיניות גודל/Pooling. אפשר להשוות `K=2` מול `K=6` רק אם לכל קבוצה יש לפחות די דוגמאות עצמאיות; אלה **דוגמאות מספריות**, לא ערכים שנקבעו. נשמור על ייצוג Real מותאם. אם E4 מכניסה VC ו-E3 רק TTS, התוצאה מודדת *גיוון משפחות*, לא רק מספר מודלים, ויש להצהיר על כך.

Contrast Source: אם בוחנים MLAAD לבדו, PhonemeDF לבדו ושילוב, מדובר גם בשינוי **מקור/שפה/דובר**, לא רק בשינוי Diversity. לא נסיק מכך מה גרם לשיפור בלי בקרות נוספות.

מדד ההרחבה המותנה: EER על **אותן קבוצות Holdout** שנקבעו לפני הניסויים; משני: Real/Fake Recall ו-Macro-F1 בסף Validation. אם קבוצת Holdout כוללת רק מערכות שכבר באימון, היא בודקת In-domain; אם שומרים מערכות חיצוניות חדשות בחוץ, ניתן לטעון Unseen-Generator רק לפי ההפרדה המאומתת. External data לעולם לא יכלול דוגמאות של Eval המיועד ל-.OOD

9.6 רפליקציות, Sampling ותלות בדוגמאות

מכיוון ש-PhonemeDF מייצר מספר נגזרות לכל מקור, **מספר הקבצים אינו מספר הדוגמאות העצמאיות.** ננהל `derivation_group_id` (או רכיבי קשירות של הקלטות מקור) ונבצע Subsampling ברמת מקור לפני בחירת גרסאות סינתטיות, ככל האפשר. לצורך Diversity נשתדל להשוות גם מספר מקורות דיבור עצמאיים, ולא רק N של קובצי Fake. **בהכרח, עבור N קבוע ו-K גדל, יורד מספר הדוגמאות הממוצע לכל Generator; זו תכונה של השוואת מדיניות הקצאת התקציב ואינה השפעה סיבתית מבודדת של K.** נריץ כמה Seeds לבחירת תתי-קבוצות **וגם מספר הרכבי Generator שונים לכל K** אם המאגר מאפשר זאת; נציג פיזור נפרד על פני הרכבים/דגימות ואימוני מודל; כאשר תקציב החישוב מוגבל, נעדיף יותר עצמאות בין מקורות על פני שכפול קבצים.

9.7 בדיקת פיילוט וחוקי עצירה

נבצע פיילוט **Small Data First**: אימות 100–300 דוגמאות/מטא-דאטה (מספר עבודה משוער, לא דרישת מחקר), בדיקות Hash/מקור, יצירת חלוקה מאוגדת, חילוץ Features ובדיקת תקינות Scores. אם אין רישוי ברור, אם Real התואם חסר, אם נמצא Overlap ל-Test, או אם יצירת ההשוואות דורשת הכנסת כמה גורמים משתנים בו-זמנית ללא אפשרות בקרה — נעצור את RQ3 ונשאיר אותו כ-*Not Feasible Under Verified Constraints*. זו תוצאה תכנונית לגיטימית ולא כישלון פרויקט.

9.8 מה אסור לעשות בניסויי ההרחבה

- להוסיף רק Fake חיצוני ממקור מסוים ואז לייחס את השיפור ל"מגוון זיופים" בלי בקרה על מקור/מחלקה.
- לערבב את Real המקורי של PhonemeDF עם נגזרת ממנו בצד אחר של Train/Test.
- להוריד 82GB ויותר של חומר לפני אימות רישוי, גישה ויכולת התאמה; פיילוט תחילה.

- לבחור K, N, מערכות או סף על בסיס תוצאות ה-Test שנועד לאמת אותם.
- לספור שבע נגזרות של אותו משפט כשבע משפחות מקור בלתי תלויות.
- להסיק מממצאי ה-KLD של PhonemeDF ש-EER בקורס בהכרח ישתפר.
- להציג שיפור מ-MLAAD v11 כאילו הוא כבר נמדד במאמר על גרסה זו.
- לכלול AT-ADD כניסוי אימון/בדיקה ישיר בלי גישה ורישוי מאומתים.

10. Augmentation, Robustness וניסויי בקרה

10.1 מדיניות נפרדת לניסוי אימון ולמבחן Robustness

Training Augmentation יופעל רק על Train, באותו כלל הסתברות ומנעד עיבוד ל-Real ול-Fake, אלא אם נבחנת השערה מפורשת על אסימטריה. **Robustness Evaluation** יופעל על Test שמור וקבוע מראש, ורק לאחר הקפאת מדיניות האימון. אין להשתמש בתוצאות אותה קבוצת Robustness Test כדי לכוונן מחדש מדיניות Augmentation; אם מבקשים להשוות Policies, נדרשת Robustness-Validation עצמאית מתוך Train/Validation בלבד.

10.2 ניסוי Augmentation מבוקר

זרוע	תכונה משתנה	תכונות קבועות	טענת תוקף
A0	ללא Augmentation	Dataset/Encoder/Classifier/Split	Clean baseline
A1	Codec/Resampling	כל היתר	Robustness לתנאי codec דומים בלבד
A2	Noise/RIR	כל היתר	Robustness להפרעות אקוסטיות דומות בלבד
A3	מדיניות משולבת	יתר הרכיבים נשארים	מודדת תערובת עיבודים, לא רכיב יחיד

אין חובה לבצע את ארבע הזרועות; נבחר לכל היותר ניסוי אחד בעל הצדקה מתוך EDA, ונבצע Ablation אם הזמן מאפשר. נבדוק גם האם ה-Augmentation פוגע ב-Clean EER. בעקבות AT-ADD נצטרך לדווח על **Real Recall תחת Shift** — לא רק כמה זיופים נתפסו.

10.3 Score Consistency והרחבות

בהשראת NKU-HLT ב-AT-ADD, אפשר בהמשך לעודד ציונים דומים לקליפ נקי ולגרסה שעברה שינוי שאינו משנה תווית. זו **היפותזה למחקר עתידי**; אינה תנאי לשלב הקורס. אם מממשים אותה, נדרש להשוות מודל זהה עם ובלי רכיב עקביות ולבחון גם תופעות לוואי: מחיקת עקבות זיוף רגישות לשינוי.

11. ניתוח שגיאות, Shortcut Learning וסיבתיות

11.1 חובה לדווח על יותר ממדד כולל

בהשראת AT-ADD, לכל מודל נדווח EER כללי, EER לפי מאגר כשקיימות שתי מחלקות, Fake Recall לפי Generator ככל שיש דוגמאות, Real Recall לפי מקור Real, התפלגות Scores וסף ההחלטה שנקבע על Validation. ממצאי BigVGAN ו-Replay ב-AT-ADD מצדיקים לבחון חולשות ממוקדות, לא להניח שכל Generator שקול לאחר. גם מודל בעל EER טוב עלול לסווג Real ממקור חדש כ-Fake.

11.2 Shortcut Probes

- **Dataset probe:** האם מקור הדיבור ניתן לחיזוי מתוך Features ב-Real בלבד? אם כן — המידע קיים; אין זו הוכחה שה-Detector משתמש בו.
- **Silence/Loudness/Bandwidth probes:** האם Scores רגישים במיוחד לתחילת/סוף שתיקה, DC Offset, עוצמה או חיתוך תדרים?
- **Matched transformations:** בוחרים אותה הקלטה ומפעילים שינוי ידוע תוך שמירה על תוויתה; אם ההחלטה משתנה, יש ראיה לרגישות לערוץ, לא בהכרח הוכחה לסיבת ההחלטה הכללית.
- **Source-matched fake/real:** כאשר יש Pairing, בודקים אם יתרון המסווג נשמר ללא הבדלי מקור טריוויאליים.
- **שגיאות משותפות:** עבור שני מודלים נוכל לחשב Jaccard בין קבוצות שגיאה, אבל רמת השלמה אינה מבטיחה ששילובם ישפר את התוצאות.

11.3 גבול ההסקה

ניסויי Cross-Dataset ו-LOSO מראים **איפה המודל מתקשה**. כדי לטעון **למה** הוא מתקשה, צריך ניסוי שמחזיק קבועים את יתר המשתנים ככל הניתן. הבדלי EER בין Domain A ל-Domain B עשויים לכלול Generator, Speaker, שפה, Source ו-Channel במקביל. לא נכתוב שמודל "למד רעש" רק מפני שהוא נכשל על M-AILABS; לכל היותר שהתוצאה מתיישבת עם תלות במאפייני מקור, ונציע בדיקת בקרה.

12. משאבים, מימוש ושחזוריות

12.1 עקרונות Compute

המחשב הזמין הוא MacBook Pro בעל M3 Pro; לכן נתעד אילוצי RAM/זיכרון ונעדיף **Frozen SSL Feature Extraction** ב-batches שמאפשרים ניהול זיכרון, Cache מקומי ומודלים קטנים. אין להניח שכל קוד מחקרי מבוסס CUDA ירוץ ללא התאמה ב-Apple Silicon. AASIST-Full/XLSR Fine-Tuning/Ensemble יישקלו רק אחרי Base Experiments, ולא לפי הצלחתם ב-Benchmark חיצוני בלבד.

12.2 רישום ניסוי מובנה

Experiment Contract — חובה לפני כל הרצה מחקרית:

שדה	מה נועלים מראש
`experiment_id`, `research_question`, `hypothesis`	מזהה, שאלה, השערה מאושרת
`train_manifest_hash`, `validation_manifest_hash`, `test_manifest_hash`	קבצי החלוקה, דוגמה למניעת שינוי בדיעבד
`grouping_rule`, `held_out_conditions`	יחידת מקור/דובר/Generator ומה הוחזק בחוץ
`representation`, `checkpoint_revision`, `preprocessing_fit_scope`	Feature config, Pretraining, Real-only או Real+Fake fit; ל-RQ2 גם `representation_selection_scope` וראיה לנעילה ללא Fake-labelled selection
`classifier`, `search_space`, `search_budget`, `seed`	מדיניות כוונון ותקציב השוואה
`primary_endpoint`, `secondary_metrics`, `threshold_rule`	איך מודדים ובאיזה סף
`contrast`, `interpretation_limit`, `stop_rule`	מה הושווה ומה אין להסיק; ל-Contrast S גם `n_fake_external`, `n_real_external`, `final_class_ratio`, `matching_policy`; ל-Contrast D אותם N/R בשתי הזרועות
`git_sha`, `environment`, `compute_budget`	קוד, סביבת הרצה ועלות
`result_status`, `deviations`, `audit_evidence`	התחייבויות שנבדקו וחריגות

לצד ה-Contract, לכל הרצה נשמור Scores ו-predictions מקומיים לצורך שיחזור EER/ROC, אימות היקף Test ושגיאות; תוצאות מסוכמות בלבד יועלו לריפו כשהדבר מותר. לא נשנה חוזה בעקבות Test: ניסוי חדש יירשם כ-Exploratory ותוצאתו תדרוש אישור שמור חדש.

12.3 יחידת בדיקות ו-Code Hygiene

- Unit Tests לפונקציית EER אחת: כיוון חיובי Spoof, דוגמאות ממוינות, ties, קלט חד-מחלקתי (אמור להיכשל עם הודעה), Interpolation וחישוב Rate עקבי.
- **Split Invariant Tests:** אין `derivation_group_id` או original recording identity משותפים בין Train/Validation/Test בפרוטוקול Strict; אין Speaker חופף כאשר נטען Speaker-Disjoint; אין Generator מוחזק בחוץ בשום שלב של `fit`/`select`.
- **Learned Preprocessing Scope:** M0/M1/M2 fit ל-Scaler/PCA/Feature Selection על Real Train בלבד; ייצוג RQ2 (Checkpoint/Layer/Pooling) רק ב-Train; M3 OC-Pure fit

ננעל ללא nu/gamma נקבעים ללא Fake לפי כלל לא-דגנרטיבי; שום Fake-labelled selection; רכיב נלמד אינו מתאמן על Test.

- **Test Access Audit:** כמות חשיפות Internal Test והקוד שיצר דו״ח סופי מתועדים; אין שינוי ארכיטקטורה לאחר החשיפה.
- **Cross-Dataset Tests:** רשימות יעד אינן מופיעות ב-Train; חפיפת Hash/מקור נבדקת; הקבוצות כוללות Real+Fake למדידת EER.
- **External Data Admission:** Gates עם ראיות; Unknown לא ייחשב PASS; רישוי, זוגות מקור ו-Metadata ייבדקו לפני אימון.
- **Competition Smoke Test:** CSV `id,score` עם סדר עמודות מדויק, ID יחיד, ציון מספרי ובדיקת מספר שורות — ללא תוויות Test או שימוש חוזר במבחן לצורך כוונון.

12.4 מדיניות קוד ונתונים

לא יועלו לריפו ציבורי אודיו, `train.csv`, קובצי Test, Embeddings, Metadata אישי, תוויות או רשימות שיכולות לחשוף מידע מוגן. קוד, קונפיגורציות ותוצאות אגרגטיביות יפורסמו רק בכפוף להנחיות ולרישיונות. נרשום את מקורם/גרסתם/רישיונם של נתוני Audio, מודלים, רעש/מוזיקה לשימוש Augmentation ו-Pretraining.

AI Prompt Log — נספח נדרש להגשה: נשמור משלב התכנון רשומת Prompt עם תאריך, כלי/מודל, משימה, נוסח הפרומפט, קובצי פלט/קוד שהושפעו, והאימות האנושי שבוצע; נוודא שאין בנספח מידע אישי או נתוני קורס שאסור לשתף. לפני כל Stage יוכן קובץ נספח Prompt Log לפי דרישת ההנחיות.

13. מסלול ביצוע, Gates וקריטריוני עצירה

13.1 Stage 1 — Literature Review + EDA + Baseline

מטרת ההגשה: מסמך 2–3 עמודים ומחברת. ייגזרו לפחות חמישה מאמרים מהסקירה; תוצג התפלגות הנתונים לפי מקור, דובר ומערכת, האזנה וספקטרוגרמות, ותוצאת EER אמיתית של M0. **Exit Gate:** קובץ הקורס נטען ונבדק; חלוקה תקפה (או מגבלתה) תועדה; Notebook משחזר EER; לא נבחרו מודלים לפי Test.

13.2 Stage 2 — Experimental Design

תוצר: מסמך תכנון בן שני עמודים ופגישת משוב. יכלול H1/H2 ותיאור RQ3 המותנה, M0 כ-Baseline ו-M1/M2 כשתי הגישות הנוספות, **M3 כניסוי ליבה מתוכנן**, פרוטוקול הערכה ראשי שינעל לאחר EDA, Cross-Dataset בעדיפות גבוהה, כללי Strict LOSO, Ablations, מדדים, Stop Rules וגבולות הסקה. אם ה-EDA עדיין לא הושלם, יצוין במפורש Gate תלוי-Metadata במקום להציג חלוקה מומצאת.

יציאה: `evaluation_contract` ו-Experiment Contracts בסיסיים מוכנים לפני הרצת התוצאות הקובעות; מסמך של שני עמודים נגזר ממסמך האב ולא מועתק ממנו.

Stage 3 — Experiments, Results & Competition 13.3

תוצר: דוח 6–8 עמודים, קוד מאפשר שחזור, M0–M2 לפחות, **M3 כליבת RQ2 אם Gate תקף**, Cross-Dataset בהתאם לדרישות הקורס או הסבר מפורש לבעיית היתכנות שהועלתה למרצה, תוצאות P0/P1 ככל שניתן, ניתוח Real/Fake שגיאות ואי-ודאות. תוצאות שליליות הן חלק מהדוח.

Internal Test: ייחשף רק לאחר שפרוטוקול הבחירה נסגר; כל בדיקה שמניעה מודל חדש מסומנת Exploratory ואינה ראיה מאשרת על אותו Final Model Freeze. **Competition:** Test לפני פרסום מבחן התחרות; לאחר הפרסום inference בלבד, בדיקת שלמות `id,score`, והגשה יחידה לפי ההנחיות. **Prompt Log:** נצרף את תיעוד הפרומפטים הנדרש.

13.4 התקדמות מדורגת — סדר העבודה

סדר	תוצר	Gate מעבר
0	EDA, Provenance graph, Metadata Schema, Split Manifest, מבחני EER	תנאי Group/Real+Fake והגדרת יחידות אי-תלות
1	**Protocol Lock**: בחירת P1/P2/P0 כ-Primary, פירוט P2 החובה והקפאת Test Governance	בלי צפייה ב-Scores של מודלים
2	M0 + Notebook: EER ראשון	Validation בלבד לבחירת מודל
3	M1 + M2: השוואת Representations, תקציב כוונון אחיד	אותם Splits, EER Scores ו-Model Contracts
4	**M3 OC-Pure** ואופציונלית OC-Supervised-Val	Real-only fit, Stop Rule, השוואה מול M2
5	P1 Strict/limited LOSO ו-P2 Cross-Dataset כפי שנקבעו בפרוטוקול	נגזרות מקור/שני Classes/אין Test Tuning
6	פיילוט MLAAD/PhonemeDF מותנה	G1–G7 PASS
7	E0–E5 Size × Diversity מותנה	N/K והרכבי Generators נעולים מראש
8	Augmentation, WavLM, Fusion או Pooling רק אם יש ראיה ותקציב	Experiment Contract ו-Validation נפרד
9	Final Model Freeze, Prompt Log, Competition Inference	אין אימון לאחר חשיפת המבחן; CSV תקין

שלבים 6–8 מותנים; אין לפגוע בביצוע Stage 1–3 המחויבים כדי לבצע הרחבת נתונים. אם M3 לא ניתן לביצוע מסיבה מתודולוגית מוכחת, RQ2 תסומן 'not tested' במפורש.

14. Risk Register ופתרונות מראש

סיכון	השפעה	סימן אזהרה	מענה / החלטת Stop
מיעוט דוגמאות לכל Generator	EER לא יציב	מספר נמוך מאוד ב-LOSO	לא להציג פר-Generator EER מדויק לכאורה; לצרף n ו-CI או לוותר
זהות דובר לא ייחודית	Overlap לא מזוהה	Speaker IDs סותרים	Audit ידני/מקור; לא לטעון Speaker-Disjoint מלא
נגזרות Real/Fake חוצות חלוקה	Leakage	אותו `derivation_group_id` או קשר נגזרת משני צדדים	Group split מחמיר; פסילת ניסוי אם אין פתרון
דיבור Real ממאגר אחד בלבד	Shortcut	מקור מנבא תווית	בקרה/Real matching; שינוי ניסוי ולא רק שיפור Score
חוסר Real חיצוני תואם ל-MLAAD	Confounding	Fake חיצוני ייחודי למקור	עיכוב RQ3 או הגבלת פרשנות
רישוי PhonemeDF לא מאומת	שימוש לא מורשה	UNKNOWN ב-G2	לא לכלול דוגמאות בניסוי
Train/Test מתערבבים ב-Pretraining	אי-תלות חלקית	מקור משותף לא מתועד	Provenance disclosure; לא לטעון עצמאות מוחלטת
עומס חישובי	איחור בדרישות הקורס	Feature extraction איטי/זיכרון חסר	Frozen features, פיילוט, Cache, ביטול הרחבות
כוונון על Test	הטיית תוצאה	שינוי Threshold אחרי Eval	הקפאת Config; Test חדש אם נדרש אימות
שחיקת Internal Test דרך החלטות מחקר	Selection Bias	מודל חדש בעקבות Test קודם	פרוטוקול נעול, Test חד-פעמי, סימון Exploratory / Holdout חדש
זליגת Fake ל-OC-Pure דרך Scaler/PCA	השוואה שאינה One-Class טהורה	`fit()` על שתי מחלקות	אכיפה אוטומטית על Real-only ב-M3
מודלים שונים ללא כלל הכרעה	בחירה בדיעבד על המדד הנוח	סתירה בין In-domain ל-OOD	Primary endpoint נעול, דיווח Secondary מלא ובחירת Competition נפרדת
Mix of Generators and Channels	סיבתיות לא ברורה	כל המשתנים משתנים יחד	Reporting על Shift משולב בלבד
Overfitting לשינויי אודיו	ירידה ב-Clean performance	A1/A2 פוגעים ב-Clean	בדיקת שני התנאים והעדפת מודל יציב

סיכון	השפעה	סימן אזהרה	מענה / החלטת Stop
שגיאות ב-Scoring	תוצאות מטעות	מודל טוב עם EER חריג	Unit Tests, כיוון Score אחיד, Audit

15. Decision Log — מאושר, מותנה, פתוח

15.1 החלטות מאושרות במסגרת התכנון

1. הפרויקט נשאר **Binary Speech Deepfake Detection**; מדד EER מרכזי.
2. בסיס נתוני הקורס: 1,520 קטעים; M-AILABS משמש Real בלבד.
3. M0 MFCC+LR; שתי גישות חובה נוספות M1 CQCC+LR ו-M2 Frozen wav2vec2+LR.
4. M3 One-Class SVM על **ייצוג משותף וקבוע מראש ללא Fake-labelled selection** הוא **ניסוי ליבה מתוכנן** לאחר השלמת השלישייה הראשונית; אם לא ישים, RQ2 תסומן כלא נבדקה.
5. כל המודלים יושוו על אותן חלוקות מאומתות ועם כיוון Score אחיד; Trial/Model Selection יבוצעו רק באמצעות Inner Validation.
6. הפרדה בין אימון, Validation, Internal Test ו-Test התחרות; מניעת שחיקת Test דרך בחירות חוזרות.
7. AT-ADD הוא **Research Paper 10** מתודולוגי; אינו Dataset 03 ברשימת מאגרי האימון.
8. MLAAD ו-PhonemeDF הם מועמדי Dataset בלבד, וכפופים ל-Gates.
9. אין קביעה מראש ש-One-Class/SSL/Augmentation/Ensemble עדיפים — אלה השערות לבדיקה.
10. ההערכה תפריד בין In-Domain, Unseen System, Cross-Dataset ו-Channel Shift.

15.2 החלטות שטרם ניתן לקבע

- מספר Folds ויחס החלוקה; ייקבע לאחר EDA של דוברים ומקורות.
- האם LOSO תקף עבור מזהי Generator הספציפיים בקובץ הקורס.
- האם אפשר לבצע Speaker-Disjoint וגם Source-Disjoint מלא לכל ניסוי.
- רישוי ההרחבה, חפיפת מאגרים והתאמת Real חיצוני.
- ערכי N ו-K, היחס בין TTS/VC, שפות ומספר Seeds בניסויי RQ3.
- בחירת checkpoint/שכבה/Pooling לניסויי M2 המפוקחים, ללא השפעה על הייצוג הנעול מראש להשוואת RQ2.
- האם יש טעם להוסיף WavLM, AASIST-L או Score Consistency.
- מסגרת אופטימיזציה של זמן ריצה על Apple Silicon.

15.3 תנאים מפורשים שלא נבטיח לפני מדידה

אין כאן EER של הקורס, אין הוכחת יכולת הכללה ל-Generator חדש, אין תוצאת השוואת Size/Diversity, אין הצהרת Speaker-Disjoint מלאה, ואין אישור שהרישוי של כל מאגר חיצוני תקין. אלה יושלמו באמצעות EDA, Gates וניסויים, או יסומנו כבלתי ישימים.

16. Expected Contributions וגבולות הדיווח

בסיום הפרויקט אנו שואפים להציג: (1) Baseline שקוף ו-EER אמיתי; (2) השוואת ייצוגים בשליטה על מסווג והחלוקה; (3) השוואת Binary/One-Class אם M3 ישים; (4) לפחות מבחן הכללה אחד שתוקפו הוכח מול ה-(6); (5) Real/Fake error breakdown; Metadata ממצאים חיוביים ושליליים עם אי-ודאות; (7) קוד ניתן לשחזור ומודל סופי בפורמט התחרות. אם RQ3 יעמוד ב-Gates, נוסיף תרומה אמפירית על ההבדל בין **הגדלת נפח האימון** לבין **הרחבת מגוון מערכות היצירה**; אם לא, נתעד את סיבות אי-הישימות ולא ניצור מסקנה ללא בקרה.

עיקרון מסכם: הצלחה אינה רק ה-EER הנמוך ביותר על קבוצה אחת. הצלחה מחקרית היא היכולת לומר איזו החלטה גרמה *לשינוי עד גבול התקפות שהניסוי מאפשר*, אילו דומיינים נבדקו, באילו תנאים המערכת נכשלת, וכיצד ניתן לשחזר זאת.

נספח A — Experiment Contract לדוגמה: M3 מול M2

רכיב	החלטה מחייבת בתכנון
שאלת מחקר	RQ2 — האם One-Class משפר הכללה יחסית ל-Binary על אותו Frozen wav2vec 2.0?
יחידת פיצול	לפי `derivation_group_id` ובמידת הטענה גם speaker, מתוך Audit
ייצוג	Checkpoint, שכבה ו-Pooling זהים **ונבחרו מראש ללא שימוש בתוויות Fake**; ניסויי ייצוג נבחר-Validation ל-M2 יישמרו מחוץ לחוזה RQ2
Training	M2: Real+Fake; M3-Pure: Real בלבד, כולל Scaler/PCA וכל טרנספורמציה נלמדת; `nu` ו-policy של `gamma` קבועים מראש או נבחרים לפי כלל Real-only לא-דגנרטיבי
Validation	M2: מתויג לבחירת LR; M3-Pure: Real-only, ללא בחירה של Layer/Pooling לפי Fake וללא בחירת `nu`/`gamma` על Real Recall המוכתב מכיול אחוזון קבוע; OC-Supervised-Val נבדק בנפרד אם ייבחר
Primary Metric	הפרש EER ב-Primary Research Protocol הנעול
Secondary Metrics	Real Recall, Fake Recall, קבוצות Generator, זמן חילוץ/אימון
לא ניתן להסיק	שהחלפת מסווג בלבד מסבירה פער; שכל זיוף עתידי יתגלה
Stop	חוסר קבוצות Real עצמאיות / Source Leakage לא פתיר / נתוני Eval לא מתאימים

נספח B — רשימת בדיקת Pre-EDA → Locked Protocol

- [ ] `train.csv` נטען ונבדקו השדות הקיימים בפועל, התוויות והמספרים.
- [ ] הוגדרו original recording / derivation / speaker groups, כולל Unknowns.
- [ ] ל-P0/P1/P2 יש ספירה של Real/Fake בכל Fold ומשפחות מקור.
- [ ] נבחרה חלופה ראשית מההירכיה, ללא צפייה בתוצאות מודל.
- [ ] הוגדרה מדיניות Inner Validation, זמני חשיפת Test וסף ה-Validation.
- [ ] ננעלה שיטת דיווח EER per-fold, פיזור, Aggregation ואי-ודאות.
- [ ] אושרו Experiment Contracts ל-M0–M3, כולל תקציב כוונון הוגן.
- [ ] נוצרו בדיקות שמבטיחות `OC-Pure` Real-only fitting.
- [ ] נבדקו אילוצי Cross-Dataset מהקורס והוגדרה תוכנית טיפול בחפיפות.
- [ ] הוכנה מדיניות Final Refit/Freeze ו-Prompt Log מתחילת העבודה.
- [ ] עבור RQ2 ננעלו Checkpoint, שכבה ו-Pooling לפני שימוש בתוויות Fake לבחירת ייצוג, והופרדו ניסויי ייצוג מפוקחים של M2.
- [ ] ב-OC-Pure נקבעו `nu`/policy של `gamma` ללא Fake, והוכח שכלל Real-only אינו מתנוון לאחר כיול הסף.
- [ ] ב-Contrast S נקבעו `N_low/R_low` ו-`N_high/R_high`, תועד יחס Real:Fake הסופי בכל Train ונבדקה השפעת Class Balance; ב-Contrast D ננעלו אותו N ואותו R.

כלל סיום התכנון: המסמך מקבע את *שיטת קבלת ההחלטות*, לא תוצאות EDA שלא בוצעו. מזהים, Folds, ערכי N/K, מודלים חיצוניים ורכיבי גיוון יתועדו רק לאחר בדיקה אמפירית, ובכל מקרה לפני שהם משמשים להכרעה על Test.

ביבליוגרפיה — 12 המקורות שנקראו

[1] Wang et al. (2024). *ASVspoof 5: Crowdsourced Speech Data, Deepfakes, and Adversarial Attacks at Scale*. arXiv:2408.08739. https://arxiv.org/abs/2408.08739

[2] Wu, H., Tseng, Y., & Lee, H.-y. (2024). *CodecFake: Enhancing Anti-Spoofing Models Against Deepfake Audios from Codec-Based Speech Synthesis Systems*. Interspeech 2024. https://arxiv.org/abs/2406.07237

[3] Todisco, M., Delgado, H., & Evans, N. (2017). *Constant Q cepstral coefficients: A spoofing countermeasure for automatic speaker verification*. Computer Speech & Language, 45, 516–535. https://doi.org/10.1016/j.csl.2017.01.001

[4] Jung et al. (2022). *AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks*. ICASSP 2022. https://doi.org/10.1109/ICASSP43922.2022.9747766

[5] Baevski et al. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech*

Representations. NeurIPS. https://arxiv.org/abs/2006.11477
Chen et al. (2022). *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech* [6]
Processing. IEEE JSTSP, 16(6), 1505–1518. https://doi.org/10.1109/JSTSP.2022.3188113
Wu, S., Cheng, Y., Wang, R., & Yan, D. (2026). *Robust Speech Forgery Detection via* [7]
Enhanced Forensic Trace Generation. Signal, Image and Video Processing.
https://doi.org/10.1007/s11760-026-05167-y
Izrailov, K. E., Kotenko, I. V., & Chechulin, A. A. (2026). *Intelligent Voice Fraud Detection* [8]
Methods in Authentication Systems. Pattern Recognition and Image Analysis.
https://doi.org/10.1134/S1054661826700203
Yin, J., & Lei, S. (2026). *A Novel Attack-Resistant Speech Forgery Detection Method* [9]
Integrating One-Class Learning and Wav2vec2. CNML 2026.
https://doi.org/10.1109/CNML68938.2026.11452384
Müller et al. (2024). *MLAAD: The Multi-Language Audio Anti-Spoofing Dataset*. IJCNN [10]
2024. https://doi.org/10.1109/IJCNN60899.2024.10650962; v11 (2026):
https://arxiv.org/abs/2401.09512
Nallaguntla et al. (2026). *PhonemeDF: A Synthetic Speech Dataset for Audio Deepfake* [11]
Detection and Naturalness Evaluation. LREC 2026, 5905–5915.
/https://aclanthology.org/2026.lrec-1.469
Xie et al. (2026). *AT-ADD: A Benchmark and Challenge for Robust and All-Type Audio* [12]
Deepfake Detection. arXiv:2608.23437v2. https://arxiv.org/abs/2608.23437

מקור להגדרת דרישות הקורס: *זיהוי זיופים קוליים: אמיתי או מזויף?*, HIT, אוקטובר 2026; אינו נספר כאחד מ-12 מאמרי המחקר.